Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Computación Cuántica

Red Neuronal Cuántica Híbrida para la Predicción de Estructura Tridimensional de Proteínas mediante Embeddings de Lenguaje Proteico

Trabajo Fin de Máster

presentado por: Marco Antonio Roca Rodríguez

Dirigido por: Mariano Caruso

Ciudad: Madrid

Fecha: 2026

Índice

Índice de figuras **iv**

Índice de tablas **vi**

Resumen **vii**

Abstract **viii**

1 Introducción **1**

1.1 Motivación . . . 3

1.2 Planteamiento del trabajo . . . 4

1.3 Principales aportaciones . . . 5

1.4 Estructura del trabajo . . . 6

2 Contexto y estado del arte **7**

2.1 Antecedentes históricos . . . 7

2.1.1 De las secuencias a las estructuras: el problema central . . . 7

2.1.2 Los cuatro niveles de la estructura proteica . . . 8

2.1.3 Evolución de los métodos de predicción: de la homología al aprendizaje profundo . . . 9

2.1.4 El experimento CASP: el termómetro del campo . . . 11

2.1.5 Mapas de contactos y mapas de distancias . . . 12

2.2 Estado actual . . . 13

2.2.1 Modelos de lenguaje proteico: aprender sin etiquetas . . . 13

2.2.2 Fundamentos de computación cuántica . . . 14

2.2.3 Redes neuronales cuánticas híbridas . . . 17

2.2.4 Tipos de circuito cuántico: VQC, TTN y MERA . . . 17

2.2.5 El concepto de ventaja cuántica . . . 19

2.2.6 Aplicaciones de redes neuronales cuánticas a bioinformática . . . 20

2.2.7 El conjunto de datos ProteinNet . . . 20

3 Objetivos **22**

3.1 Objetivos generales . . . 22

3.2 Objetivos específicos 23

4 Desarrollo del Trabajo **25**

4.1 Visión general del sistema 26

4.2 Etapa 1: Preprocesamiento de datos (Bloques 1–6) 26

4.2.1 Bloque 1 — Importaciones y detección de hardware 26

4.2.2 Bloque 2 — Configuración global e hiperparámetros 28

4.2.3 Bloque 3 — Carga del modelo ESM-2 28

4.2.4 Bloque 4 — Carga y parseo de ProteinNet 30

4.2.5 Bloque 5 — Utilidades geométricas y extracción de pares 31

4.2.6 Bloque 6 — Conjunto de datos, balanceo y cargadores 32

4.2.7 Resumen del formato de datos y del flujo de preprocesamiento . . . 34

4.3 Etapa 2: Arquitectura del modelo híbrido (Bloques 7–8) 35

4.3.1 Bloque 7 — Circuito cuántico MERA 35

4.3.2 Bloque 8 — Modelo híbrido HybridQNN_MultiTask 38

4.4 Etapa 3: Entrenamiento (Bloques 9–10) 39

4.4.1 Bloque 9 — Entrenamiento con parada temprana y checkpoint . . . 40

4.4.2 Bloque 10 — Curvas de entrenamiento y diagnóstico 41

4.5 Retos de implementación y decisiones de diseño 42

4.5.1 El reto de la eficiencia computacional 42

4.5.2 El equilibrio entre capacidad y datos 43

4.5.3 La representación de las características 43

4.6 Etapa 4: Evaluación, ablación y visualización (Bloques 11–19) 44

4.6.1 Bloque 11 — Conjuntos de evaluación 44

4.6.2 Bloque 12 — Métricas de predicción de contactos 44

4.6.3 Bloque 13 — Reconstrucción tridimensional 46

4.6.4 Bloque 14 — Métricas de estructura tridimensional 47

4.6.5 Bloque 15 — Evaluación del modelo entrenado 47

4.6.6 Bloque 16 — Estudio de ablación del componente cuántico 48

4.6.7 Bloque 17 — Tablas comparativas con CASP 48

4.6.8 Bloques 18 y 19 — Exportación y visualización 48

4.7 Guía de ajuste de hiperparámetros 49

5 Resultados y discusión **50**

5.1 Métricas de evaluación empleadas 50

5.2 Resultados de predicción de contactos 52

5.3 Resultados de reconstrucción estructural 3D 53

5.4 Análisis cualitativo de un caso concreto 57

5.5 Discusión del estudio de ablación 58

5.6 Síntesis de los resultados 60

6 Conclusiones **61**

6.1 Conclusiones sobre el rendimiento del sistema 61

6.2 Conclusiones sobre el componente cuántico 62

6.3 Conclusiones metodológicas 63

6.4 Valoración global 64

7 Trabajo futuro **67**

7.1 Limitaciones del trabajo actual 67

7.2 Representaciones de entrada de mayor capacidad 68

7.3 Mejoras en la arquitectura cuántica 69

7.4 Aceleración mediante redes tensoriales 70

7.5 Extensiones del pipeline de reconstrucción 71

7.6 Aplicaciones al descubrimiento de proteínas 71

7.7 Reflexión final sobre la línea de investigación 72

Bibliografía **73**

Apéndices **79**

.1 Repositorio de código 79

Índice de figuras

2.1 Los cuatro niveles de organización de la estructura de una proteína. 9

2.2 Las tres generaciones de métodos de predicción de estructura proteica. . . . 10

2.3 Relación entre la estructura tridimensional, el mapa de distancias y el mapa de contactos de una proteína. 13

2.4 Representación del estado de un qubit en la esfera de Bloch. El vector $|\psi\rangle$ puede apuntar a cualquier punto de la superficie. 16

2.5 Comparación esquemática de los tres ansätze cuánticos. R: rotación; U: isometría (pooling); D: disentangler. 18

4.1 Organización general del sistema en cuatro etapas y trece bloques. 25

4.2 Flujo de datos de extremo a extremo del sistema propuesto. En violeta, el componente cuántico. 27

4.3 El modelo ESM-2 transforma cada aminoácido de la secuencia en un vector numérico (embedding) que captura su contexto. 30

4.4 Efecto del balanceo por bins sobre la distribución de distancias del conjunto de entrenamiento. 33

4.5 Diagrama de bloques de la arquitectura propuesta `HybridQNN_MultiTask`. En violeta, el componente cuántico; en verde, las tres cabezas de predicción. 35

4.6 Detalle de las puertas cuánticas del circuito MERA. A la izquierda, un bloque de entrelazamiento $B(\boldsymbol{\theta})$: rotaciones R_Y y R_Z parametrizadas sobre cada qubit seguidas de una puerta CNOT. A la derecha, un *disentangler* $D(\boldsymbol{\phi})$, que combina puertas CNOT en ambos sentidos con rotaciones intermedias para eliminar el entrelazamiento espurio entre escalas. 37

4.7 Esquema jerárquico de renormalización en tres niveles, ilustrado sobre la variante TTN base de la que parte el diseño. Cada bloque (B, violeta) aplica rotaciones R_Y y R_Z seguidas de una puerta CNOT que entrelaza y reduce el número de qubits activos. El circuito MERA de 12 qubits del modelo principal extiende este esquema añadiendo puertas de *disentangling* entre niveles y una medición extendida del estado. 38

4.8 Ciclo de entrenamiento que se repite en cada época hasta la parada temprana. 41

4.9 Pipeline de reconstrucción tridimensional a partir del mapa de distancias predicho. 47

5.1 Precisión de los contactos de largo alcance (≥24, lista @L/5) en el contexto del experimento CASP11. La irrupción de las técnicas de covariación elevó el mejor resultado desde en torno al 20% en CASP10 hasta el 27% de CONSIP2 en CASP11. El sistema propuesto, que no emplea alineamientos múltiples, se sitúa por debajo de ese nivel pero por encima tanto de la predicción nativa de ESM-2 como del predictor aleatorio (línea discontinua). 56

5.2 Comparación esquemática entre la estructura real y la predicha para `2KJI`, una proteína de 50 aminoácidos del conjunto de validación y el mejor caso del conjunto evaluado (GDT_TS 0,485, TM-score 0,393, RMSD 3,55 Å). En cadenas cortas el sistema reproduce de forma reconocible la topología general; en cadenas largas la reconstrucción se degrada notablemente. . . . 58

Índice de tablas

4.1 Hiperparámetros de la configuración de referencia. 29
4.2 Campos de información de cada proteína en el conjunto de datos ProteinNet. 34

5.1 Precisión de predicción de contactos sobre las 224 proteínas del conjunto de validación oficial de ProteinNet CASP11, siguiendo el protocolo del experimento CASP: rangos **exclusivos** de separación de secuencia y listas reducidas de los contactos mejor puntuados. Umbral de contacto de 8 Å. . . 53
5.2 Métricas de reconstrucción tridimensional sobre 30 proteínas del conjunto de validación oficial de ProteinNet CASP11. Junto a la media se incluyen la desviación típica y los valores extremos del conjunto, que reflejan la elevada variabilidad del sistema entre proteínas: el mejor caso corresponde a una cadena de 50 residuos y el peor a una reconstrucción degenerada. Valores más bajos son mejores en RMSD; más altos en el resto de métricas. 54
5.3 Precisión media de los contactos de largo alcance (@L/5) en el experimento CASP11, en el que participaron 29 grupos sobre dominios de modelado libre. Se incluye como referencia el mejor resultado de CASP10 para dimensionar el salto que supusieron las técnicas de covariación, y los resultados de este trabajo. 55
5.4 Estudio de ablación de la ruta cuántica. Precisión @L/5 en el rango de largo alcance, el criterio de CASP. Ambos brazos comparten datos, semilla e hiperparámetros; la única diferencia es la capa que ocupa la ruta intercambiable. 59

6.1 Síntesis de los principales hallazgos del trabajo, con las cifras más representativas de cada uno. 66

Resumen

La predicción de la estructura tridimensional de proteínas es un problema fundamental de la biología computacional. Este trabajo presenta el diseño y la evaluación de una red neuronal híbrida clásico-cuántica para predecir mapas de contactos y distancias entre carbonos alfa a partir de la secuencia de aminoácidos, sin recurrir a alineamientos de secuencias múltiples. La arquitectura combina las representaciones del modelo de lenguaje proteico ESM-2 con un circuito cuántico variacional MERA de 12 qubits y cabezas de predicción clásicas multitarea. El sistema se entrena sobre ProteinNet CASP11 y se evalúa sobre las 224 proteínas de su conjunto de validación oficial siguiendo el protocolo del experimento CASP. Los resultados muestran que el sistema propuesto supera a la predicción de contactos que ESM-2 genera de forma nativa en los tres rangos de separación de secuencia, con mejoras de 19,0, 15,8 y 2,1 puntos porcentuales. En términos absolutos, la precisión sobre los contactos de largo alcance —el criterio que emplea CASP— alcanza el 10,9%, frente al 27,0% del mejor grupo de CASP11, que sí utiliza alineamientos múltiples. Un estudio de ablación controlado, replicado en dos ejecuciones independientes, sustituye el circuito cuántico por una capa lineal de capacidad equivalente manteniendo el resto del sistema inalterado: la diferencia de rendimiento resulta indistinguible del ruido experimental. Se concluye que la mejora observada es atribuible a la arquitectura clásica y no al componente cuántico, y se identifican las limitaciones de codificación y de escala que explican este comportamiento.

Palabras clave: computación cuántica, red neuronal cuántica híbrida, predicción de estructura de proteínas, TTN, embeddings ESM-2

Abstract

Protein three-dimensional structure prediction is a fundamental problem in computational biology. This work presents the design and evaluation of a hybrid classical-quantum neural network that predicts alpha-carbon contact and distance maps from sequence alone, without multiple sequence alignments. The architecture combines ESM-2 protein language model representations with a 12-qubit MERA variational quantum circuit and classical multitask prediction heads. The system is trained on ProteinNet CASP11 and evaluated on the 224 proteins of its official validation set following the CASP assessment protocol. The proposed system outperforms ESM-2's own native contact prediction across all three sequence-separation ranges, by 19.0, 15.8 and 2.1 percentage points respectively. In absolute terms, precision on long-range contacts —the criterion used by CASP— reaches 10.9%, against 27.0% for the best CASP11 group, which does rely on multiple sequence alignments. A controlled ablation study, replicated over two independent runs, replaces the quantum circuit with a classical linear layer of equivalent capacity while leaving the rest of the system unchanged: the resulting performance difference is indistinguishable from experimental noise. We conclude that the observed improvement is attributable to the classical architecture rather than to the quantum component, and identify the encoding and scale limitations that account for this behaviour.

Keywords: quantum computing, hybrid quantum neural network, protein structure prediction, MERA, ESM-2 embeddings

1. Introducción

Este primer capítulo presenta el problema que aborda el trabajo, explica por qué es relevante y plantea la propuesta que se desarrolla a lo largo de la memoria. El objetivo es que cualquier lector, aunque no sea experto en biología ni en computación cuántica, pueda entender de qué trata el trabajo y qué se pretende conseguir con él. Para ello se parte de lo más básico —qué es una proteína y por qué importa su forma— y se avanza progresivamente hasta llegar a la idea central que combina inteligencia artificial y computación cuántica. El capítulo se organiza en cuatro secciones: una introducción general al problema, la motivación del trabajo, el planteamiento de la propuesta y, por último, la estructura del resto del documento.

Cuando se habla de proteínas, a menudo se piensa en algo muy abstracto relacionado con la biología o la medicina. Sin embargo, las proteínas son en realidad las moléculas que hacen que casi todo funcione en un ser vivo: desde digerir la comida hasta defenderse de infecciones, pasando por construir los músculos o transmitir señales entre neuronas. Son, en cierto modo, las herramientas con las que trabaja el cuerpo, y cada una está especializada en una tarea concreta.

Lo que hace especialmente interesantes a las proteínas desde el punto de vista computacional es que están compuestas por cadenas de bloques más pequeños llamados aminoácidos (Nelson y Cox 2005), y que la secuencia exacta en que estos aminoácidos se encadenan determina completamente cómo la proteína se dobla en el espacio tridimensional. Esa forma tridimensional, a su vez, determina su función. Es decir, si conocemos la secuencia, en teoría podemos deducir la forma, y si conocemos la forma, podemos saber para qué sirve la proteína. Esta cadena de implicaciones es la base de toda la biología estructural moderna.

El problema está en que predecir esa forma a partir de la secuencia es extraordinariamente difícil. Esto es lo que se conoce como el problema del plegamiento de proteínas (Anfinsen 1973), y lleva décadas resistiendo todos los intentos de resolución computacional. La dificultad viene del hecho de que una proteína de tamaño mediano puede adoptar un número astronómico de configuraciones posibles (Levinthal 1969), y aun así siempre acaba encontrando su forma correcta en cuestión de milisegundos dentro de la célula. Entender y reproducir ese proceso ha sido uno de los grandes retos de la biología computacional durante más de medio siglo (Dill y MacCallum 2012).

Predecir la estructura de proteínas tiene aplicaciones enormes. En el diseño de fármacos, por ejemplo, muchos medicamentos funcionan porque su molécula encaja perfectamente en una proteína específica, como una llave en una cerradura (Blundell et al. 2002). Si se puede predecir la forma de esa proteína sin necesidad de experimentos costosos como la cristalografía de rayos X (Berman et al. 2000) o la criomicroscopía electrónica (Cheng 2015), se acelera enormemente el desarrollo de nuevos tratamientos. Lo mismo aplica para entender enfermedades relacionadas con proteínas mal plegadas, como el Alzheimer o el Parkinson (Dobson 2003), en las que la proteína adopta una forma incorrecta que resulta tóxica para las células.

Durante décadas, los avances en este campo fueron lentos y se basaban principalmente en comparar proteínas nuevas con proteínas ya conocidas mediante técnicas de modelado por homología (Chothia y Lesk 1986). Pero en 2021 todo cambió. La empresa DeepMind publicó AlphaFold2 (Jumper et al. 2021), un sistema de inteligencia artificial que resuelve el problema del plegamiento con una precisión cercana a la experimental para muchas proteínas. Fue un hito histórico, celebrado en la portada de las revistas científicas más importantes del mundo y considerado uno de los mayores avances de la biología en décadas (Callaway 2020).

Sin embargo, AlphaFold2 y sistemas similares como RoseTTAFold (Baek et al. 2021) tienen una limitación importante: necesitan disponer de Alineamientos de Secuencias Múltiples (MSA, del inglés *Multiple Sequence Alignments*) (Edgar 2004), es decir, colecciones de secuencias de proteínas similares procedentes de otras especies que permiten inferir qué posiciones de la cadena han evolucionado de forma conjunta. Para proteínas bien estudiadas con muchos homólogos conocidos esto funciona muy bien, pero para proteínas huérfanas —aquellas sin parientes evolutivos conocidos— o para proteínas diseñadas artificialmente desde cero, el rendimiento cae drásticamente (Lin et al. 2023). Esta dependencia del MSA es precisamente una de las debilidades que motiva la búsqueda de enfoques alternativos.

Aquí es donde entra la idea principal de este trabajo. Por un lado, se plantea la posibilidad de prescindir de los MSA usando modelos de lenguaje proteico (Rives et al. 2021), que ya han aprendido implícitamente la información evolutiva durante su entrenamiento. Por otro lado, se explora si las propiedades de la computación cuántica (Nielsen y Chuang 2000) pueden aprovecharse para construir un modelo más expresivo utilizando

muchos menos parámetros que las redes neuronales clásicas. La combinación de ambas ideas constituye el núcleo del trabajo.

1.1 Motivación

La motivación de este trabajo nace de la intersección de dos observaciones independientes. La primera es que los métodos actuales de predicción de estructura proteica, pese a su éxito, arrastran una dependencia importante de los alineamientos de secuencias múltiples. La segunda es que la computación cuántica ofrece propiedades matemáticas que podrían resultar especialmente útiles en problemas de este tipo. A continuación se desarrolla cada una de estas dos motivaciones.

En cuanto al primer punto, los modelos de lenguaje proteico como ESM-2 (Lin et al. 2023), desarrollado por la empresa Meta AI, han demostrado que es posible extraer información estructural muy rica directamente de la secuencia de aminoácidos, sin necesidad de buscar proteínas similares en bases de datos. Estos modelos aprenden patrones en millones de secuencias proteicas de la misma manera que los modelos de lenguaje para texto aprenden la gramática y el significado de un idioma (Vaswani et al. 2017). El resultado son representaciones numéricas por residuo —llamadas embeddings— que capturan de forma implícita qué aminoácidos tienden a estar cerca en el espacio cuando la proteína se pliega. Disponer de esta información sin recurrir al MSA abre la puerta a predecir la estructura de proteínas que carecen de homólogos conocidos.

En cuanto al segundo punto, las Redes Neuronales Cuánticas (QNN, del inglés *Quantum Neural Networks*) (Biamonte et al. 2017) son un tipo de modelo que combina circuitos cuánticos con redes neuronales clásicas. Su ventaja teórica es que pueden representar funciones muy complejas con un número reducido de parámetros, ya que el espacio de estados de un sistema cuántico crece exponencialmente con el número de qubits (Cerezo et al. 2021). En particular, las arquitecturas jerárquicas de tipo red tensorial —como el TTN (Tree Tensor Network) y su extensión, el MERA (Multi-scale Entanglement Renormalization Ansatz) (Vidal 2007), inspiradas en técnicas del grupo de renormalización de la mecánica cuántica— están diseñadas específicamente para capturar correlaciones a múltiples escalas. Esta capacidad es especialmente relevante en proteínas, donde residuos muy distantes en la secuencia pueden encontrarse muy próximos en el espacio tridimensional una vez la proteína se ha plegado.

La combinación de embeddings ESM-2 con circuitos cuánticos jerárquicos de tipo red tensorial es, hasta donde se ha podido constatar en la literatura, una aproximación novedosa al problema de predicción de estructura proteica. Esta novedad, unida al interés práctico de prescindir del MSA, constituye la justificación central del trabajo y lo que lo diferencia de los enfoques existentes.

1.2 Planteamiento del trabajo

La idea principal del trabajo puede resumirse de forma sencilla. Dada una proteína descrita únicamente por su secuencia de aminoácidos, se busca predecir qué pares de residuos están cerca en el espacio tridimensional —lo que se conoce como un mapa de contactos (Olmea y Valencia 1997)— y, a partir de ese mapa, reconstruir la estructura tridimensional completa de la proteína. El mapa de contactos actúa así como un paso intermedio entre la secuencia y la estructura final.

Para lograrlo, el trabajo propone una arquitectura híbrida clásico-cuántica que funciona en varias etapas. En primer lugar, se obtienen los embeddings ESM-2 de cada residuo de la proteína. A continuación, para cada par de residuos posible, se construye un vector de características que combina esos embeddings con información geométrica local de la cadena principal de la proteína. Ese vector se procesa mediante un circuito cuántico variacional con arquitectura jerárquica de tipo red tensorial, que actúa como extractor de características. Por último, las salidas del circuito cuántico se procesan con capas clásicas que predicen la distancia probable entre el par de residuos. Todo este proceso se describe en detalle en el Capítulo 4.

Para determinar qué aporta realmente cada componente se realiza un estudio de ablación controlado. Un estudio de ablación consiste en sustituir o desactivar partes del modelo de forma sistemática, midiendo el efecto de cada cambio con el resto del sistema inalterado. La ablación central de este trabajo compara el circuito cuántico con una capa clásica de capacidad equivalente que ocupa exactamente su lugar en la arquitectura, lo que permite atribuir cualquier diferencia de rendimiento al componente cuántico y no a otros factores. A esta comparación se añade una referencia externa imprescindible: la predicción de contactos que el propio modelo de lenguaje ESM-2 genera de forma nativa, que permite separar lo que aporta la arquitectura propuesta de lo que ya proporcionan las representaciones preentrenadas.

Toda la investigación se articula en torno a una pregunta central que da sentido al conjunto del trabajo y orienta las decisiones de diseño experimental. Dicha pregunta puede formularse de la siguiente manera: *¿aporta un circuito cuántico variacional una ventaja medible sobre un componente clásico de capacidad equivalente, dentro de un sistema de predicción de contactos entre residuos basado en modelos de lenguaje proteico y sin acceso a alineamientos de secuencias múltiples?* Esta formulación tiene dos virtudes que conviene destacar. La primera es que resulta comprobable de forma directa: basta con construir el sistema de modo que el componente cuántico sea intercambiable por su equivalente clásico y medir ambas variantes en idénticas condiciones. La segunda es que admite una respuesta informativa en ambos sentidos, pues tanto la confirmación como el descarte de la ventaja constituyen resultados válidos y de interés para el campo. El resto de la memoria se dedica a responderla de forma rigurosa, construyendo el sistema completo, evaluándolo con el protocolo estándar del experimento CASP y analizando la contribución de cada componente.

1.3 Principales aportaciones

Antes de describir la organización del documento, conviene resumir las aportaciones principales de este trabajo, de modo que el lector tenga claro desde el inicio qué se ha conseguido y qué lo distingue de trabajos previos. Estas aportaciones se desarrollan y justifican en detalle a lo largo de los capítulos siguientes.

La primera aportación es el diseño y la implementación de una arquitectura híbrida que combina los embeddings de un modelo de lenguaje proteico con circuitos cuánticos jerárquicos de tipo red tensorial para la predicción de contactos entre residuos, una combinación que no se ha encontrado documentada en la literatura previa.

La segunda aportación, y la más relevante desde el punto de vista metodológico, es el diseño de un experimento controlado capaz de aislar la contribución del componente cuántico. La arquitectura se construyó de modo que la ruta cuántica fuese intercambiable por una capa clásica de capacidad equivalente sin alterar ningún otro elemento del sistema, lo que permite atribuir las diferencias de rendimiento observadas a esa única variable. El experimento se replicó de forma independiente para verificar la estabilidad del resultado.

La tercera aportación es la incorporación de una referencia externa explícita —la predicción de contactos nativa de ESM-2— que permite cuantificar qué parte del rendimien-

to procede de las representaciones preentrenadas y qué parte aporta la arquitectura propuesta. Sin esta referencia, resulta imposible interpretar correctamente las cifras de un sistema construido sobre un modelo de lenguaje.

La cuarta aportación es de carácter técnico: la reimplementación del circuito cuántico para procesar lotes completos de datos, que redujo el tiempo de entrenamiento de forma drástica y permitió escalar el conjunto de entrenamiento en más de un orden de magnitud.

La quinta aportación es la evaluación del sistema siguiendo el protocolo del experimento CASP —con rangos exclusivos de separación de secuencia y el conjunto completo de métricas estándar— y su contextualización frente a la progresión histórica de la competición, lo que proporciona una referencia cuantificada y homogénea del nivel alcanzado por un enfoque cuántico simulado sin alineamientos de secuencias múltiples.

1.4 Estructura del trabajo

El resto de este documento se organiza de la siguiente manera. El Capítulo 2 presenta el contexto y el estado del arte, explicando con más detalle el problema del plegamiento de proteínas, el funcionamiento del experimento CASP, los modelos de lenguaje proteico y los fundamentos de las redes neuronales cuánticas híbridas. El Capítulo 3 establece los objetivos concretos del trabajo, tanto el objetivo general como los objetivos específicos. El Capítulo 4 describe todo el desarrollo técnico: desde el procesamiento de los datos hasta la construcción y el entrenamiento del modelo, pasando por la formulación matemática de cada componente. El Capítulo 5 presenta y discute los resultados obtenidos, comparándolos con el estado del arte. El Capítulo 6 recoge las conclusiones del trabajo y, finalmente, el Capítulo 7 propone líneas de trabajo futuro.

2. Contexto y estado del arte

Para entender bien qué propone este trabajo y por qué tiene sentido, conviene conocer primero el terreno en el que se mueve. Este capítulo explica de forma progresiva cuatro grandes bloques de conocimiento: qué es la predicción de estructura proteica y cómo se ha intentado resolver a lo largo del tiempo, cómo se evalúa el progreso del campo, qué tienen de especial los modelos de lenguaje proteico y, finalmente, qué aporta la computación cuántica a este problema. El objetivo es que el lector disponga de todos los conceptos necesarios para seguir el desarrollo técnico del Capítulo 4 sin tener que recurrir a fuentes externas. El capítulo se divide en dos secciones principales: los antecedentes históricos del problema y el estado actual de las técnicas relevantes.

2.1 Antecedentes históricos

Esta sección recorre la historia del problema de predicción de estructura proteica, desde su formulación inicial hasta la llegada del aprendizaje profundo. Se explica primero en qué consiste exactamente el problema, después cómo han evolucionado los métodos para resolverlo a lo largo de varias generaciones, y por último cómo se ha medido objetivamente el progreso del campo mediante el experimento CASP. Comprender esta evolución es importante porque sitúa la propuesta de este trabajo dentro de una larga tradición de intentos y permite valorar en su justa medida los resultados obtenidos.

2.1.1 De las secuencias a las estructuras: el problema central

Una proteína es, en esencia, una cadena de aminoácidos (Nelson y Cox 2005). Existen 20 tipos diferentes de aminoácidos, y la secuencia en que se encadenan —que puede tener desde decenas hasta miles de elementos— determina completamente cómo esa proteína se dobla en el espacio tridimensional. Ese proceso de plegamiento ocurre de forma espontánea, en milisegundos, dentro de la célula, y el resultado es casi siempre la misma forma final, conocida como estructura nativa (Anfinsen 1973). La estructura nativa es la que permite a la proteína realizar su función biológica.

Lo que hace especialmente interesante a este problema desde el punto de vista computacional es la paradoja de Levinthal (Levinthal 1969). Si una proteína de tamaño modesto tiene, por ejemplo, 100 aminoácidos, y cada uno puede adoptar varios estados de rotación,

el número total de configuraciones posibles es astronómico, del orden de 10^{300}. Explorarlas todas a razón de una por picosegundo tardaría más que la edad del universo. Y sin embargo, la proteína encuentra su estructura correcta en milisegundos. Esto significa que el plegamiento no es una búsqueda al azar: la secuencia de aminoácidos contiene toda la información necesaria para guiar el proceso, y descifrar esa información es precisamente el reto central de la biología computacional (Dill y MacCallum 2012).

Conocer la estructura de una proteína tiene aplicaciones directas y de gran alcance. La mayoría de los fármacos funcionan porque su molécula encaja en una proteína concreta del cuerpo o de un patógeno (Blundell et al. 2002). Si se puede predecir la forma de esa proteína, se pueden diseñar mejores fármacos sin necesidad de realizar miles de experimentos físicos. Además, la predicción de estructura es crucial para entender enfermedades como el Alzheimer o el Parkinson, que están relacionadas con proteínas que se pliegan de forma incorrecta y acaban formando agregados tóxicos (Dobson 2003).

Experimentalmente, las estructuras proteicas se determinan mediante técnicas como la cristalografía de rayos X (Berman et al. 2000), la resonancia magnética nuclear o la criomicroscopía electrónica (Cheng 2015). Estas técnicas son caras, lentas y no funcionan para todos los tipos de proteínas. El resultado de décadas de trabajo experimental es la base de datos Protein Data Bank (PDB) (Berman et al. 2000), que hoy contiene alrededor de 220.000 estructuras determinadas. Al mismo tiempo, la base de datos UniProt (UniProt Consortium 2023) almacena más de 250 millones de secuencias conocidas. La enorme brecha entre ambas cifras —cientos de miles de estructuras frente a cientos de millones de secuencias— es exactamente lo que motiva toda la investigación en predicción computacional de estructura.

2.1.2 Los cuatro niveles de la estructura proteica

Para entender qué significa exactamente predecir la estructura de una proteína, conviene saber que los biólogos describen la organización de una proteína en cuatro niveles jerárquicos. Comprender estos niveles es importante porque el presente trabajo se centra en uno de ellos en concreto, y porque la terminología aparecerá de forma recurrente a lo largo de la memoria.

El primer nivel es la **estructura primaria**, que es simplemente la secuencia lineal de aminoácidos, es decir, el orden en que estos se encadenan uno tras otro. Es la información más básica y la que se conoce directamente a partir del gen que codifica la proteína. El

segundo nivel es la **estructura secundaria**, que describe cómo se pliegan localmente pequeños tramos de la cadena en patrones regulares y repetitivos. Los dos patrones más comunes son la hélice alfa, en la que la cadena se enrolla en espiral, y la lámina beta, en la que varios tramos de la cadena se alinean en paralelo formando una superficie plegada. El tercer nivel es la **estructura terciaria**, que es la forma tridimensional completa de la cadena, resultado de cómo se disponen en el espacio todos los elementos de estructura secundaria. Este es el nivel que predice el sistema desarrollado en este trabajo. Por último, el cuarto nivel es la **estructura cuaternaria**, que describe cómo se ensamblan varias cadenas proteicas distintas para formar un complejo funcional. La Figura 2.1 ilustra estos cuatro niveles de organización.

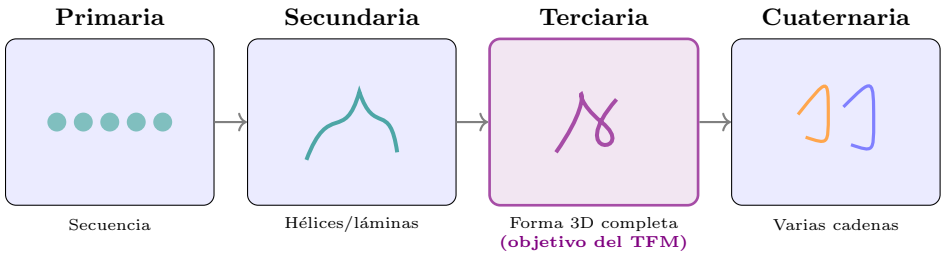


Figura 2.1: Los cuatro niveles de organización de la estructura de una proteína.

Nota. Elaboración propia a partir de Nelson y Cox (2005).

En el contexto de este trabajo, el objetivo es predecir la estructura terciaria a partir de la estructura primaria, que es precisamente el salto más difícil y valioso. Para ello, en lugar de predecir directamente las coordenadas tridimensionales de todos los átomos, se sigue una estrategia intermedia muy extendida en el campo: predecir primero qué pares de aminoácidos están próximos entre sí, y a partir de esa información reconstruir la forma tridimensional completa.

2.1.3 Evolución de los métodos de predicción: de la homología al aprendizaje profundo

Los métodos de predicción de estructura proteica han evolucionado a lo largo de varias décadas y pueden agruparse en tres grandes generaciones, cada una basada en una idea fundamental distinta. La Figura 2.2 resume esta evolución y la precisión aproximada alcanzada por cada generación.

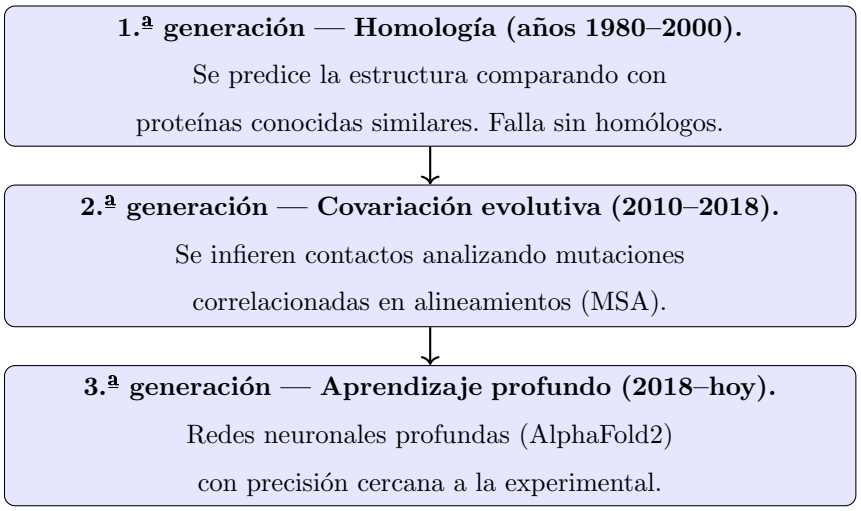


Figura 2.2: Las tres generaciones de métodos de predicción de estructura proteica.

Nota. Elaboración propia a partir de Chothia y Lesk (1986), Marks et al. (2011) y Jumper et al. (2021).

La primera generación son los métodos basados en homología (Chothia y Lesk 1986). La idea es sencilla: si la proteína que se quiere estudiar tiene una secuencia similar a otra cuya estructura ya se conoce, se puede asumir que ambas tendrán estructuras parecidas. Esta estrategia funciona muy bien cuando existe un buen homólogo conocido, pero falla por completo para proteínas sin parientes estructurales. Estas proteínas se denominan de *free modeling* y son precisamente las más difíciles e interesantes de predecir.

La segunda generación son los métodos basados en covariación evolutiva (Marks et al. 2011). La idea aquí es más sofisticada: a lo largo de la evolución, las mutaciones en los aminoácidos de una proteína no ocurren de forma aleatoria. Si dos posiciones de la cadena están en contacto en el espacio, cuando una de ellas muta, la otra tiende a mutar también para mantener la compatibilidad estructural. Analizando cientos o miles de secuencias homólogas mediante alineamientos múltiples (Edgar 2004), es posible inferir qué pares de posiciones están en contacto. Esta técnica supuso un avance importante, pero su eficacia depende críticamente de disponer de muchas secuencias homólogas (Monastyrskyy et al. 2016).

La tercera generación son los métodos basados en aprendizaje profundo (Goodfellow et al. 2016). A partir del experimento CASP12, celebrado en 2016, las redes neuronales profundas empezaron a dominar el campo. El punto de inflexión llegó con AlphaFold2 (Jumper et al. 2021) en CASP14, en 2020, que resolvió el problema del plegamiento con

una precisión comparable a la experimental para la mayoría de las proteínas. AlphaFold2 combina una arquitectura Transformer (Vaswani et al. 2017) con módulos especializados de atención sobre la información evolutiva y sobre las coordenadas atómicas, utilizando el MSA como entrada principal. Su publicación fue celebrada como uno de los mayores avances científicos de los últimos años (Callaway 2020).

Tras AlphaFold2, otros sistemas como RoseTTAFold (Baek et al. 2021) o ESMFold (Lin et al. 2023) continuaron el progreso. ESMFold es especialmente relevante para este trabajo porque prescinde del MSA, usando en su lugar un modelo de lenguaje proteico como representación de la secuencia. Este enfoque, que reemplaza la información evolutiva explícita del MSA por la información implícita aprendida por un modelo de lenguaje, es justamente el que inspira la propuesta de esta memoria.

2.1.4 El experimento CASP: el termómetro del campo

Para evaluar de forma objetiva el progreso en predicción de estructura, desde 1994 se celebra cada dos años el experimento CASP (Critical Assessment of Protein Structure Prediction) (Moult et al. 1995). Su funcionamiento garantiza una evaluación imparcial: varios laboratorios experimentales determinan estructuras de proteínas pero no las publican de inmediato; los grupos participantes en CASP reciben únicamente las secuencias y realizan sus predicciones; finalmente, cuando se publican las estructuras reales, estas se comparan con las predicciones de forma ciega. Este protocolo evita que los participantes puedan ajustar sus métodos a las respuestas conocidas, lo que convierte a CASP en la referencia más fiable del campo.

Las métricas principales de evaluación incluyen varias medidas complementarias. La Contact Precision @L/5 (Monastyrskyy et al. 2016) mide qué fracción de los $L/5$ contactos predichos con mayor confianza —siendo L la longitud de la proteína— son contactos reales. El GDT_TS (Global Distance Test) mide la fracción de residuos correctamente posicionados bajo varios umbrales de distancia (Zemla 2003). El TM-score evalúa la similitud topológica global con independencia de la longitud de la proteína (Zhang y Skolnick 2004). Por último, el lDDT (Local Distance Difference Test) mide la conservación de las distancias locales entre residuos vecinos (Mariani et al. 2013). Todas estas métricas se definen formalmente en el Capítulo 4, ya que son las mismas que se utilizan para evaluar el modelo propuesto.

La evolución de los resultados a lo largo de las distintas ediciones de CASP es muy reveladora. La Contact Precision @L/5 del mejor grupo participante fue de aproximadamente un 26,7% en CASP11 (Monastyrskyy et al. 2016), un 47,1% en CASP12 (Schaarschmidt et al. 2018), un 71,6% en CASP13 (Shrestha et al. 2019) y más del 80% gracias a AlphaFold2 en CASP14 (Kryshtafovych et al. 2021). Esta progresión ilustra a la perfección cómo el aprendizaje profundo ha transformado el campo en muy pocos años, y proporciona los valores de referencia con los que se compararán los resultados de este trabajo.

2.1.5 Mapas de contactos y mapas de distancias

Uno de los conceptos centrales de este trabajo es el de mapa de contactos, junto con su versión más detallada, el mapa de distancias. Como toda la metodología gira en torno a predecir estos mapas, conviene explicarlos con detalle antes de continuar.

Un **mapa de distancias** es una tabla cuadrada que recoge, para cada par de aminoácidos de una proteína, la distancia que los separa en el espacio tridimensional. Si la proteína tiene L aminoácidos, el mapa es una matriz de tamaño $L \times L$ en la que la celda situada en la fila i y la columna j contiene la distancia entre el aminoácido i y el aminoácido j. Como la distancia entre dos puntos es la misma en ambos sentidos, esta matriz es simétrica, y su diagonal principal vale siempre cero, ya que la distancia de un aminoácido consigo mismo es nula. La distancia se mide habitualmente entre los átomos de carbono alfa ($C\alpha$) de cada aminoácido, que es el átomo central de cada uno y que sirve como punto de referencia de su posición.

Un **mapa de contactos** es una versión simplificada del mapa de distancias. En lugar de guardar la distancia exacta, solo indica si dos aminoácidos están o no en contacto, entendiendo por contacto que su distancia sea inferior a un umbral determinado, habitualmente 8 Å (ångströms). Así, el mapa de contactos es una matriz de ceros y unos: vale 1 si los dos aminoácidos están en contacto y 0 en caso contrario. La Figura 2.3 ilustra la relación entre la estructura tridimensional de una proteína, su mapa de distancias y su mapa de contactos.

La razón por la que estos mapas son tan útiles es que actúan como un puente entre la secuencia y la estructura tridimensional. Predecir directamente las coordenadas tridimensionales de cada átomo es muy difícil, porque hay que acertar simultáneamente con la posición de todos ellos en un espacio continuo. En cambio, predecir si dos aminoácidos están en contacto es un problema más sencillo y acotado. Una vez se dispone del ma-

pa de distancias, existen técnicas matemáticas que permiten reconstruir las coordenadas tridimensionales a partir de él, como se explicará en el Capítulo 4. Por este motivo, la predicción de contactos ha sido durante años el paso intermedio fundamental en la predicción de estructura proteica.

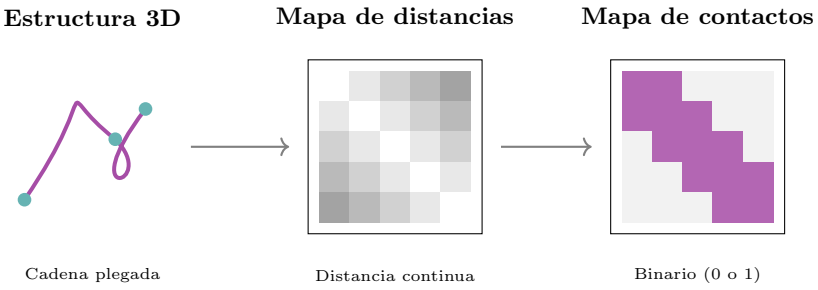


Figura 2.3: Relación entre la estructura tridimensional, el mapa de distancias y el mapa de contactos de una proteína.

Nota. Elaboración propia.

2.2 Estado actual

Esta sección describe las técnicas concretas sobre las que se construye el trabajo. Se explican primero los modelos de lenguaje proteico, que proporcionan la representación de entrada del sistema; después los fundamentos de computación cuántica necesarios para entender el componente cuántico del modelo; a continuación las redes neuronales cuánticas híbridas y los distintos tipos de circuito que existen; y finalmente el concepto de ventaja cuántica, el estado de las aplicaciones cuánticas en bioinformática y el conjunto de datos utilizado. Estas subsecciones cubren todo el conocimiento técnico que se aplicará en los capítulos posteriores.

2.2.1 Modelos de lenguaje proteico: aprender sin etiquetas

Una de las ideas más poderosas surgidas en los últimos años en bioinformática es que las secuencias proteicas pueden tratarse como un lenguaje. Los modelos de lenguaje (Vaswani et al. 2017) entrenados sobre millones de secuencias aprenden de manera implícita la gramática de ese lenguaje, es decir, las reglas que determinan qué aminoácidos pueden

combinarse y en qué configuraciones. Esta analogía entre lenguaje natural y secuencias biológicas ha resultado sorprendentemente fructífera.

El proceso de entrenamiento de estos modelos es autosupervisado (Devlin et al. 2019), lo que significa que no requiere etiquetas creadas por humanos. El procedimiento consiste en tomar secuencias proteicas reales, ocultar algunos aminoácidos al azar y pedir al modelo que prediga cuáles son a partir del contexto restante. Para hacerlo bien, el modelo necesita aprender qué aminoácidos son compatibles entre sí, qué patrones evolutivos existen y qué secuencias dan lugar a qué tipos de estructura, todo ello sin haber visto nunca directamente una estructura tridimensional.

La arquitectura que hace posible este aprendizaje es el **Transformer** (Vaswani et al. 2017), el mismo tipo de red neuronal que está detrás de los grandes modelos de lenguaje de texto actuales. La idea central del Transformer es un mecanismo llamado *atención*, que permite a cada elemento de la secuencia —en este caso, cada aminoácido— fijarse en todos los demás y ponderar cuáles son más relevantes para entender su propio contexto. En una proteína, esto significa que el modelo puede aprender que un aminoácido situado en una posición determinada está relacionado con otro que se encuentra muy lejos en la secuencia, lo cual es precisamente el tipo de información que resulta útil para predecir contactos. Esta capacidad de relacionar elementos distantes es lo que distingue al Transformer de arquitecturas anteriores y lo que lo hace tan adecuado para capturar la información evolutiva contenida en las secuencias proteicas.

El resultado de este entrenamiento son los embeddings: vectores numéricos densos que representan cada residuo en su contexto secuencial, capturando información evolutiva y estructural de forma compacta. Modelos como ESM-1v (Meier et al. 2021) o ESM-2 (Lin et al. 2023) han demostrado que estos embeddings son extraordinariamente informativos. De hecho, clasificadores lineales muy simples entrenados sobre estos embeddings pueden predecir la estructura secundaria, la accesibilidad al disolvente y otras propiedades estructurales con notable precisión, lo que confirma que la información estructural está realmente codificada en ellos.

El modelo ESM-2 t12_35M (Lin et al. 2023) es una versión ligera de la familia ESM-2, con 12 capas Transformer y 35 millones de parámetros, y genera un embedding de 480 dimensiones por residuo. Además de los embeddings, se extraen sus mapas de atención de par, que codifican relaciones directas entre residuos. A pesar de su tamaño modesto comparado con las versiones mayores de la familia, ha demostrado ser suficientemente in-

formativo para la tarea de predicción de contactos que se aborda en este trabajo, y su reducido tamaño lo hace especialmente adecuado para un entorno con recursos computacionales limitados.

2.2.2 Fundamentos de computación cuántica

La computación cuántica (Nielsen y Chuang 2000) es un paradigma de cómputo que aprovecha los fenómenos de la mecánica cuántica —la superposición, el entrelazamiento y la interferencia— para realizar cálculos que serían difíciles o imposibles para los ordenadores clásicos. Comprender estos tres fenómenos es esencial para entender por qué un circuito cuántico puede ser más expresivo que una red clásica del mismo tamaño.

En un ordenador clásico, la unidad básica de información es el bit, que puede tomar el valor 0 o 1. En un ordenador cuántico, la unidad básica es el qubit, que puede encontrarse en una superposición (Nielsen y Chuang 2000) de ambos valores simultáneamente. El estado de un qubit se describe matemáticamente mediante la ecuación

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle, \qquad |\alpha|^2 + |\beta|^2 = 1, \tag{2.1}$$

donde α y β son números complejos cuyos módulos al cuadrado representan las probabilidades de medir el qubit en el estado $|0\rangle$ o $|1\rangle$ respectivamente. La consecuencia más importante de la superposición es que un sistema de n qubits puede representar simultáneamente 2^n estados, lo que confiere una capacidad expresiva que crece exponencialmente con el número de qubits.

El entrelazamiento cuántico (Nielsen y Chuang 2000) es la segunda propiedad fundamental. Dos qubits entrelazados no pueden describirse de forma independiente el uno del otro, ni siquiera cuando están físicamente separados. Esto permite que el estado de un qubit influya de manera instantánea en el estado de otro, creando correlaciones que no tienen ningún equivalente en la física clásica. El entrelazamiento es precisamente lo que permite a un circuito cuántico capturar dependencias complejas entre las distintas componentes de los datos de entrada.

La interferencia cuántica (Nielsen y Chuang 2000) es la tercera propiedad. Consiste en la capacidad de los algoritmos cuánticos de amplificar las amplitudes de los estados correctos y cancelar las de los incorrectos, lo que hace posible encontrar soluciones de forma más eficiente que mediante una búsqueda clásica exhaustiva.

Para visualizar el estado de un qubit resulta muy útil la llamada **esfera de Bloch**, que se muestra en la Figura 2.4. Cualquier estado posible de un qubit puede representarse como un punto sobre la superficie de esta esfera. El polo norte corresponde al estado $|0\rangle$ y el polo sur al estado $|1\rangle$. Los puntos intermedios sobre la superficie representan las distintas superposiciones de ambos estados. De este modo, mientras que un bit clásico solo puede estar en uno de los dos polos, un qubit puede situarse en cualquier punto de la esfera, lo que ilustra gráficamente su mayor capacidad de representación.

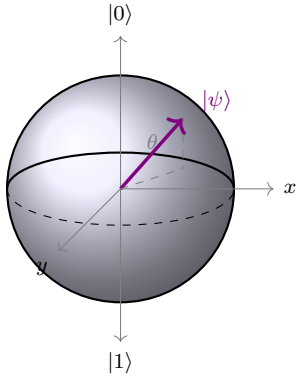


Figura 2.4: Representación del estado de un qubit en la esfera de Bloch. El vector $|\psi\rangle$ puede apuntar a cualquier punto de la superficie.

Nota. Elaboración propia a partir de Nielsen y Chuang (2000).

Las operaciones que se aplican sobre los qubits para realizar cálculos se denominan **puertas cuánticas**, y son el equivalente cuántico de las puertas lógicas clásicas. Geométricamente, una puerta cuántica sobre un solo qubit corresponde a una rotación del vector de estado sobre la esfera de Bloch. En este trabajo se emplean dos tipos de puertas de un qubit: la puerta R_Y, que rota el estado en torno al eje Y de la esfera, y la puerta R_Z, que lo rota en torno al eje Z. El ángulo de rotación de estas puertas es precisamente el parámetro que el modelo aprende durante el entrenamiento. Además, se utiliza una puerta fundamental de dos qubits llamada **CNOT** (NOT controlada), que invierte el estado de un qubit únicamente cuando otro qubit, llamado de control, se encuentra en el estado $|1\rangle$. La puerta CNOT es esencial porque es la que genera entrelazamiento entre qubits, y sin ella el circuito no podría capturar correlaciones entre las distintas componentes de los datos.

En la actualidad nos encontramos en la denominada era NISQ (Noisy Intermediate-Scale Quantum) (Preskill 2018), en la que los ordenadores cuánticos disponibles tienen entre decenas y cientos de qubits, pero son ruidosos y propensos a errores. En este contexto, los circuitos cuánticos variacionales (VQC) (Cerezo et al. 2021) se han convertido en el paradigma dominante. En lugar de ejecutar algoritmos cuánticos perfectos —que requerirían hardware tolerante a fallos todavía inexistente—, se parametrizan circuitos cuánticos relativamente cortos y se optimizan sus parámetros mediante un optimizador clásico, de forma muy similar a cómo se entrena una red neuronal convencional.

2.2.3 Redes neuronales cuánticas híbridas

Las redes neuronales cuánticas (Biamonte et al. 2017) son modelos que integran circuitos cuánticos parametrizados como capas dentro de una arquitectura de aprendizaje automático más amplia. En la configuración híbrida clásico-cuántica (Schuld y Petruccione 2021), las capas clásicas se encargan de transformar los datos de alta dimensión y de la optimización, mientras que el circuito cuántico actúa como extractor de características operando en el espacio de Hilbert. Esta división de tareas permite aprovechar lo mejor de ambos mundos: la robustez y madurez de las redes clásicas junto con la expresividad teórica del componente cuántico.

La ventaja teórica de las redes neuronales cuánticas es que pueden representar familias de funciones que resultarían exponencialmente costosas de representar con redes clásicas del mismo tamaño (Biamonte et al. 2017). Sin embargo, esta ventaja teórica no siempre se materializa en la práctica, especialmente con las arquitecturas y el hardware disponibles en la era NISQ, un matiz importante que se discutirá en los resultados de este trabajo.

Un obstáculo importante en el entrenamiento de redes neuronales cuánticas es el problema de los *barren plateaus* o mesetas estériles (McClean et al. 2018). A medida que el circuito se hace más profundo y tiene más qubits, los gradientes de la función de pérdida se vuelven exponencialmente pequeños en promedio, lo que hace que el entrenamiento sea prácticamente imposible. Este problema se agrava con el número de qubits y con una inicialización aleatoria de los parámetros, y constituye uno de los desafíos abiertos más importantes del campo. Estrategias como la inicialización con valores próximos a cero (Grant et al. 2019) o el diseño cuidadoso de la arquitectura del circuito ayudan a mitigarlo.

La técnica del re-uploading o recarga de datos (Pérez-Salinas et al. 2020) es otra idea clave en el diseño de circuitos cuánticos variacionales. En lugar de codificar los datos de

entrada en el circuito una sola vez, estos se vuelven a insertar en varios puntos del circuito. Esto aumenta la expresividad del modelo y permite que el circuito utilice la información de entrada a múltiples escalas, de forma análoga a cómo las capas intermedias de una red neuronal clásica profunda transforman progresivamente la representación de los datos.

2.2.4 Tipos de circuito cuántico: VQC, TTN y MERA

La elección del tipo de circuito cuántico, conocido técnicamente como *ansatz*, es una decisión de diseño fundamental en cualquier red neuronal cuántica. Durante el desarrollo de este trabajo se implementaron y ensayaron tres ansätze de complejidad creciente —un circuito genérico VQC, una red tensorial en árbol TTN y un MERA—, cuyas características estructurales y capacidad para capturar correlaciones difieren notablemente. El sistema final adopta el MERA, por las razones que se exponen a continuación. La Figura 2.5 ilustra la estructura de los tres.

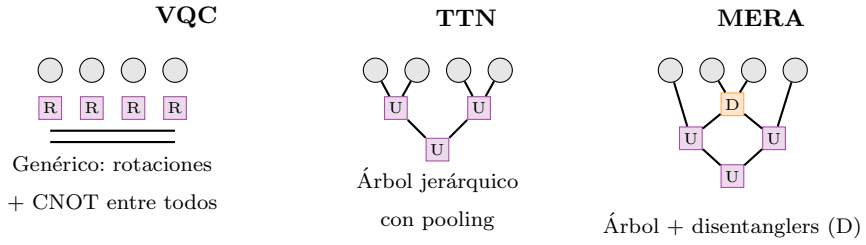


Figura 2.5: Comparación esquemática de los tres ansätze cuánticos. R: rotación; U: isometría (pooling); D: disentangler.

Nota. Elaboración propia a partir de Schuld y Petruccione (2021), Grant et al. (2018) y Vidal (2007).

El VQC genérico (Schuld y Petruccione 2021) es la versión más simple. Consiste en capas alternas de rotaciones individuales en cada qubit y puertas CNOT que crean entrelazamiento entre todos los pares. No tiene una estructura específica adaptada al problema y constituye el equivalente cuántico de una red neuronal completamente conectada. Su ventaja es la flexibilidad, mientras que su desventaja es que es propenso a los *barren plateaus* y no incorpora ningún sesgo inductivo útil para el problema concreto.

El TTN (Tree Tensor Network) (Grant et al. 2018) organiza las puertas en una estructura jerárquica en forma de árbol. En el primer nivel, las puertas actúan sobre pares de qubits vecinos; en el segundo nivel, sobre los qubits supervivientes del nivel anterior;

y así sucesivamente hasta llegar a un único qubit que se mide. Esta estructura captura correlaciones a múltiples escalas de forma natural, de manera análoga a una red neuronal convolucional con operaciones de pooling. Su ventaja para problemas con estructura jerárquica —como las proteínas, donde existen interacciones locales, de rango medio y de largo alcance— es que impone un sesgo inductivo muy adecuado.

El MERA (Multi-scale Entanglement Renormalization Ansatz) (Vidal 2007) es una extensión del TTN que añade puertas de *disentangling* entre los niveles del árbol. Estas puertas eliminan el entrelazamiento espurio que se acumula antes de cada operación de pooling, lo que permite al circuito capturar correlaciones de largo alcance de forma más eficiente. El MERA fue propuesto originalmente en el contexto de la física de la materia condensada como una forma de simular sistemas cuánticos con correlaciones de largo alcance. Su estructura resulta adecuada para problemas en los que las interacciones no son puramente locales, como ocurre en las proteínas, donde residuos muy distantes en la secuencia pueden encontrarse en contacto en la estructura tridimensional. El MERA es el ansatz adoptado en la arquitectura final de este trabajo, cuya aportación se evalúa en el Capítulo 5 mediante un estudio de ablación que lo contrasta con un componente clásico de capacidad equivalente.

2.2.5 El concepto de ventaja cuántica

Uno de los temas más debatidos en el campo de la computación cuántica es el de la ventaja cuántica (Preskill 2012), que consiste en demostrar que un algoritmo cuántico puede resolver un problema de forma más eficiente que cualquier algoritmo clásico posible. En el contexto de las redes neuronales cuánticas, esta ventaja es difícil de demostrar formalmente, pero existen caminos concretos que apuntan hacia ella y que conviene conocer para entender la motivación cuántica del trabajo.

El primer camino es la expresividad cuántica. Un circuito de n qubits opera en un espacio de Hilbert de dimensión 2^n, lo que significa que puede representar estados que requerirían una cantidad exponencial de parámetros clásicos para describirse. En el contexto de la predicción de contactos, esta propiedad permite capturar correlaciones entre residuos de una forma que no tiene un equivalente clásico directo y eficiente.

El segundo camino es la teoría de los kernels cuánticos (Havlíček et al. 2019; Schuld y Killoran 2019). En lugar de usar el circuito como una capa de transformación de características, se puede emplear para calcular la similitud entre dos estados cuánticos mediante

la fidelidad cuántica, definida como

$$k(x_i, x_j) = |\langle \phi(x_i) | \phi(x_j) \rangle|^2, \tag{2.2}$$

donde $|\phi(x)\rangle$ es el estado cuántico que codifica el dato x. Esta cantidad mide cómo de similares son dos estados cuánticos en el espacio de Hilbert y es genuinamente cuántica, ya que para estados de alta dimensión calcularla de forma clásica requeriría recursos exponenciales. En este trabajo se exploran tres niveles de aprovechamiento de propiedades cuánticas genuinas, que se describen en detalle en el Capítulo 4.

2.2.6 Aplicaciones de redes neuronales cuánticas a bioinformática

La aplicación de circuitos cuánticos a problemas de bioinformática y, en particular, de predicción de estructura proteica, es un campo emergente y en gran medida inexplorado. La mayor parte del trabajo existente se limita a problemas de demostración de pequeña escala (Fingerhuth et al. 2018) o a análisis teóricos sobre la ventaja cuántica potencial (Babbush et al. 2018), sin abordar todavía problemas reales de tamaño relevante.

En el ámbito concreto de la predicción de contactos, no se conoce ningún trabajo previo que combine embeddings de modelos de lenguaje proteico con circuitos cuánticos variacionales y los evalúe sobre el conjunto de referencia estándar CASP. Este trabajo se sitúa precisamente en esa brecha, explorando de forma sistemática y cuantitativa si los circuitos cuánticos pueden aportar valor real en este contexto, lo que constituye una de sus principales aportaciones.

2.2.7 El conjunto de datos ProteinNet

ProteinNet (AlQuraishi 2019) es el conjunto de datos estándar del campo para el desarrollo y la evaluación de modelos de predicción de estructura proteica. Su diseño cuidadoso, con particiones basadas en fechas de corte que garantizan la ausencia de fuga de información entre los conjuntos de entrenamiento y validación, lo hace especialmente adecuado para realizar comparaciones justas entre métodos. La versión CASP11 utilizada en este trabajo contiene proteínas cuyas estructuras se determinaron antes de la competición CASP11 de 2014, mientras que el conjunto de validación contiene las proteínas objetivo de esa misma competición. Este trabajo emplea para el entrenamiento el subconjunto `training_100` y reserva el conjunto de validación oficial de ProteinNet para la evaluación final, lo que

permite medir el rendimiento sobre proteínas que el modelo no ha visto durante el entrenamiento, como se detalla en el Capítulo 4.

ProteinNet ofrece el conjunto de entrenamiento en varios niveles de redundancia, denominados *thinnings*, correspondientes a distintos umbrales de identidad de secuencia máxima entre proteínas (30%, 50%, 70%, 90%, 95% y 100%). Estos subconjuntos están anidados: a mayor umbral se incluyen más proteínas, pero también aumenta la proporción de secuencias muy similares entre sí. El conjunto `training_30` contiene 22 344 proteínas y `training_100` asciende a 87 573.

La elección entre ellos se resolvió experimentalmente. Existían argumentos en ambas direcciones: un filtrado estricto maximiza la diversidad estructural por proteína y evita el sesgo hacia familias sobrerrepresentadas, mientras que la redundancia de secuencia podría en principio aportar información equivalente a la que los métodos basados en alineamientos extraen de la covariación entre homólogos. Se entrenaron por tanto dos configuraciones idénticas salvo en el subconjunto empleado. Las diferencias resultaron marginales y dentro de la variabilidad experimental, por lo que la redundancia de secuencia no aporta, en este sistema, la señal evolutiva que cabría esperar. La configuración final emplea `training_100` por disponer de un conjunto de partida mayor del que muestrear, si bien la elección no resulta determinante para los resultados.

3. Objetivos

Este trabajo tiene como propósito explorar, implementar y evaluar una arquitectura de red neuronal cuántica híbrida para la predicción de estructura tridimensional de proteínas, utilizando embeddings de lenguaje proteico ESM-2 como representación de secuencia única y circuitos cuánticos variacionales como componente central del modelo. El trabajo no pretende superar a métodos como AlphaFold2 en el rango donde estos son plenamente efectivos, sino explorar el potencial de los circuitos cuánticos como componente estructural en pipelines de predicción de estructura proteica y establecer una línea base cuantificada para evaluar el progreso futuro de estos enfoques.

Antes de enunciar los objetivos conviene aclarar la filosofía metodológica que los guía. El trabajo se plantea como un estudio exploratorio y sistemático, en el sentido de que no se limita a construir un único modelo y medir su rendimiento, sino que compara de forma controlada distintas variantes para entender qué aporta cada componente. Esta forma de proceder, conocida como estudio de ablación, es la que permite extraer conclusiones fiables sobre el valor real del componente cuántico, más allá del resultado concreto de una configuración particular. Los objetivos que se enumeran a continuación reflejan esta doble vocación: por un lado, construir un sistema completo y funcional; por otro, analizarlo de forma rigurosa para responder a la pregunta de investigación.

Los objetivos de este trabajo se han organizado en dos niveles. En primer lugar se formula un objetivo general que resume el propósito global de la investigación. A continuación se desglosa ese objetivo general en una serie de objetivos específicos, más concretos y verificables, que en conjunto permiten alcanzar el objetivo general y que sirven de guía para estructurar el desarrollo técnico de los capítulos siguientes.

3.1 Objetivos generales

El objetivo general de este trabajo es diseñar, implementar y evaluar una red neuronal híbrida clásico-cuántica para la predicción de mapas de contactos y distancias Cα–Cα en proteínas a partir de la secuencia, con reconstrucción posterior de la estructura tridimensional, y determinar mediante un experimento controlado si el componente cuántico aporta una ventaja medible sobre un equivalente clásico de capacidad similar, empleando para ello las métricas estándar del experimento CASP.

3.2 Objetivos específicos

A partir del objetivo general anterior se derivan siete objetivos específicos, que abarcan desde la preparación de los datos hasta la contextualización de los resultados. Estos objetivos definen las tareas concretas que se han llevado a cabo y que se documentan en los capítulos de desarrollo y resultados. Se enumeran a continuación:

1. **Implementar el pipeline de datos sobre ProteinNet CASP11.** Desarrollar el sistema de carga, parseo y preprocesamiento del dataset ProteinNet, incluyendo la extracción de embeddings ESM-2 por residuo, el cálculo de coordenadas Cα en ångströms, la construcción de pares de residuos con sus labels de distancia y orientación, y la implementación de un split por proteína que evite data leakage entre conjuntos de entrenamiento y validación.

2. **Diseñar la representación de los pares de residuos y evaluar la contribución de cada componente.** Construir una vectorización simétrica del par (i, j) que combine la suma y la diferencia absoluta de los embeddings de ambos residuos, la separación normalizada en secuencia y los mapas de atención por par extraídos de ESM-2. Cuantificar mediante ablación la aportación de estas últimas, que constituyen la señal más específica del modelo de lenguaje, activándolas y desactivándolas con el resto del sistema inalterado.

3. **Aislar la contribución del componente cuántico mediante un experimento controlado.** Diseñar la arquitectura de modo que la ruta cuántica sea intercambiable por una capa clásica de capacidad equivalente, entrenar ambas variantes en la misma ejecución con idénticos datos, semilla e hiperparámetros, y cuantificar la diferencia de rendimiento entre ellas. Replicar el experimento de forma independiente para verificar la estabilidad del resultado.

4. **Establecer referencias que permitan interpretar las cifras obtenidas.** Incorporar dos líneas base explícitas: la densidad de contactos de cada rango de separación, que corresponde al rendimiento de un predictor aleatorio, y la predicción de contactos que el modelo ESM-2 genera de forma nativa, que permite separar la contribución de la arquitectura propuesta de la de las representaciones preentrenadas. Analizar además el efecto del volumen y la redundancia de los datos de entrenamiento sobre el rendimiento alcanzado.

5. **Implementar el pipeline de reconstrucción 3D.** Desarrollar el sistema de reconstrucción de coordenadas Cα a partir del mapa de distancias predicho, incluyendo la reconstrucción mediante MDS (Multidimensional Scaling) métrico y el refinamiento geométrico en dos fases: una primera fase de estructura global con pares de largo alcance y una segunda fase de ajuste local del backbone.

6. **Evaluar el modelo siguiendo el protocolo del experimento CASP.** Implementar la evaluación de contactos con los rangos *exclusivos* de separación de secuencia que emplea CASP —corto (6–11), medio (12–23) y largo ($\geq$24)— sobre las listas reducidas @L, @L/2, @L/5 y @L/10, junto con el coeficiente de correlación de Matthews, la puntuación Xd y el área bajo la curva de precisión-recall. Calcular asimismo el conjunto completo de métricas estructurales: RMSE de distancias, RMSD con superposición de Kabsch, GDT_TS, GDT_HA, TM-score y lDDT.

7. **Contextualizar los resultados en el marco del experimento CASP.** Comparar las métricas obtenidas con los resultados reportados por los grupos participantes en CASP11, CASP12, CASP13 y CASP14, discutiendo las diferencias metodológicas relevantes —en particular la ausencia de MSA en el enfoque propuesto frente a su uso ubicuo en los métodos CASP— y estableciendo qué edición del experimento es la referencia más justa para la comparación.

4. Desarrollo del Trabajo

Este capítulo describe en detalle la implementación completa del sistema propuesto, desde el procesamiento de los datos hasta la construcción matemática del modelo y su entrenamiento. El objetivo es doble: por un lado, ser suficientemente explicativo para que cualquier lector entienda cada decisión de diseño y la justificación que hay detrás; por otro, ser suficientemente preciso para que el trabajo pueda reproducirse. La descripción sigue la estructura del notebook de desarrollo, organizado en 19 bloques numerados y agrupados en ocho partes conceptuales que van de la preparación del entorno a la visualización de las estructuras predichas. Cada bloque encapsula una responsabilidad concreta y puede ejecutarse de forma independiente, lo que facilita tanto la depuración como la experimentación iterativa con distintos hiperparámetros.

El capítulo se organiza en seis secciones. La primera ofrece una visión global de la arquitectura del sistema. Las cinco siguientes desarrollan las etapas en que se divide el trabajo: el preprocesamiento de los datos, la arquitectura del modelo híbrido, el proceso de entrenamiento, la evaluación con el protocolo CASP y el estudio de ablación que compara el componente cuántico con su equivalente clásico. La Figura 4.1 muestra esta organización general.

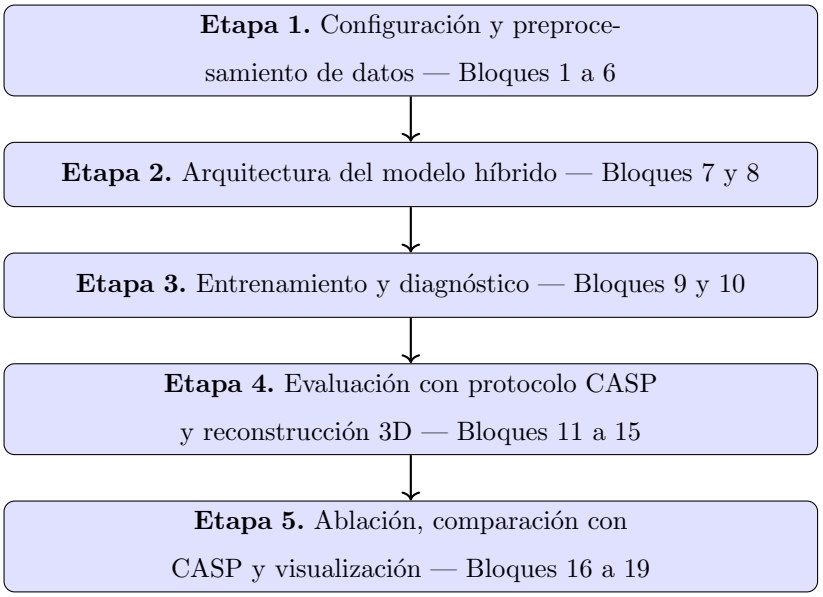


Figura 4.1: Organización general del sistema en cuatro etapas y trece bloques.

Nota. Elaboración propia.

4.1 Visión general del sistema

Antes de entrar en el detalle de cada etapa, conviene tener una visión de conjunto de cómo fluye la información a través del sistema. El sistema parte de una secuencia de aminoácidos y produce, como resultado final, una estructura tridimensional reconstruida junto con un conjunto de métricas que cuantifican su calidad. Entre medias, la información pasa por una serie de transformaciones que conviene entender en su conjunto antes de analizarlas individualmente.

El flujo completo puede resumirse así. En primer lugar, la secuencia de aminoácidos se convierte en una representación numérica mediante el modelo de lenguaje proteico ESM-2. A continuación, para cada par de residuos de la proteína, se construye un vector de características que combina esa representación con información geométrica local. Ese vector se proyecta a un número reducido de dimensiones y se introduce en el circuito cuántico TTN, que actúa como extractor de características. Las salidas del circuito se procesan mediante capas clásicas que predicen la distancia probable entre el par de residuos. Finalmente, el conjunto de todas las distancias predichas forma un mapa de distancias, a partir del cual se reconstruye la estructura tridimensional. La Figura 4.2 representa este flujo de datos de extremo a extremo.

4.2 Etapa 1: Preprocesamiento de datos (Bloques 1–6)

La primera etapa transforma las proteínas en bruto del conjunto de datos ProteinNet CASP11 (AlQuraishi 2019) en tensores numéricos listos para alimentar el modelo. Esta etapa es la más extensa del notebook en cuanto a líneas de código, porque concentra todas las decisiones de representación que determinan qué información ve el modelo y cómo la ve. Cada uno de los seis bloques que la componen cumple una función específica dentro de esta transformación, que se detalla en las subsecciones siguientes.

4.2.1 Bloque 1 — Importaciones y detección de hardware

El primer bloque configura el entorno de ejecución cargando todas las bibliotecas necesarias y detectando automáticamente el hardware disponible. Las dependencias principales son NumPy y Pandas para la manipulación de datos, Scikit-learn (Pedregosa et al. 2011) para el preprocesamiento y la evaluación, PennyLane (Bergholm et al. 2018) para los circuitos cuánticos y PyTorch para las capas clásicas del modelo híbrido. La elección de

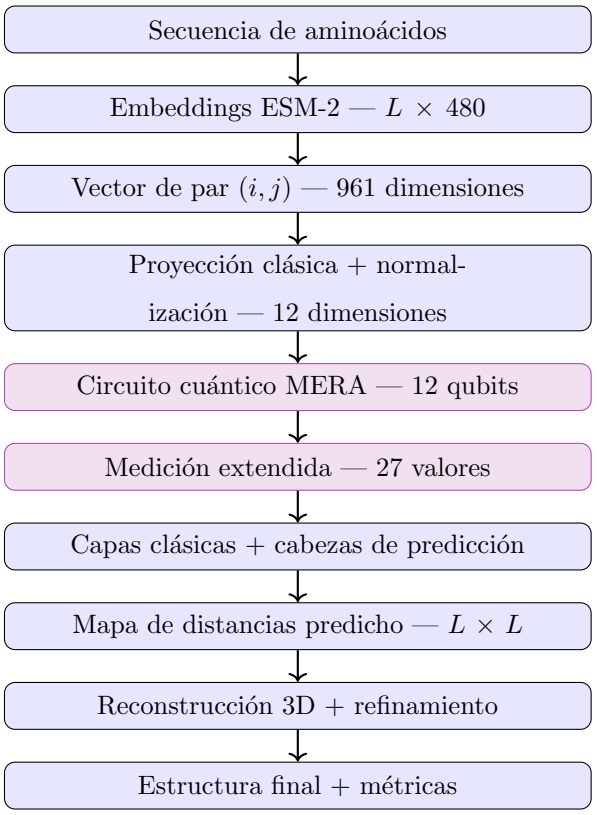


Figura 4.2: Flujo de datos de extremo a extremo del sistema propuesto. En violeta, el componente cuántico.

Nota. Elaboración propia.

estas bibliotecas responde a una división clara de responsabilidades: PyTorch se encarga de toda la parte de aprendizaje profundo clásico —las capas lineales, la normalización y la optimización basada en gradientes—, mientras que PennyLane aporta la capacidad de definir y simular circuitos cuánticos variacionales de forma diferenciable. Esta última propiedad es esencial, ya que permite que los gradientes fluyan a través del circuito cuántico durante el entrenamiento, integrándose de manera transparente con el resto de la red mediante el mecanismo de diferenciación automática de PyTorch.

El bloque determina si hay una tarjeta gráfica compatible con CUDA disponible y configura el dispositivo de cómputo en consecuencia, lo que permite ejecutar el notebook tanto en CPU como en GPU sin necesidad de modificar el código. Esta detección automática es una buena práctica de reproducibilidad, pues garantiza que el mismo código funcione en distintos entornos —desde un ordenador personal sin GPU hasta un servidor

con aceleración por hardware— sin intervención manual. En el entorno de desarrollo de este trabajo se utilizó una tarjeta NVIDIA GeForce RTX 5070 Ti con 16 GB de memoria, lo que aceleró notablemente las operaciones de las capas clásicas del modelo. Conviene matizar, no obstante, que la simulación del circuito cuántico con PennyLane se ejecuta principalmente en CPU y constituye el cuello de botella computacional del sistema, un aspecto que se analiza en detalle más adelante en este mismo capítulo.

4.2.2 Bloque 2 — Configuración global e hiperparámetros

El segundo bloque centraliza todos los hiperparámetros y constantes del sistema en un único punto de control. Esta decisión de diseño facilita enormemente la experimentación sistemática, ya que basta con modificar este bloque y volver a ejecutar el notebook para probar una nueva configuración sin tocar ningún otro bloque. Los hiperparámetros se dividen en dos grupos: los que controlan el entrenamiento y los que controlan el modelo.

Los parámetros de entrenamiento determinan el volumen de datos y la duración del proceso de optimización. Entre ellos se encuentran el número de proteínas de entrenamiento y validación, el número máximo de pares de residuos por bin de distancia, el tamaño del lote o *batch*, el número máximo de épocas y la paciencia del criterio de parada temprana. Los hiperparámetros del modelo, por su parte, incluyen la tasa de *dropout*, el coeficiente de regularización y las tasas de aprendizaje diferenciadas para las capas clásicas y para el circuito cuántico. Además, el bloque define las constantes fijas del sistema, como los límites de los bins de distancia, el umbral de contacto de 8 Å, la escala de las coordenadas de ProteinNet y la separación mínima en secuencia. La Tabla 4.1 resume los valores empleados en la configuración de referencia.

4.2.3 Bloque 3 — Carga del modelo ESM-2

El tercer bloque inicializa el modelo de lenguaje proteico ESM-2 t12_35M (Lin et al. 2023) y define la función que transforma una secuencia de aminoácidos en una matriz de embeddings. Para una proteína de longitud L, esta función devuelve una matriz de dimensiones $L \times 480$, en la que cada fila es el vector de 480 componentes que representa un residuo en su contexto. El modelo ESM-2 se carga en modo de inferencia y se transfiere al dispositivo de cómputo disponible, manteniendo sus pesos completamente fijos durante todo el entrenamiento del modelo propuesto. Es decir, ESM-2 actúa como un extractor de características preentrenado y no como un componente que se aprende.

Tabla 4.1: Hiperparámetros de la configuración de referencia.

Parámetro	**Valor**	**Descripción**
Proteínas de entrenamiento	12 000	80% de la muestra de `training_100`
Proteínas de monitorización	3 000	20% restante (parada temprana)
Proteínas de validación	224	Conjunto oficial de CASP11, no visto
Pares por bin	40 000	Máximo de pares por bin de distancia
Tamaño de batch	64	Muestras por lote
Épocas máximas	50	Límite superior de épocas
Paciencia (early stopping)	10	Épocas sin mejora antes de parar
Dropout	0,5	Fracción de neuronas desactivadas
Weight decay	10^{-3}	Regularización L_2
Learning rate clásico	3×10^{-3}	Tasa de aprendizaje clásica
Learning rate cuántico	5×10^{-4}	Tasa de aprendizaje del circuito
Separación mínima	6	Residuos mínimos entre pares

Nota. Elaboración propia.

Conviene detenerse en el concepto de **embedding**, ya que es la representación de entrada de todo el sistema. Un embedding es una forma de convertir un objeto que no es numérico —en este caso, un aminoácido dentro de su contexto— en un vector de números que una máquina puede procesar. La idea clave es que este vector no es arbitrario, sino que se construye de manera que objetos parecidos tengan vectores parecidos. Una analogía útil es la de los mapas: del mismo modo que en un mapa dos ciudades cercanas aparecen en posiciones próximas, en el espacio de los embeddings dos aminoácidos que desempeñan papeles estructurales similares aparecen representados por vectores próximos entre sí. La Figura 4.3 ilustra esta idea de forma esquemática.

Internamente, la función realiza tres pasos. Primero convierte la secuencia de texto en una representación de tokens que el modelo puede procesar. Después pasa esos tokens por las seis capas Transformer del modelo y extrae las representaciones de la última capa. Por último, elimina los dos tokens especiales que ESM-2 añade automáticamente al principio y al final de cada secuencia, devolviendo únicamente los vectores correspondientes a los residuos reales. Conviene destacar que esta función se invoca una sola vez por proteína

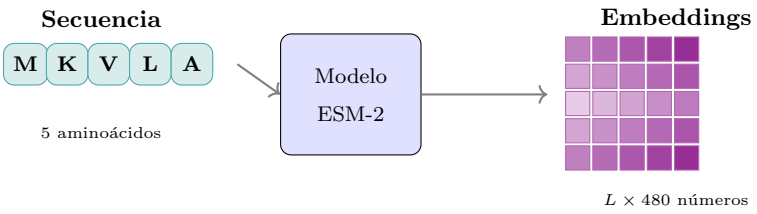


Figura 4.3: El modelo ESM-2 transforma cada aminoácido de la secuencia en un vector numérico (embedding) que captura su contexto.

Nota. Elaboración propia.

durante la carga de los datos, de modo que los embeddings se calculan una única vez y se almacenan, evitando el coste de recalcularlos en cada época de entrenamiento.

4.2.4 Bloque 4 — Carga y parseo de ProteinNet

El cuarto bloque se encarga de leer el conjunto de datos ProteinNet CASP11 desde el disco y de transformarlo en una estructura tabular manejable. La función de carga interpreta el formato de texto propio de ProteinNet y devuelve una tabla en la que cada fila representa una proteína con todos los campos necesarios para el resto del procesamiento. La elección de ProteinNet como fuente de datos no es casual: se trata de un conjunto estandarizado y ampliamente utilizado en la comunidad, que replica de forma rigurosa las divisiones de entrenamiento y validación del experimento CASP, lo que facilita la comparación de resultados con otros trabajos y evita la contaminación entre los conjuntos de entrenamiento y evaluación.

El formato de ProteinNet organiza cada proteína en bloques etiquetados. El bloque de identificador contiene el nombre único de la proteína. El bloque de secuencia primaria contiene la cadena de aminoácidos. El bloque de máscara indica, mediante una secuencia de símbolos, qué posiciones tienen coordenadas experimentales válidas y cuáles no, ya que algunos residuos pueden no haberse resuelto en el experimento. Esta máscara es importante porque las técnicas experimentales de determinación de estructuras, como la cristalografía de rayos X, a menudo no consiguen resolver ciertas regiones flexibles o desordenadas de la proteína; ignorar esas posiciones es imprescindible para no introducir coordenadas erróneas o inexistentes en el entrenamiento. El bloque de estructura terciaria contiene las coorde-

nadas atómicas tridimensionales expresadas en unidades de 10^{-2} Å, una convención de escala propia del formato que debe deshacerse para trabajar en ångströms.

El proceso de parseo extrae las coordenadas del átomo Cα de cada residuo, aplica la máscara para eliminar las posiciones sin coordenadas, y escala las coordenadas a ångströms dividiéndolas por 100. Se emplea el carbono alfa como representante de cada residuo porque es el átomo central del esqueleto de la cadena principal y su posición resume adecuadamente la ubicación del residuo, lo que constituye una simplificación estándar en la predicción de estructura a nivel de esqueleto. A continuación, el proceso alinea los embeddings ESM-2 con las coordenadas aplicando la misma máscara, de forma que cada residuo válido queda asociado tanto a su vector de características como a su posición tridimensional. Esta correspondencia uno a uno entre características y coordenadas es la base sobre la que se construirán después los ejemplos de entrenamiento por pares de residuos.

4.2.5 Bloque 5 — Utilidades geométricas y extracción de pares

El quinto bloque define las funciones que calculan las características geométricas locales de la cadena principal de la proteína y que construyen el conjunto de pares de residuos. Estas características geométricas complementan la información de los embeddings ESM-2 con datos sobre la forma local del esqueleto proteico, que los embeddings de secuencia no capturan de forma explícita.

Se calculan dos características geométricas para cada residuo. La primera es el vector tangente, que indica la dirección local de la cadena en cada punto. Para el residuo i, el vector tangente se define como la dirección normalizada del vector que une el residuo anterior con el siguiente:

$$\mathbf{t}_i = \frac{\mathbf{r}_{i+1} - \mathbf{r}_{i-1}}{\|\mathbf{r}_{i+1} - \mathbf{r}_{i-1}\|}, \tag{4.1}$$

donde $\mathbf{r}_i$ representa las coordenadas del átomo Cα del residuo i, con un tratamiento especial en los extremos de la cadena. La segunda característica es la curvatura local, que mide cuánto cambia la dirección de la cadena en cada punto:

$$\kappa_i = \left\| \frac{\mathbf{r}_{i+1} - \mathbf{r}_i}{\|\mathbf{r}_{i+1} - \mathbf{r}_i\|} - \frac{\mathbf{r}_i - \mathbf{r}_{i-1}}{\|\mathbf{r}_i - \mathbf{r}_{i-1}\|} \right\|. \tag{4.2}$$

Una curvatura alta indica un giro o un lazo, mientras que una curvatura baja indica una región extendida, como una hélice o una lámina. A partir de los vectores tangentes de dos residuos se calcula además su producto escalar, $\tau_{ij} = \mathbf{t}_i \cdot \mathbf{t}_j$, que mide si ambos residuos están orientados de forma similar; este valor tiende a ser cercano a 1 en hélices y más

variable en láminas y lazos. La función principal del bloque recorre todos los pares de residuos (i, j) que cumplen la condición de separación mínima en secuencia $|i - j| \geq 6$ y calcula, para cada uno, su etiqueta de distancia y de orientación.

4.2.6 Bloque 6 — Conjunto de datos, balanceo y cargadores

El sexto bloque construye los conjuntos de entrenamiento y validación a partir de las proteínas cargadas y prepara los cargadores de datos de PyTorch que alimentarán el entrenamiento por lotes. Este bloque integra varias operaciones importantes que merecen explicarse por separado.

La representación de cada par de residuos se construye mediante una vectorización de 961 dimensiones. Esta se obtiene concatenando los embeddings de los dos residuos junto con la separación normalizada entre ellos en la secuencia y las características de atención de par extraídas de ESM-2. El vector resultante se define como

$$\mathbf{x}_{ij} = \left[\mathbf{e}_i \parallel \mathbf{e}_j \parallel \frac{|i-j|}{L} \right], \tag{4.3}$$

donde $\mathbf{e}_i, \mathbf{e}_j \in \mathbb{R}^{480}$ son los embeddings de los dos residuos, el símbolo $\parallel$ denota concatenación. Los embeddings de ambos residuos ocupan 960 dimensiones y la dimensión restante recoge la separación normalizada en secuencia, sumando un total de 961. Conviene señalar que las características geométricas de la cadena descritas en el bloque anterior —los vectores tangentes y las curvaturas— no se utilizan como entrada del modelo, sino únicamente para construir las etiquetas de orientación que el modelo aprende a predecir. De este modo, la entrada del modelo depende exclusivamente de la información de secuencia proporcionada por ESM-2, sin incorporar información derivada de las coordenadas tridimensionales reales.

El bloque aplica además un balanceo por bins. La distribución natural de distancias entre residuos no es uniforme: existen muchos más pares a distancias largas que a distancias cortas. Si se entrenara con esta distribución desequilibrada, el modelo aprendería a predecir siempre distancias largas. Para evitarlo, se muestrea aleatoriamente un número máximo de pares por cada bin de distancia, de modo que todos los bins queden igualmente representados. La Figura 4.4 ilustra el efecto de este balanceo sobre la distribución de los datos.

Conviene también explicar el concepto de **separación mínima en secuencia**, que aparece de forma recurrente. Al construir los pares de aminoácidos, se descartan aquellos

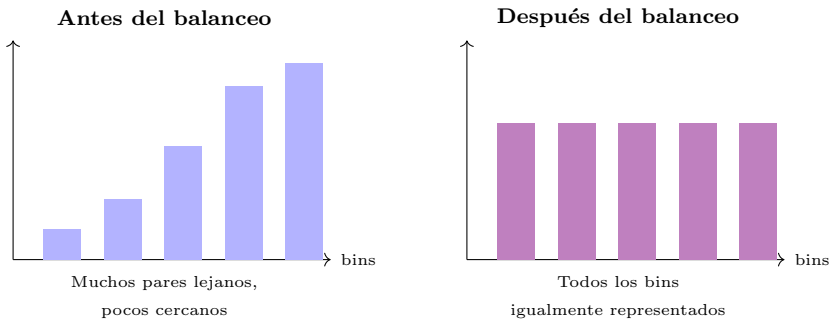


Figura 4.4: Efecto del balanceo por bins sobre la distribución de distancias del conjunto de entrenamiento.

Nota. Elaboración propia.

cuyas posiciones están demasiado próximas en la secuencia, concretamente los que distan menos de 6 posiciones. La razón es que los aminoácidos consecutivos o muy cercanos en la cadena están siempre próximos en el espacio por el simple hecho de estar encadenados, lo que constituye una información trivial que no aporta nada sobre el plegamiento. Los contactos realmente informativos son los que se producen entre aminoácidos alejados en la secuencia pero próximos en el espacio, ya que son estos los que definen cómo se pliega la proteína sobre sí misma. Por ello, filtrar los pares cercanos obliga al modelo a centrarse en la información estructuralmente relevante. Por último, conviene precisar la estrategia de validación empleada, que opera en dos niveles. Durante el entrenamiento, la muestra extraída de `training_100` se divide en dos partes mediante una partición aleatoria por proteína (aproximadamente un 80% para el ajuste de los pesos y un 20% para monitorizar la evolución del entrenamiento y activar la parada temprana). Esta división se realiza a nivel de proteína completa para evitar la fuga de información (Russ et al. 2020): todos los pares de una misma proteína van siempre al mismo subconjunto. Las métricas finales que se reportan en el Capítulo 5, en cambio, se calculan sobre el conjunto de validación oficial de ProteinNet CASP11 —las proteínas objetivo de la competición—, que el modelo no ha utilizado en ninguna fase del entrenamiento. De este modo, las cifras de rendimiento reflejan la capacidad de generalización del modelo a proteínas genuinamente no vistas. El escalado de las características se ajusta exclusivamente sobre el conjunto de entrenamiento y se aplica después a los conjuntos de validación.

4.2.7 Resumen del formato de datos y del flujo de preprocesamiento

Para cerrar la descripción de esta primera etapa, resulta útil resumir de forma estructurada los distintos campos de información que componen cada proteína en el conjunto de datos ProteinNet, ya que el manejo correcto de estos campos es lo que determina la calidad de los datos que finalmente recibe el modelo. La Tabla 4.2 recoge estos campos junto con su descripción y su papel dentro del sistema.

Tabla 4.2: Campos de información de cada proteína en el conjunto de datos ProteinNet.

Campo	**Descripción y uso en el sistema**
Identificador	Nombre único de la proteína; sirve para rastrear cada muestra.
Secuencia primaria	Cadena de aminoácidos; entrada del modelo de lenguaje ESM-2.
Estructura terciaria	Coordenadas tridimensionales de los átomos; se usan para calcular las distancias reales que sirven de referencia.
Máscara de validez	Indica qué aminoácidos tienen coordenadas experimentales fiables; los demás se descartan.

Nota. Elaboración propia a partir de AlQuraishi (2019).

El flujo de preprocesamiento completo encadena de forma ordenada todas las operaciones descritas en los bloques anteriores. Partiendo del fichero de texto de ProteinNet, el sistema lee cada proteína y extrae sus cuatro campos. A continuación aplica la máscara de validez para quedarse únicamente con los aminoácidos fiables, calcula los embeddings de la secuencia con ESM-2 y obtiene las coordenadas tridimensionales reales. Con esa información construye todos los pares de aminoácidos que cumplen la separación mínima, calcula para cada par sus características y su etiqueta de distancia, aplica el balanceo por bins para equilibrar la distribución y, finalmente, normaliza las características. El resultado de todo este proceso es un conjunto de datos numérico, equilibrado y normalizado, listo para entrenar el modelo. Este encadenamiento ordenado de operaciones es lo que garantiza que el modelo reciba datos de calidad, lo cual es una condición indispensable para que pueda

aprender de forma efectiva, pues incluso el mejor modelo fracasaría si los datos de entrada estuvieran mal construidos.

4.3 Etapa 2: Arquitectura del modelo híbrido (Bloques 7–8)

La segunda etapa define el corazón del trabajo: el circuito cuántico TTN y el modelo híbrido completo que lo integra con las capas clásicas. Esta es la parte más relevante desde el punto de vista de la computación cuántica, ya que en ella se concentran todas las decisiones de arquitectura que determinan cómo se combina el componente clásico con el cuántico. La Figura 4.5 muestra el diagrama de bloques completo del modelo, indicando para cada componente sus dimensiones de entrada y salida.

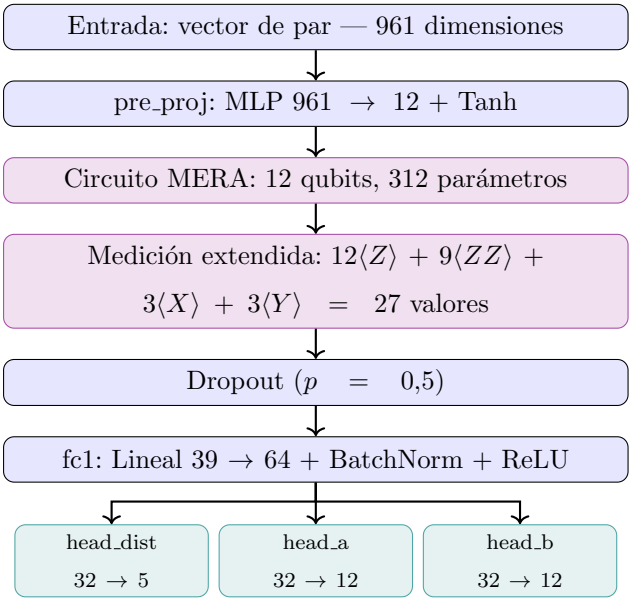


Figura 4.5: Diagrama de bloques de la arquitectura propuesta `HybridQNN_MultiTask`. En violeta, el componente cuántico; en verde, las tres cabezas de predicción.

Nota. Elaboración propia.

4.3.1 Bloque 7 — Circuito cuántico MERA

El séptimo bloque define el circuito cuántico variacional que constituye el componente central y más refinado del modelo. Tras evaluar alternativas más simples en el estudio de ablación (un circuito genérico VQC y una red tensorial en árbol TTN), el modelo principal adopta una arquitectura MERA (*Multi-scale Entanglement Renormalization Ansatz*,

ansatz de renormalización de entrelazamiento multiescala) (Vidal 2007) con recarga de datos (Pérez-Salinas et al. 2020). Este es el componente que diferencia el trabajo de una red neuronal puramente clásica, por lo que se describe con especial detalle, tanto en su estructura como en su formalismo matemático.

El circuito opera sobre 12 qubits y organiza sus operaciones de forma jerárquica, como una extensión del esquema en árbol del TTN a la que se añaden puertas de *disentangling* (desentrelazado). Se construye a partir de dos tipos de bloque parametrizado. El primero, común con el TTN, actúa sobre dos qubits aplicando rotaciones individuales en torno a los ejes Y y Z de la esfera de Bloch, seguidas de una puerta CNOT que los entrelaza. El segundo, característico del MERA, es un *disentangler*: una puerta de dos qubits que se aplica *antes* de cada paso de renormalización para eliminar el entrelazamiento de corto alcance espurio, permitiendo que el circuito capture correlaciones a múltiples escalas de forma más eficiente que el TTN. Matemáticamente, un bloque de entrelazamiento sobre los qubits i y j con parámetros $\boldsymbol{\theta}$ se expresa como

$$B(\boldsymbol{\theta}) = \mathrm{CNOT}_{ij} \left(R_Y(\theta_3)R_Z(\theta_4)\right)_j \left(R_Y(\theta_1)R_Z(\theta_2)\right)_i, \tag{4.4}$$

donde R_Y y R_Z son las puertas de rotación en torno a los ejes Y y Z, y la puerta CNOT sobre el par (i, j) genera el entrelazamiento. Los *disentanglers* siguen una forma análoga pero se sitúan cruzando las fronteras entre los bloques de renormalización, actuando sobre pares de qubits que pertenecerían a ramas distintas del árbol. La Figura 4.6 muestra el detalle de las puertas cuánticas que componen un bloque de entrelazamiento y un *disentangler*.

La estructura del circuito procede combinando ambos tipos de bloque a lo largo de los niveles de renormalización que reducen progresivamente los 12 qubits iniciales. En total, el circuito contiene 27 bloques con 8 parámetros cada uno, lo que suma 312 parámetros cuánticos entrenables. Frente a los 28 parámetros del TTN, esta mayor riqueza paramétrica —junto con las puertas de *disentangling*— dota al MERA de una expresividad sustancialmente superior, que se traduce en los mejores resultados del estudio de ablación tanto en predicción de contactos como en reconstrucción tridimensional.

A diferencia de las configuraciones más simples, que medían únicamente los valores de expectación de dos qubits, el modelo principal emplea una *medición extendida* del estado cuántico: se miden los valores de expectación $\langle Z_i \rangle$ de los 12 qubits, las correlaciones $\langle Z_i Z_j \rangle$ de 9 pares, y los valores $\langle X_i \rangle$ y $\langle Y_i \rangle$ de 3 qubits, sumando 27 valores de salida. Las correlaciones $\langle Z_i Z_j \rangle$ son genuinamente cuánticas —codifican el entrelazamiento entre

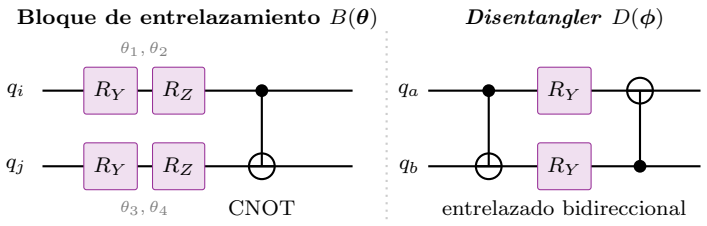


Figura 4.6: Detalle de las puertas cuánticas del circuito MERA. A la izquierda, un bloque de entrelazamiento $B(\boldsymbol{\theta})$: rotaciones R_Y y R_Z parametrizadas sobre cada qubit seguidas de una puerta CNOT. A la derecha, un *disentangler* $D(\boldsymbol{\phi})$, que combina puertas CNOT en ambos sentidos con rotaciones intermedias para eliminar el entrelazamiento espurio entre escalas.

Nota. Elaboración propia.

qubits— y proporcionan a las capas clásicas una información mucho más rica sin añadir ningún parámetro adicional al circuito.

Mientras que la variante TTN base ilustrada mide únicamente el valor de expectación del operador de Pauli Z sobre los qubits supervivientes, el circuito MERA del modelo principal emplea una medición extendida de 27 valores, como se ha descrito. El vector de salida de la variante base se define, a modo de ejemplo, como

$$\mathbf{o} = \big[\langle Z_0\rangle,\ \langle Z_4\rangle\big] \in \mathbb{R}^2. \tag{4.5}$$

Medir estos dos qubits en lugar de uno solo proporciona una señal algo más rica a las capas clásicas que procesan la salida del circuito, sin aumentar el número de parámetros.

Conviene aclarar el significado intuitivo del bloque que compone el circuito, ya que es la clave de cómo funciona la red en árbol. Cada bloque cumple una función parecida a la de las operaciones de reducción en una red neuronal convencional: combina la información de dos qubits mediante el entrelazamiento que introduce la puerta CNOT y la concentra en uno solo, de modo que en cada nivel el número de qubits activos se reduce a la mitad y la información se va resumiendo de forma jerárquica. Esta estructura en árbol permite que información procedente de qubits inicialmente distantes acabe combinándose en los niveles superiores, lo que resulta especialmente valioso cuando dos aminoácidos alejados en la secuencia están en contacto en el espacio tridimensional.

La recarga de datos entre niveles, que reinyecta las características de entrada en los qubits supervivientes, aumenta la expresividad del circuito sin añadir profundidad excesiva.

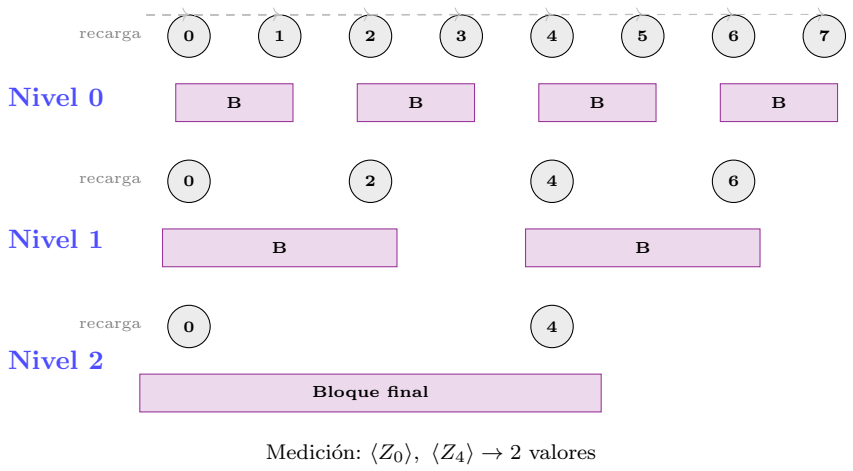


Figura 4.7: Esquema jerárquico de renormalización en tres niveles, ilustrado sobre la variante TTN base de la que parte el diseño. Cada bloque (B, violeta) aplica rotaciones R_Y y R_Z seguidas de una puerta CNOT que entrelaza y reduce el número de qubits activos. El circuito MERA de 12 qubits del modelo principal extiende este esquema añadiendo puertas de *disentangling* entre niveles y una medición extendida del estado.

Nota. Elaboración propia a partir de Vidal (2007).

Finalmente, los parámetros del circuito se inicializan con valores próximos a cero, en el intervalo $[-0{,}01, 0{,}01]$, siguiendo la estrategia de inicialización que mitiga el problema de los *barren plateaus* (Grant et al. 2019).

4.3.2 Bloque 8 — Modelo híbrido HybridQNN_MultiTask

El octavo bloque define la clase del modelo híbrido completo, que integra el circuito TTN del bloque anterior con las capas clásicas de proyección y predicción. El modelo se compone de varios módulos que se ejecutan en secuencia, tal como se mostró en la Figura 4.5.

La primera capa, denominada `pre_proj`, es un perceptrón multicapa que comprime el vector de entrada de 961 dimensiones a tan solo 12, seguida de una activación de tipo tangente hiperbólica. Esta activación es necesaria porque acota los valores de salida en el intervalo $[-1, 1]$, dado que esos valores se utilizarán como ángulos de rotación en las puertas del circuito cuántico. A continuación se encuentra el circuito MERA, seguido de una capa de *dropout* (Srivastava et al. 2014) que desactiva aleatoriamente una fracción de las salidas del circuito para regularizar el entrenamiento.

Tras el componente cuántico, las 27 salidas de la medición extendida del circuito se procesan mediante una capa lineal con normalización por lotes (Ioffe y Szegedy 2015) y activación ReLU (Nair y Hinton 2010). Finalmente, el vector resultante alimenta tres cabezas de predicción independientes: una para la distancia, con 5 salidas correspondientes a los 5 bins, y dos para los ángulos de orientación, con 12 salidas cada una. El circuito cuántico aporta su capacidad expresiva con solo 312 parámetros cuánticos, una fracción reducida del total del modelo, lo que ilustra que la mayor parte de la expresividad se concentra en un componente cuántico compacto.

La decisión de emplear tres cabezas de predicción independientes en lugar de una sola responde a la naturaleza multitarea del problema. Predecir la distancia entre dos residuos y predecir su orientación relativa son objetivos distintos pero complementarios: la distancia captura cuán próximos están dos residuos, mientras que los ángulos capturan la disposición geométrica de la cadena en torno a ellos. Al compartir el tronco común —las capas que van desde la entrada hasta la salida del circuito cuántico— y bifurcarse solo al final, el modelo aprende una representación interna común que sirve a las tres tareas, lo que actúa como una forma de regularización: cada tarea impone restricciones sobre la representación compartida, y esas restricciones cruzadas ayudan a que el modelo generalice mejor que si se entrenara cada objetivo por separado. Esta estrategia de aprendizaje multitarea es habitual en los sistemas modernos de predicción de estructura, que suelen predecir simultáneamente distancias y orientaciones para reconstruir después la geometría tridimensional con mayor fidelidad.

Es importante subrayar que el circuito cuántico ocupa una posición central en el flujo de información: toda la señal que llega a las cabezas de predicción ha pasado necesariamente a través de él, ya que actúa como un cuello de botella entre la proyección de entrada y las capas clásicas finales. Esto significa que el circuito no es un añadido accesorio, sino un componente por el que fluye obligatoriamente toda la información, lo que garantiza que su capacidad de transformación se aproveche de forma efectiva en cada predicción.

4.4 Etapa 3: Entrenamiento (Bloques 9–10)

La tercera etapa implementa el proceso de entrenamiento del modelo, con todas las estrategias de regularización y de diagnóstico necesarias para que el aprendizaje sea estable.

Esta etapa comprende dos bloques: el que ejecuta el bucle de entrenamiento propiamente dicho y el que analiza visualmente el progreso del aprendizaje.

4.4.1 Bloque 9 — Entrenamiento con parada temprana y checkpoint

El noveno bloque implementa el bucle completo de entrenamiento. El modelo se entrena de forma multitarea (Caruana 1997), optimizando simultáneamente la predicción de distancias y la de los dos ángulos de orientación. La función de pérdida combina tres términos de entropía cruzada (Goodfellow et al. 2016), uno por cada tarea, ponderados de la siguiente forma:

$$\mathcal{L} = \lambda_{\text{dist}}\,\mathcal{L}_{\text{CE}}^{\text{dist}} + \lambda_{\text{ang}}\,\mathcal{L}_{\text{CE}}^{\alpha} + \lambda_{\text{ang}}\,\mathcal{L}_{\text{CE}}^{\beta}, \tag{4.6}$$

con $\lambda_{\text{dist}} = 1{,}0$ y $\lambda_{\text{ang}} = 0{,}3$. Los ángulos de orientación actúan como tarea auxiliar que regulariza el modelo: al obligarlo a predecir también la geometría local, se fomenta que aprenda representaciones más informativas que si solo predijera las distancias (Xu 2019).

Conviene explicar qué es la **entropía cruzada** que aparece en la función de pérdida, ya que es el criterio que mide cómo de buenas son las predicciones del modelo. Cuando el modelo predice a qué intervalo de distancia pertenece un par de aminoácidos, no da una respuesta única, sino que reparte una probabilidad entre todos los intervalos posibles. La entropía cruzada mide la discrepancia entre esa distribución de probabilidad predicha y la respuesta correcta real: vale poco cuando el modelo asigna una probabilidad alta a la respuesta correcta, y mucho cuando se equivoca con confianza. Durante el entrenamiento, el objetivo es ajustar los parámetros del modelo para que esta discrepancia sea lo más pequeña posible, lo que equivale a que las predicciones se acerquen progresivamente a las respuestas correctas.

El modelo incorpora además varias técnicas de regularización, es decir, mecanismos que evitan que aprenda de memoria los datos de entrenamiento en lugar de captar patrones generales. La primera es el **dropout** (Srivastava et al. 2014), que durante el entrenamiento desactiva al azar una fracción de las neuronas en cada paso. Esto obliga al modelo a no depender en exceso de ninguna neurona concreta y lo hace más robusto, de forma análoga a cómo un equipo de trabajo se vuelve más resiliente si sus miembros saben cubrir las tareas de los demás. La segunda es la **normalización por lotes** (Ioffe y Szegedy 2015), que ajusta los valores que circulan entre capas para que mantengan una escala estable a lo largo del entrenamiento, lo que acelera y estabiliza el aprendizaje. La tercera es

la regularización L_2, controlada por el parámetro *weight decay*, que penaliza los valores grandes en los parámetros del modelo para evitar que algunos dominen sobre el resto.

El optimizador empleado es Adam (Kingma y Ba 2015), configurado con tasas de aprendizaje diferenciadas para las capas clásicas y para el circuito cuántico. La tasa de aprendizaje del circuito es más baja porque los gradientes de un circuito cuántico, calculados mediante la regla de desplazamiento de parámetros (Schuld et al. 2019), son más ruidosos que los gradientes clásicos. Esta regla es un procedimiento específico de la computación cuántica que permite calcular cómo cambia la salida del circuito al variar cada parámetro, ejecutando el circuito dos veces con el parámetro ligeramente desplazado en sentidos opuestos. El entrenamiento incorpora además dos mecanismos para evitar el sobreajuste. El primero es la parada temprana (Prechelt 1998), que detiene el entrenamiento si la pérdida de validación no mejora durante un número determinado de épocas consecutivas y restaura los pesos del mejor estado encontrado. El segundo es el guardado automático de un punto de control cada vez que se alcanza un nuevo mínimo en la pérdida de validación, lo que permite reanudar el entrenamiento o recuperar el mejor modelo en cualquier momento. La Figura 4.8 resume el ciclo completo de entrenamiento que se repite en cada época.

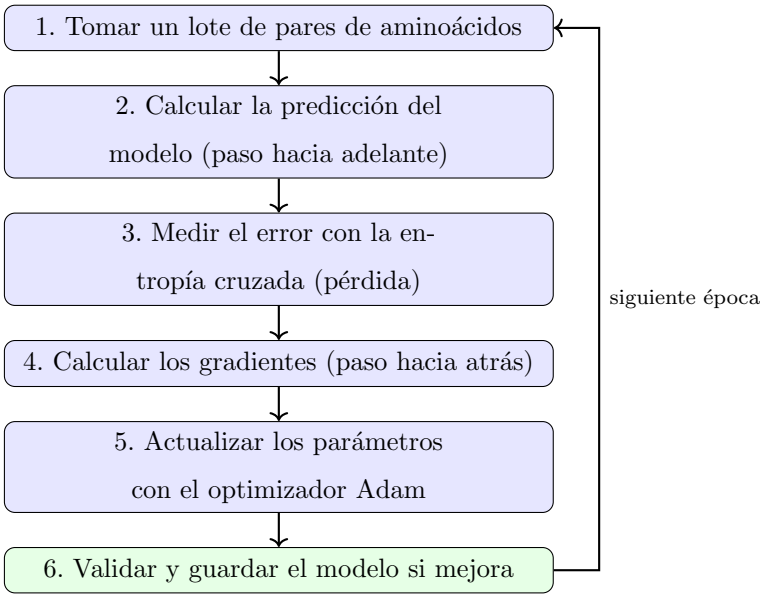


Figura 4.8: Ciclo de entrenamiento que se repite en cada época hasta la parada temprana.

Nota. Elaboración propia.

4.4.2 Bloque 10 — Curvas de entrenamiento y diagnóstico

El décimo bloque genera las curvas de entrenamiento y proporciona un diagnóstico automático del estado del modelo. Se producen dos gráficas: la evolución de la pérdida de entrenamiento y de validación a lo largo de las épocas, y la evolución de la precisión de clasificación de distancia junto con la línea base correspondiente al azar. Además, el bloque calcula la diferencia entre la pérdida de validación y la de entrenamiento al final del proceso y emite una recomendación automática: si la diferencia es grande, indica posible sobreajuste y sugiere aumentar la regularización; si es negativa, indica posible subajuste y sugiere reducir la regularización o aumentar los datos. Este diagnóstico resulta especialmente útil durante el proceso de ajuste iterativo de hiperparámetros.

4.5 Retos de implementación y decisiones de diseño

Antes de pasar a la etapa de evaluación, conviene detenerse en algunos de los retos técnicos que surgieron durante el desarrollo y en las decisiones que se tomaron para resolverlos. Documentar estos aspectos es valioso porque forma parte del aprendizaje del trabajo y porque puede orientar a quien intente reproducirlo o ampliarlo.

4.5.1 El reto de la eficiencia computacional

El principal reto técnico del trabajo fue la eficiencia de la simulación del circuito cuántico. En la implementación empleada, basada en la biblioteca PennyLane, el circuito se ejecuta procesando los pares de aminoácidos de uno en uno, lo que resulta computacionalmente costoso: una sola pasada completa sobre los datos de entrenamiento puede tardar alrededor de media hora. La causa es que la biblioteca de simulación cuántica utilizada no permite procesar varios datos de forma simultánea de manera nativa, obligando a un bucle que repite la simulación para cada par individualmente.

Este coste condicionó el diseño experimental: condicionó el número de pares que pueden procesarse por época y el número de configuraciones exploradas en el estudio de ablación. La versión por lotes del circuito, que expresa sus operaciones como multiplicaciones de matrices ejecutables sobre la tarjeta gráfica, permitió elevar el conjunto de entrenamiento hasta 200 000 pares extraídos de 15 000 proteínas. Una vía de mejora natural, que se plantea como trabajo futuro en el Capítulo 7, consiste en reimplementar el circuito de forma que pueda procesar lotes completos de datos a la vez, aprovechando que las operaciones del

circuito pueden expresarse como multiplicaciones de matrices que las bibliotecas de cálculo numérico ejecutan de forma muy eficiente sobre la tarjeta gráfica. Esta optimización ilustra un principio importante: la viabilidad práctica de un enfoque cuántico simulado depende en gran medida de cómo se implemente la simulación, y no solo del diseño teórico del circuito.

4.5.2 El equilibrio entre capacidad y datos

Otra decisión de diseño relevante fue la elección del tamaño del modelo. Durante el desarrollo se exploraron configuraciones con un mayor número de qubits y con capas clásicas más profundas, bajo la hipótesis razonable de que un modelo con más capacidad obtendría mejores resultados. Sin embargo, los experimentos mostraron lo contrario: al aumentar la capacidad del modelo sin incrementar proporcionalmente la cantidad de datos de entrenamiento, el rendimiento empeoraba en lugar de mejorar. Este fenómeno, conocido como sobreajuste, se produce cuando el modelo tiene tantos parámetros que aprende de memoria los ejemplos de entrenamiento en lugar de captar patrones generalizables.

La conclusión práctica fue que el modelo MERA de 12 qubits, con su medición extendida y una regularización cuidadosa de las capas clásicas, resultó ser el que mejor equilibraba capacidad expresiva y datos disponibles. Esta decisión refleja una lección general del aprendizaje automático especialmente relevante en contextos con datos limitados: la complejidad del modelo debe ajustarse a la cantidad de información disponible para entrenarlo, y un modelo más grande no es necesariamente mejor.

4.5.3 La representación de las características

Una tercera decisión importante fue cómo representar cada par de aminoácidos como entrada al modelo. La representación adoptada concatena los embeddings de los dos residuos junto con su separación normalizada en la secuencia, tal como se describió en la ecuación correspondiente del Bloque 6. Se optó por mantener los embeddings de ambos residuos por separado, en lugar de resumirlos en una única representación, para conservar toda la información que ESM-2 proporciona sobre cada uno de ellos.

Una alternativa que se contempló fue emplear una representación simétrica —basada en la suma y la diferencia de los embeddings— que produjera la misma salida independientemente del orden de los dos residuos. Esta variante tiene la ventaja teórica de garantizar que el par (i, j) y el par (j, i) se traten de forma idéntica, lo cual es coherente con el

hecho de que la distancia entre dos residuos no depende del orden. Su exploración queda planteada como una posible mejora futura. En la configuración evaluada en este trabajo, la simetría se maneja en la fase de reconstrucción, donde el mapa de distancias se simetriza explícitamente antes de aplicar el escalado multidimensional, garantizando así que la matriz de distancias sea válida con independencia de cómo se hayan generado sus entradas.

4.6 Etapa 4: Evaluación, ablación y visualización (Bloques 11–19)

La cuarta y última etapa implementa la evaluación cuantitativa completa del modelo, la reconstrucción de las estructuras tridimensionales a partir de los mapas de distancias predichos y la documentación del proceso de ajuste. Esta etapa es la que produce los resultados que se analizan en el Capítulo 5.

4.6.1 Bloque 11 — Conjuntos de evaluación

El undécimo bloque carga las proteínas sobre las que se mide el rendimiento del sistema, tomadas del conjunto de validación oficial de ProteinNet CASP11, que no interviene en ninguna fase del entrenamiento. Se emplean las 224 proteínas disponibles para las métricas de contacto y un subconjunto de 30 para las métricas estructurales, cuyo cálculo es considerablemente más costoso por requerir la reconstrucción tridimensional completa de cada cadena. Este bloque define asimismo las funciones de registro que almacenan en disco los resultados de cada configuración evaluada, de modo que las tablas comparativas puedan generarse posteriormente sin repetir el cálculo.

El tamaño del conjunto de evaluación resultó ser un factor determinante durante el desarrollo. Medir la misma configuración sobre 10, 20 o 224 proteínas produjo diferencias en la precisión superiores al efecto de cualquier modificación arquitectónica ensayada, lo que llevó a fijar la evaluación sobre el conjunto completo.

4.6.2 Bloque 12 — Métricas de predicción de contactos

El duodécimo bloque implementa la evaluación de contactos siguiendo el protocolo del experimento CASP. Dado que estas métricas son las que sustentan los resultados del Capítulo 5, conviene definirlas formalmente.

La Contact Precision @k mide la fracción de contactos correctamente predichos entre los k pares con mayor confianza. Un contacto se define como un par de residuos cuya distancia Cα–Cα es inferior a 8 Å. Formalmente, si se ordenan los pares por confianza decreciente y se toman los k primeros, la precisión es

$$\mathrm{P@}k = \frac{1}{k} \sum_{(i,j)\in \text{top-}k} \mathbb{1}\left[d_{ij} < 8\,\text{Å}\right], \tag{4.7}$$

donde $\mathbb{1}[\cdot]$ es la función indicadora y d_{ij} es la distancia real entre los residuos. Se evalúan los valores $k = L$, $k = L/2$, $k = L/5$ y $k = L/10$, siendo L la longitud de la proteína.

Un aspecto esencial del protocolo es que los pares no se evalúan de forma conjunta sino agrupados en tres rangos *exclusivos* según su separación en la secuencia: corto alcance ($6 \leq |i-j| \leq 11$), medio alcance ($12 \leq |i-j| \leq 23$) y largo alcance ($|i-j| \geq 24$). Los pares con separación inferior a seis residuos se excluyen por corresponder a estructura secundaria local trivialmente predecible. Esta separación en rangos exclusivos es determinante: los contactos de corto alcance son mucho más fáciles de predecir y, si se mezclan con los de largo alcance en una única cifra, la dominan y producen valores considerablemente más altos que no resultan comparables con los que publica CASP, referidos siempre al rango largo.

Junto a la precisión se calculan el *recall* y la puntuación F1 sobre las mismas listas reducidas, el coeficiente de correlación de Matthews —más robusto que la precisión ante el fuerte desbalance entre contactos y no contactos— y el área bajo la curva de precisión-recall. Se incluye además la puntuación Xd, definida en el protocolo de CASP como la desviación entre la distribución de distancias de los contactos predichos y la distribución *a priori* de todos los pares del mismo rango, que toma el valor cero para un predictor aleatorio y crece cuanto mejor concentra el modelo sus predicciones en pares realmente próximos.

El RMSD (Root Mean Square Deviation) mide la desviación media entre las coordenadas predichas y las reales tras alinearlas óptimamente. Para dos conjuntos de N coordenadas alineadas, se define como

$$\mathrm{RMSD} = \sqrt{\frac{1}{N}\sum_{i=1}^{N} \|\mathbf{r}_i^{\text{pred}} - \mathbf{r}_i^{\text{real}}\|^2}. \tag{4.8}$$

La alineación óptima entre ambas estructuras se obtiene mediante el algoritmo de Kabsch (Kabsch 1976), que encuentra la rotación que minimiza el RMSD.

El TM-score (Zhang y Skolnick 2004) mide la similitud topológica global y, a diferencia del RMSD, es menos sensible a errores locales grandes y está normalizado entre 0 y 1. Se define como

$$\text{TM-score} = \frac{1}{L}\sum_{i=1}^{L}\frac{1}{1+(d_i/d_0)^2}, \tag{4.9}$$

donde d_i es la distancia entre el residuo i predicho y el real tras la alineación, y d_0 es un factor de normalización que depende de la longitud de la proteína. El GDT_TS (Zemla 2003) mide la fracción de residuos que quedan correctamente posicionados bajo cuatro umbrales de distancia (1, 2, 4 y 8 Å), promediando los cuatro porcentajes. Por último, el lDDT (Mariani et al. 2013) evalúa la conservación de las distancias locales entre residuos vecinos, sin necesidad de alineación global. El bloque también define las funciones de reconstrucción tridimensional, que se describen en la sección siguiente.

4.6.3 Bloque 13 — Reconstrucción tridimensional

El decimotercer bloque convierte el mapa de distancias predicho en coordenadas tridimensionales. La reconstrucción se realiza en dos etapas. En la primera, se aplica el escalado multidimensional métrico (MDS) (Cox y Cox 2000) sobre el mapa de distancias predicho. El MDS es una técnica que encuentra el conjunto de puntos en el espacio tridimensional cuyas distancias mutuas reproducen lo mejor posible las distancias del mapa. En la segunda etapa, las coordenadas obtenidas se refinan mediante una optimización en dos fases: una primera fase que establece la estructura global priorizando los contactos de largo alcance, y una segunda fase que ajusta la geometría local del esqueleto imponiendo la distancia canónica de 3,8 Å entre residuos consecutivos. La Figura 4.9 resume este pipeline.

Una vez reconstruidas las estructuras, el bloque calcula todas las métricas definidas en la sección anterior sobre el conjunto de validación y exporta varias estructuras en formato PDB para su visualización. El refinamiento en dos fases produce mejores resultados que un refinamiento uniforme, porque evita que la corrección de errores locales distorsione la estructura global ya establecida.

Para entender mejor el papel del **escalado multidimensional**, conviene una analogía sencilla. Imaginemos que disponemos únicamente de una tabla con las distancias por carretera entre varias ciudades, pero no de un mapa. A partir de esas distancias, sería posible reconstruir aproximadamente las posiciones de las ciudades en un mapa plano, situando cada una de modo que las distancias entre ellas coincidan con las de la tabla. El escalado multidimensional hace exactamente esto, pero en tres dimensiones en lugar de dos: a partir

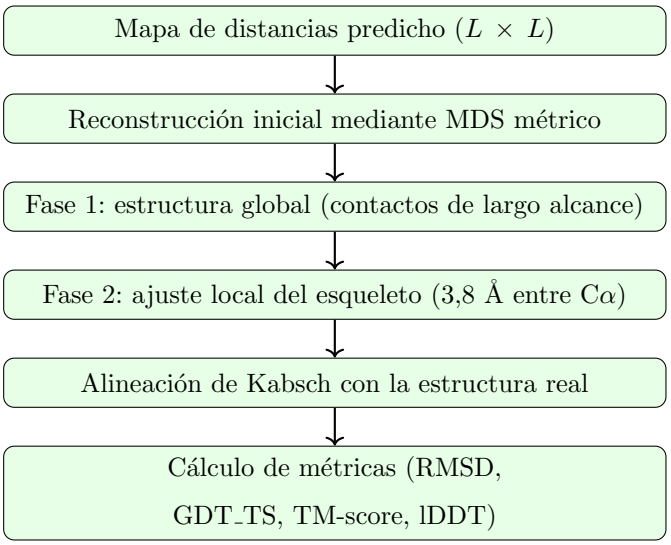


Figura 4.9: Pipeline de reconstrucción tridimensional a partir del mapa de distancias predicho.

Nota. Elaboración propia.

del mapa de distancias entre aminoácidos, encuentra unas coordenadas tridimensionales que reproduzcan esas distancias lo mejor posible. El resultado es una primera versión de la estructura de la proteína que después se refina. Esta analogía también permite entender por qué la calidad de la reconstrucción depende críticamente de la precisión del mapa de distancias: si las distancias de partida contienen errores, las posiciones reconstruidas heredarán esos errores, igual que un mapa reconstruido a partir de distancias inexactas resultaría deformado.

4.6.4 Bloque 14 — Métricas de estructura tridimensional

El decimocuarto bloque compara la estructura predicha con la experimental tras superponerlas de forma óptima mediante el algoritmo de Kabsch, y calcula el conjunto de medidas que emplea CASP para valorar modelos estructurales: RMSD, GDT_TS, GDT_HA, TM-score y lDDT. Además de los valores agregados, el bloque desglosa el GDT_TS por cada uno de sus cuatro umbrales de distancia y reporta las métricas proteína a proteína. Este desglose resultó especialmente informativo: permitió identificar que la calidad de la reconstrucción se degrada de forma acusada con la longitud de la cadena, y detectar los casos en que el escalado multidimensional no converge a una configuración coherente.

4.6.5 Bloque 15 — Evaluación del modelo entrenado

El decimoquinto bloque integra los dos anteriores y ejecuta la evaluación completa. Aplica las métricas de contacto y las estructurales al modelo entrenado y, en la misma pasada, a la referencia de ESM-2: la predicción de contactos que el propio modelo de lenguaje genera de forma nativa, sin ningún componente entrenado en este trabajo. Esta referencia es la que permite determinar qué parte del rendimiento aporta la arquitectura propuesta y qué parte procede ya de las representaciones preentrenadas. Los resultados de ambas evaluaciones se registran en disco para su uso posterior.

4.6.6 Bloque 16 — Estudio de ablación del componente cuántico

El decimosexto bloque implementa el experimento central del trabajo. Entrena y evalúa dos variantes del modelo que comparten absolutamente todo —datos, semilla aleatoria, hiperparámetros, arquitectura clásica y protocolo de parada temprana— salvo la capa que ocupa la ruta intercambiable: el circuito MERA en una y una capa lineal $12 \to 27$ en la otra. Ambas se entrenan de forma consecutiva dentro de la misma ejecución, reinicializando la semilla antes de cada una para que partan de condiciones idénticas.

Un detalle de implementación resultó crítico. El circuito cuántico se instancia como un objeto global compartido, de modo que la variante cuántica heredaría los pesos ya entrenados en el pipeline principal si no se reconstruyese explícitamente. El bloque lo reinicializa antes de cada brazo, garantizando que ambas variantes parten de sus respectivas inicializaciones y que la única diferencia entre ellas es la naturaleza de la capa.

4.6.7 Bloque 17 — Tablas comparativas con CASP

El decimoséptimo bloque genera las tablas de resultados a partir del registro almacenado en disco: la precisión por rango de separación para todas las configuraciones evaluadas, el detalle completo del rango de largo alcance, la comparación con las cifras publicadas de CASP11 a CASP14 y el resumen de métricas estructurales. Al operar sobre los resultados guardados y no sobre el modelo, este bloque puede ejecutarse de forma autónoma sin repetir ningún cálculo.

4.6.8 Bloques 18 y 19 — Exportación y visualización

Los dos últimos bloques generan los ficheros necesarios para inspeccionar visualmente las estructuras predichas. El primero exporta en formato PDB, para cada proteína seleccionada, la estructura experimental, la reconstrucción directa por escalado multidimensional y la estructura tras el refinamiento geométrico, junto con sus métricas individuales. El segundo completa el esqueleto peptídico a partir de las posiciones de los carbonos alfa, paso necesario para que los programas de visualización molecular representen la cadena como una estructura continua en lugar de como átomos aislados.

4.7 Guía de ajuste de hiperparámetros

El decimotercer y último bloque recoge, en forma de tabla, una guía práctica para el ajuste de hiperparámetros. Esta guía relaciona cada patrón observable en las curvas de entrenamiento con la acción correctiva recomendada: el sobreajuste sugiere aumentar la regularización; el subajuste sugiere reducirla o aumentar los datos; las oscilaciones en la pérdida sugieren reducir la tasa de aprendizaje; y una diferencia pequeña y estable entre las pérdidas indica que el modelo está listo para escalar a un conjunto de datos mayor.

Conviene explicar la lógica que subyace a cada una de estas recomendaciones, ya que constituye el conocimiento práctico destilado durante el desarrollo. El sobreajuste se manifiesta cuando la pérdida de entrenamiento sigue disminuyendo mientras que la de validación se estanca o empeora, señal de que el modelo está memorizando los ejemplos concretos en lugar de aprender patrones generalizables; la respuesta natural es reforzar la regularización, ya sea aumentando el *dropout* o el decaimiento de pesos, o bien ampliando el volumen de datos para dificultar la memorización. El subajuste es el fenómeno opuesto: ambas pérdidas se mantienen altas porque el modelo carece de capacidad o de tiempo para capturar la estructura de los datos, y la solución pasa por relajar la regularización o incrementar la capacidad efectiva del modelo. Las oscilaciones bruscas en la pérdida suelen indicar que la tasa de aprendizaje es demasiado alta, lo que hace que la optimización dé pasos excesivamente grandes y sobrepase los mínimos; reducirla estabiliza el descenso. Por último, cuando la diferencia entre las pérdidas de entrenamiento y validación es pequeña y estable, el modelo ha alcanzado un equilibrio saludable entre ajuste y generalización, lo que sugiere que se le puede exigir más aumentando el volumen de datos sin riesgo inmediato de sobreajuste.

Este bloque actúa como documentación del proceso de ajuste iterativo seguido durante el desarrollo del trabajo y facilita la reproducción de los experimentos. Más allá de su utilidad práctica inmediata, refleja una filosofía de trabajo basada en el diagnóstico sistemático: en lugar de ajustar los hiperparámetros por ensayo y error sin criterio, cada decisión se toma a partir de la lectura razonada de las curvas de entrenamiento, lo que hace el proceso más eficiente y reproducible.

5. Resultados y discusión

Este capítulo presenta y analiza los resultados obtenidos en el estudio de ablación sistemático descrito en el Capítulo 4. Se comparan las configuraciones evaluadas, tanto entre sí como con los grupos participantes en el experimento CASP11 —la misma edición de la que procede el conjunto de validación empleado—, con el fin de responder a la pregunta de investigación planteada en la introducción. El análisis se estructura en siete secciones: primero se recuerdan las métricas empleadas, después se presentan los resultados de predicción de contactos y de reconstrucción tridimensional, a continuación se contextualizan frente a CASP11 y se analiza un caso concreto, y finalmente se discute el estudio de ablación y se sintetizan los hallazgos.

Conviene advertir desde el principio que el objetivo de este trabajo no es competir con sistemas como AlphaFold2, que disponen de recursos de entrenamiento varios órdenes de magnitud superiores, sino explorar si un circuito cuántico puede aportar valor como componente de un sistema de predicción de estructura. Por ello, los resultados deben interpretarse como una exploración de viabilidad y no como un intento de superar el estado del arte.

5.1 Métricas de evaluación empleadas

Antes de presentar los resultados conviene recordar brevemente qué mide cada una de las métricas utilizadas, todas ellas definidas formalmente en el Capítulo 4. La Contact Precision evalúa la capacidad del modelo para identificar qué pares de residuos están en contacto, y es la métrica principal del experimento CASP para la predicción de contactos. El RMSD mide el error medio de posición entre la estructura predicha y la real tras alinearlas. El GDT_TS y el TM-score miden la similitud estructural global, siendo ambos más robustos que el RMSD frente a errores locales aislados. Por último, el lDDT mide la calidad de las distancias locales sin depender de una alineación global. En conjunto, estas métricas ofrecen una visión completa de la calidad de las predicciones, tanto a nivel de contactos individuales como de estructura tridimensional global.

Resulta útil tener presente cómo se interpretan los valores de estas métricas para poder valorar los resultados con criterio. En el caso de la Contact Precision, el GDT_TS, el TM-score y el lDDT, los valores son mejores cuanto más altos, ya que indican una mayor

proporción de aciertos o una mayor similitud con la estructura real; estas cuatro métricas se expresan como una fracción entre 0 y 1, o equivalentemente como un porcentaje. En cambio, el RMSD y el RMSE son mejores cuanto más bajos, ya que miden errores: un valor de cero correspondería a una predicción perfecta. Conviene además señalar que el TM-score tiene umbrales de interpretación bien establecidos en la literatura: valores por debajo de 0,2 corresponden a estructuras esencialmente no relacionadas, mientras que valores por encima de 0,5 indican que las dos estructuras comparten el mismo plegamiento general. Tener presentes estas referencias permite juzgar si un resultado concreto refleja una predicción útil o meramente aproximada, lo que será especialmente relevante al analizar las tablas de las secciones siguientes.

Junto a la precisión, las tablas de este capítulo incorporan tres métricas complementarias que el protocolo de CASP emplea para caracterizar la calidad de una predicción de contactos más allá del simple porcentaje de aciertos. El **coeficiente de correlación de Matthews** (MCC) resume la matriz de confusión en un único valor entre -1 y 1, y resulta especialmente informativo cuando las clases están fuertemente desbalanceadas, como ocurre aquí: en el rango de largo alcance apenas un 6% de los pares son contactos reales, de modo que una precisión aparentemente razonable puede corresponder a una capacidad discriminativa casi nula. Un valor de cero indica un comportamiento equivalente al azar.

La puntuación **Xd** mide cuánto se aparta la distribución de distancias de los contactos predichos respecto a la distribución *a priori* de todos los pares del mismo rango. A diferencia de la precisión, que solo distingue entre acierto y fallo según el umbral de 8 Å, Xd premia que las predicciones erróneas correspondan al menos a pares próximos: un modelo que se equivoca prediciendo pares a 10 Å obtiene una puntuación mejor que otro que se equivoca prediciendo pares a 30 Å. Toma el valor cero para un predictor aleatorio y crece cuanto mejor concentra el modelo sus predicciones en regiones realmente cercanas. Es una de las dos métricas que el informe oficial de evaluación de CASP11 reporta para cada grupo participante (Monastyrskyy et al. 2016).

Por último, el **área bajo la curva de precisión-recall** (AUC-PR) evalúa la calidad del ordenamiento completo de los pares por confianza, sin depender de dónde se corte la lista. Resulta complementaria a las precisiones @L, @L/2 y @L/5, que miden el rendimiento en puntos de corte concretos.

5.2 Resultados de predicción de contactos

La predicción de contactos es la tarea fundamental del modelo, ya que el mapa de contactos es el paso intermedio del que depende toda la reconstrucción posterior. En esta sección se presentan los resultados de Contact Precision para las distintas configuraciones evaluadas, comparando el efecto del tipo de circuito cuántico y de la resolución de la discretización de distancias.

La Tabla 5.1 presenta los resultados de predicción de contactos siguiendo el protocolo del experimento CASP. Este protocolo agrupa los pares de residuos en tres rangos *exclusivos* según su separación en la secuencia —corto (6–11), medio (12–23) y largo (≥24)— y evalúa la precisión sobre las listas de los contactos mejor puntuados por el modelo. La distinción es esencial: los contactos de corto alcance reflejan en buena medida estructura secundaria local y resultan mucho más fáciles de predecir, razón por la cual las cifras que publica CASP corresponden al rango largo.

Junto a los resultados del sistema propuesto se incluyen dos referencias imprescindibles para interpretarlos. La primera es la *densidad de contactos*, es decir, la proporción de pares que efectivamente están en contacto dentro de cada rango, que constituye el rendimiento esperable de un predictor aleatorio. La segunda es la predicción de contactos que el propio modelo de lenguaje ESM-2 genera de forma nativa, sin ningún componente entrenado en este trabajo; esta referencia permite cuantificar qué parte del rendimiento procede de las representaciones preentrenadas y qué parte aporta la arquitectura propuesta.

El sistema propuesto supera a ambas referencias en los tres rangos de separación. La mejora sobre ESM-2 es de 19,0 puntos porcentuales en el rango corto, 15,8 en el medio y 2,1 en el largo, medida sobre la precisión de la lista @L/5. Las métricas complementarias confirman esta ventaja de forma independiente: el coeficiente de correlación de Matthews y la puntuación Xd, que mide cuánto se aparta la distribución de distancias de los contactos predichos de la distribución *a priori*, son superiores en todos los rangos. El hecho de que cuatro indicadores distintos coincidan refuerza que la mejora no es un artefacto de una métrica concreta.

No obstante, la magnitud de la mejora decrece marcadamente con la separación de secuencia. En el rango largo, el más difícil y el único directamente comparable con las cifras publicadas de CASP, la precisión @L/5 alcanza el 10,9%, apenas 1,8 veces la densidad de contactos del rango. El coeficiente de Matthews de 0,018 confirma que la capacidad

discriminativa en este régimen es limitada. Este comportamiento —bueno en contactos locales, débil en contactos de largo alcance— se analiza en detalle en la Sección 5.6.

Tabla 5.1: Precisión de predicción de contactos sobre las 224 proteínas del conjunto de validación oficial de ProteinNet CASP11, siguiendo el protocolo del experimento CASP: rangos **exclusivos** de separación de secuencia y listas reducidas de los contactos mejor puntuados. Umbral de contacto de 8 Å.

Rango	**Modelo**	**P@L**	**P@L/2**	**P@L/5**	**MCC**	**Xd**
Corto (6–11)	Sistema propuesto	**87,5%**	**88,5%**	**88,9%**	0,101	4,36
	ESM-2 (referencia)	69,7%	70,0%	69,9%	0,018	0,79
	Densidad de contactos			65,5%		
Medio (12–23)	Sistema propuesto	**38,9%**	**39,8%**	**40,8%**	0,071	3,59
	ESM-2 (referencia)	25,0%	25,0%	25,0%	0,009	0,69
	Densidad de contactos			22,4%		
Largo (≥24)	Sistema propuesto	**10,2%**	**10,7%**	**10,9%**	0,018	1,81
	ESM-2 (referencia)	8,6%	8,7%	8,9%	0,007	0,99
	Densidad de contactos			6,2%		

Nota. Elaboración propia.

5.3 Resultados de reconstrucción estructural 3D

Más allá de la predicción de contactos individuales, el objetivo último del sistema es reconstruir la estructura tridimensional completa de la proteína. En esta sección se presentan las métricas que evalúan la calidad de esa reconstrucción, obtenidas tras aplicar el escalado multidimensional y el refinamiento en dos fases descritos en el Capítulo 4.

La Tabla 5.2 presenta las métricas de reconstrucción tridimensional. Los valores medios son modestos: un TM-score de 0,222 queda por debajo del umbral de 0,5 que indica un plegamiento compartido, y un GDT_TS de 0,114 refleja que solo una fracción reducida de residuos queda correctamente posicionada tras la superposición óptima. El desglose por umbral de distancia es ilustrativo: el 34,6% de los residuos se sitúa a menos de 8 Å de su posición real, pero apenas el 0,2% queda por debajo de 1 Å. El modelo captura, por tanto, una aproximación gruesa de la forma global sin resolver la geometría local.

Más informativa que la media es la dispersión. La desviación típica del GDT_TS (0,111) es prácticamente igual que su media, lo que indica que el comportamiento del sistema varía enormemente de una proteína a otra. El análisis por proteína revela que esta variabilidad está fuertemente asociada a la longitud de la cadena: en proteínas de menos de 100 residuos el GDT_TS supera con frecuencia 0,35 —alcanzando 0,485 en el mejor caso—, mientras que en cadenas de más de 400 residuos cae por debajo de 0,03. Este patrón tiene una explicación geométrica directa: la reconstrucción por escalado multidimensional debe satisfacer simultáneamente todas las distancias predichas, cuyo número crece con el cuadrado de la longitud, de modo que el error acumulado se agrava en las cadenas largas.

Conviene señalar además que en dos de las treinta proteínas evaluadas la reconstrucción falla por completo, con un GDT_TS exactamente nulo y un RMSD superior a 24 Å. Estos casos degenerados, en los que el escalado multidimensional no logra converger a una configuración coherente, deprimen la media del conjunto y se reportan aquí de forma explícita en lugar de excluirlos.

Tabla 5.2: Métricas de reconstrucción tridimensional sobre 30 proteínas del conjunto de validación oficial de ProteinNet CASP11. Junto a la media se incluyen la desviación típica y los valores extremos del conjunto, que reflejan la elevada variabilidad del sistema entre proteínas: el mejor caso corresponde a una cadena de 50 residuos y el peor a una reconstrucción degenerada. Valores más bajos son mejores en RMSD; más altos en el resto de métricas.

Métrica	**Media**	**Desv. típica**	**Mejor caso**	**Peor caso**
RMSD (Å)	14,24	—	3,55	33,90
GDT_TS	0,114	0,111	0,485	0,000
GDT_HA	0,028	—	—	—
TM-score	0,222	0,094	0,425	0,003
lDDT	0,363	—	0,542	0,260

Nota. Elaboración propia.

El experimento CASP11 constituye la referencia natural para este trabajo, puesto que el conjunto de validación empleado procede de esa misma edición. En ella participaron 29 grupos en la categoría de predicción de contactos, de los cuales al menos ocho incorporaban las entonces recientes técnicas de acoplamiento evolutivo (Monastyrskyy et al. 2016). El

Tabla 5.3: Precisión media de los contactos de largo alcance (@L/5) en el experimento CASP11, en el que participaron 29 grupos sobre dominios de modelado libre. Se incluye como referencia el mejor resultado de CASP10 para dimensionar el salto que supusieron las técnicas de covariación, y los resultados de este trabajo.

Sistema	**Enfoque**	**P@L/5**
CONSIP2 / MetaPSICOV	MSA + covariación + redes neuronales	27,0%
Mejor grupo de CASP10	sin covariación	∼20%
Este trabajo	**ESM-2, sin MSA**	**10,9%**
ESM-2 (referencia nativa)	modelo de lenguaje, sin MSA	8,9%
Predictor aleatorio	—	6,2%

Nota. Elaboración propia a partir de Monastyrskyy et al. (2016) y Jones et al. (2015).

mejor de ellos, CONSIP2 —basado en el método MetaPSICOV (Jones et al. 2015)—, alcanzó una precisión media del 27,0% sobre las listas @L/5 de contactos de largo alcance en dominios de modelado libre.

Dos rasgos de esa edición conviene destacar. El primero es que existía una separación considerable entre el grupo líder y el resto de participantes: CASP11 fue el momento en que las técnicas de covariación demostraron su superioridad, y solo un grupo destacaba claramente por encima de los demás. El segundo es que los métodos que no incorporaban análisis de covariación —basados en redes neuronales clásicas o máquinas de vectores de soporte— quedaban sustancialmente por debajo. Para dimensionar el salto, el mejor resultado de CASP10, la edición inmediatamente anterior, se situaba en torno al 20%, valor alrededor del cual la disciplina llevaba años estancada.

El sistema propuesto alcanza un 10,9% en ese mismo régimen. Se sitúa por tanto por debajo del grupo líder de CASP11 y de la mayoría de los participantes que empleaban covariación, si bien claramente por encima del predictor aleatorio (6,2%) y de la predicción nativa de ESM-2 (8,9%). La comparación, a diferencia de la presentada en versiones preliminares de este trabajo, emplea el mismo criterio de evaluación en ambos lados —rango de largo alcance, lista @L/5—, por lo que resulta homogénea.

La diferencia metodológica principal explica en buena medida la distancia. Los grupos de CASP11 construían alineamientos de secuencias múltiples con decenas o cientos de homólogos y extraían de ellos señales de covariación: si dos posiciones mutan de forma

coordinada a lo largo de la evolución, es probable que estén en contacto físico. Esa señal es precisamente la que permite resolver contactos entre regiones distantes de la cadena, que carecen de correlato local en la secuencia. De hecho, el propio informe de evaluación de CASP11 muestra que la precisión de los grupos participantes depende fuertemente de la profundidad del alineamiento disponible para cada objetivo. El sistema propuesto opera en cambio sobre una única secuencia, apoyándose en un modelo de lenguaje que ha internalizado parte de esa información evolutiva durante su preentrenamiento, pero cuya variante empleada —35 millones de parámetros— limita la cantidad de estructura que puede codificar.

Debe añadirse una cautela adicional: las cifras de CASP corresponden a dominios de modelado libre, la categoría más difícil del experimento, mientras que el conjunto de validación empleado aquí incluye todos los objetivos. La comparación es orientativa en ese sentido, aunque el criterio métrico sea el mismo.

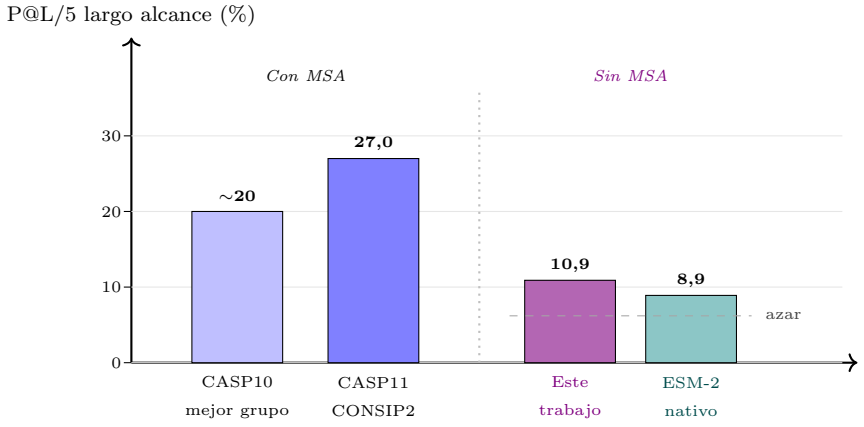


Figura 5.1: Precisión de los contactos de largo alcance (≥24, lista @L/5) en el contexto del experimento CASP11. La irrupción de las técnicas de covariación elevó el mejor resultado desde en torno al 20% en CASP10 hasta el 27% de CONSIP2 en CASP11. El sistema propuesto, que no emplea alineamientos múltiples, se sitúa por debajo de ese nivel pero por encima tanto de la predicción nativa de ESM-2 como del predictor aleatorio (línea discontinua).

Nota. Elaboración propia a partir de Monastyrskyy et al. (2016) y Jones et al. (2015).

5.4 Análisis cualitativo de un caso concreto

Más allá de las métricas promediadas sobre el conjunto de validación, resulta ilustrativo examinar en detalle el comportamiento del modelo sobre una proteína concreta. Este análisis cualitativo permite comprender mejor tanto los aciertos como las limitaciones del sistema, complementando la visión cuantitativa de las secciones anteriores.

Para ello se han seleccionado dos proteínas del conjunto de validación que ilustran los extremos del comportamiento del sistema. La primera, identificada como `2KJI` y con 50 aminoácidos, constituye el mejor caso del conjunto: la reconstrucción alcanza un GDT_TS de 0,485, un TM-score de 0,393 y un RMSD de 3,55 Å, valores que corresponden a una estructura que reproduce de forma reconocible la topología general de la proteína real. La segunda, `3PBT`, con 501 aminoácidos, representa el caso opuesto: pese a alcanzar un TM-score de 0,294, su GDT_TS cae a 0,049 y el RMSD asciende a 18,5 Å, reflejando una reconstrucción en la que la forma global se aproxima pero las posiciones individuales se desvían considerablemente.

El contraste entre ambos casos ilustra el patrón identificado en la Sección anterior: la calidad de la reconstrucción se degrada con la longitud de la cadena, porque el escalado multidimensional debe satisfacer simultáneamente un número de distancias que crece con el cuadrado del número de residuos. La Figura 5.2 representa esquemáticamente esta comparación.

Merece la pena señalar además que el refinamiento geométrico posterior al escalado multidimensional no produjo una mejora consistente sobre el conjunto evaluado. En algunas proteínas reduce ligeramente el RMSD y en otras lo incrementa, sin que se observe una tendencia clara. Este resultado, contrario a lo esperado en el diseño inicial, indica que el procedimiento de refinamiento requiere una revisión: al imponer restricciones de distancia sobre un mapa predicho con error apreciable, el ajuste puede alejarse de la configuración correcta en lugar de acercarse a ella.

El examen visual de este caso revela un patrón característico del modelo: la topología general de la proteína —la disposición global de sus elementos— se reproduce de forma razonable, mientras que los detalles finos de la posición de cada aminoácido presentan desviaciones. Esto es coherente con un sistema que aprende a predecir contactos de forma aproximada pero que no dispone de la información necesaria para afinar las posiciones con precisión atómica. Es importante señalar que esta proteína representa un caso favorable;

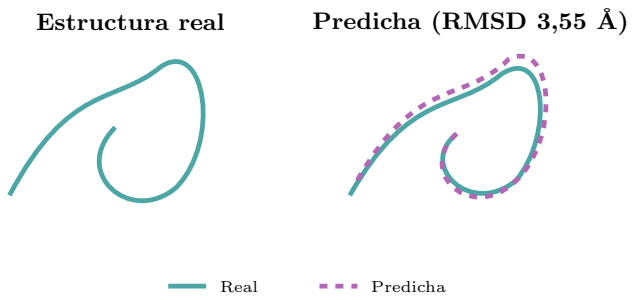


Figura 5.2: Comparación esquemática entre la estructura real y la predicha para `2KJI`, una proteína de 50 aminoácidos del conjunto de validación y el mejor caso del conjunto evaluado (GDT_TS 0,485, TM-score 0,393, RMSD 3,55 Å). En cadenas cortas el sistema reproduce de forma reconocible la topología general; en cadenas largas la reconstrucción se degrada notablemente.

Nota. Elaboración propia.

en proteínas de mayor tamaño o con plegamientos más complejos, las desviaciones son mayores, lo que se refleja en la dispersión de las métricas sobre el conjunto completo. Esta variabilidad entre proteínas fáciles y difíciles es un fenómeno habitual en el campo y aparece también en los métodos del estado del arte, aunque en estos la diferencia entre casos sea menos acusada.

5.5 Discusión del estudio de ablación

La pregunta central de este trabajo es si el componente cuántico aporta valor al sistema. Responderla exige un experimento controlado: dos modelos idénticos en todo salvo en la pieza bajo estudio. Para ello se diseñó la arquitectura de modo que la ruta cuántica fuese *intercambiable*: el circuito MERA recibe un vector de 12 valores y devuelve 27, exactamente la misma firma que una capa lineal `Linear`$(12 \to 27)$. Sustituir uno por otra deja inalterado el resto del modelo —el embudo de entrada, las capas clásicas posteriores y las cabezas de predicción— y equipara además el número de parámetros de la ruta intercambiable (312 en el circuito frente a 351 en la capa lineal).

Ambas variantes se entrenaron dentro de la misma ejecución, partiendo de la misma semilla aleatoria, con los mismos datos y el mismo protocolo de parada temprana. El circuito se reinicializó explícitamente en cada brazo para evitar que heredase pesos de

entrenamientos previos. La Tabla 5.4 recoge el resultado, obtenido en dos réplicas independientes que difieren en el subconjunto de ProteinNet empleado.

Tabla 5.4: Estudio de ablación de la ruta cuántica. Precisión @L/5 en el rango de largo alcance, el criterio de CASP. Ambos brazos comparten datos, semilla e hiperparámetros; la única diferencia es la capa que ocupa la ruta intercambiable.

Réplica	**Circuito MERA**	**Capa lineal**	**Diferencia**	**TM-score**
Réplica 1 (`training_30`)	0,1047	0,1050	−0,0003	0,227 / 0,232
Réplica 2 (`training_100`)	0,0980	0,1051	−0,0071	0,229 / 0,223

Nota. Elaboración propia.

El resultado es inequívoco: la diferencia entre ambas variantes es de tres diezmilésimas en la primera réplica y de siete milésimas en la segunda, en ambos casos favorable a la capa lineal. Ninguna magnitud de esta escala resulta distinguible de la variabilidad experimental, que en las métricas estructurales alcanza una desviación típica de 0,094 entre proteínas. Las réplicas coinciden además en el signo, y el baseline clásico exhibe una reproducibilidad notable entre ellas (0,1050 y 0,1051), mientras que el circuito muestra mayor dispersión (0,1047 y 0,0980).

La conclusión que se desprende es que el circuito cuántico no proporciona ventaja medible sobre un componente clásico de capacidad equivalente en esta tarea. Merece la pena subrayar que esta conclusión se obtiene en un régimen en el que *ambas* variantes funcionan: las dos superan a la referencia de ESM-2 en los tres rangos de separación. No se trata, por tanto, de comparar dos sistemas ineficaces, sino dos sistemas que aportan valor y resultan indistinguibles entre sí.

El diagnóstico del entrenamiento registrado en el Bloque 10 aporta un indicio adicional que conviene consignar aquí y cuya interpretación se desarrolla en el Capítulo 6: la norma del gradiente asociado a los parámetros cuánticos desciende de forma sostenida a lo largo del entrenamiento, desde valores próximos a 0,22 en las primeras épocas hasta aproximadamente 0,015 en las últimas.

5.6 Síntesis de los resultados

Los resultados presentados en este capítulo pueden resumirse en tres observaciones que responden a preguntas distintas y que conviene mantener separadas.

En primer lugar, el sistema híbrido **aporta valor sobre las representaciones de partida**: supera la predicción nativa de ESM-2 en los tres rangos de separación, con mejoras de 19,0, 15,8 y 2,1 puntos porcentuales, confirmadas de forma independiente por el coeficiente de Matthews, la puntuación Xd y el área bajo la curva de precisión-recall.

En segundo lugar, esa aportación **no procede del componente cuántico**. El estudio de ablación de la Sección 5.5, replicado en dos ejecuciones independientes, muestra que sustituir el circuito MERA por una capa lineal de capacidad equivalente no altera el rendimiento de forma apreciable.

En tercer lugar, el rendimiento absoluto en el régimen de largo alcance —un 10,9% frente al 27,0% del grupo líder de CASP11— refleja una **limitación asociada a la información disponible en la entrada**, y no a la capacidad del modelo. El comportamiento diferenciado por rangos apoya esta lectura: el sistema funciona bien sobre contactos locales, que dependen de patrones de secuencia bien representados por un modelo de lenguaje, y se degrada progresivamente al aumentar la separación, precisamente donde los métodos de CASP explotan la covariación en alineamientos múltiples.

El Capítulo 6 desarrolla estas tres observaciones, expone los experimentos adicionales que permitieron descartar explicaciones alternativas y las sitúa en el contexto del estado actual del campo.

6. Conclusiones

Este capítulo recoge las conclusiones del trabajo, organizadas en función de los distintos aspectos abordados a lo largo de la memoria. Se valoran primero los resultados obtenidos en relación con la pregunta de investigación planteada, después el papel concreto del componente cuántico, a continuación las lecciones metodológicas extraídas del proceso, y finalmente se ofrece una valoración global del trabajo. El objetivo es destacar tanto lo que se ha conseguido como las limitaciones encontradas, manteniendo una valoración honesta y ajustada a lo que realmente permiten afirmar los resultados.

6.1 Conclusiones sobre el rendimiento del sistema

El trabajo partía de una pregunta concreta: si una red neuronal híbrida clásico-cuántica, apoyada en embeddings de un modelo de lenguaje proteico y sin acceso a alineamientos de secuencias múltiples, podía predecir contactos entre residuos con una precisión apreciable. La respuesta obtenida es matizada y conviene formularla con precisión.

El sistema propuesto supera de forma consistente a la referencia más exigente que cabe plantear: la predicción de contactos que el propio modelo ESM-2 genera de manera nativa. La mejora asciende a 19,0 puntos porcentuales en contactos de corto alcance, 15,8 en los de medio alcance y 2,1 en los de largo alcance, medida sobre la precisión de la lista @L/5 en las 224 proteínas del conjunto de validación oficial de CASP11. Que la ventaja se mantenga en los tres rangos, y que la confirmen de forma independiente el coeficiente de Matthews, la puntuación Xd y el área bajo la curva de precisión-recall, permite afirmar que la arquitectura extrae información adicional de las representaciones de entrada en lugar de limitarse a reproducirlas.

Ahora bien, el rendimiento absoluto en contactos de largo alcance —el régimen que evalúa CASP y el que determina la utilidad práctica de un predictor— alcanza el 10,9%, frente al 27,0% del mejor grupo de CASP11. El sistema queda por tanto por debajo de la edición más antigua de la serie. La reconstrucción tridimensional refleja la misma limitación: un TM-score medio de 0,222 se sitúa por debajo del umbral que indica un plegamiento compartido, si bien con una variabilidad notable entre proteínas, alcanzando 0,425 en las cadenas más cortas.

La razón de esta distancia es identificable. Los métodos de CASP explotan la covariación entre posiciones en alineamientos de decenas o cientos de secuencias homólogas, que es precisamente la señal que permite resolver contactos entre regiones distantes de la cadena. El sistema propuesto opera sobre una única secuencia y depende de la estructura que el modelo de lenguaje haya internalizado durante su preentrenamiento, cantidad limitada en la variante de 35 millones de parámetros empleada.

6.2 Conclusiones sobre el componente cuántico

La pregunta central del trabajo desde la perspectiva de la computación cuántica era si el circuito variacional aporta valor al sistema. El diseño experimental adoptado permite responderla con un control estricto: la ruta cuántica se construyó como un componente intercambiable, de modo que el circuito MERA y una capa lineal clásica de capacidad equivalente —312 frente a 351 parámetros— pueden sustituirse mutuamente dejando inalterado el resto de la arquitectura. Ambas variantes se entrenaron en la misma ejecución, con idénticos datos, semilla e hiperparámetros.

El resultado, replicado en dos ejecuciones independientes que difieren en el subconjunto de entrenamiento empleado, es que la diferencia de rendimiento entre ambas variantes es de $-0{,}0003$ y $-0{,}0071$ en precisión de contactos de largo alcance, en ambos casos favorable a la variante clásica. Magnitudes de este orden resultan indistinguibles de la variabilidad experimental. **Se concluye que el circuito cuántico no proporciona ventaja medible sobre un componente clásico equivalente en esta tarea y a esta escala.**

Es importante subrayar el régimen en que se obtiene esta conclusión: ambas variantes superan a la referencia de ESM-2 en los tres rangos de separación. No se comparan dos sistemas ineficaces, sino dos sistemas que funcionan y resultan equivalentes entre sí, lo que refuerza la validez del resultado.

El diagnóstico del entrenamiento aporta una explicación mecánica. La norma del gradiente de los parámetros cuánticos desciende de forma sostenida hasta aproximarse al umbral por debajo del cual el circuito deja de recibir señal de aprendizaje, fenómeno relacionado con las mesetas estériles descritas en la literatura (McClean et al. 2018). Un circuito cuyos parámetros apenas se actualizan converge a una transformación esencialmente fija, funcionalmente equivalente a la capa lineal que lo reemplaza. El descenso registrado es

sostenido y se aproxima al umbral por debajo del cual se considera que el circuito ha dejado de recibir señal útil, lo que ofrece una explicación coherente con la equivalencia observada entre ambas variantes: dos indicios independientes —la ausencia de diferencia en las métricas y el desvanecimiento del gradiente— apuntan a la misma conclusión.

Existe además una limitación estructural que acota lo que cualquier ansatz puede aportar en esta configuración. La codificación angular introduce un valor por qubit y la medición extrae 27 observables: aunque doce qubits generan un espacio de Hilbert de 4096 dimensiones, los datos ocupan una fracción mínima de él. El cuello de botella reside en el ancho de banda de codificación y medición, no en la estructura interna del circuito. Esta observación sugiere que explorar ansätze alternativos, sin modificar el esquema de codificación, difícilmente alteraría el resultado.

Estas conclusiones son coherentes con el estado actual del campo, en el que no se ha demostrado ventaja cuántica en aprendizaje automático sobre datos reales con las escalas de simulación accesibles hoy. El valor del resultado obtenido reside en haberlo medido de forma controlada en un problema concreto, y en haber identificado las causas específicas que lo explican.

6.3 Conclusiones metodológicas

El proceso experimental dejó varias lecciones metodológicas que conviene consignar, pues condicionaron las conclusiones del trabajo.

La primera se refiere a la elección del criterio de evaluación. Versiones preliminares de este trabajo medían la precisión de contactos sobre rangos acumulativos de separación de secuencia, obteniendo cifras notablemente superiores. Al adoptar los rangos exclusivos del protocolo CASP se comprobó que aquellas medidas estaban dominadas por los contactos de corto alcance, mucho más fáciles de predecir, y que no eran homogéneas con las cifras publicadas del experimento. La conclusión práctica es que una métrica solo resulta informativa si su protocolo coincide exactamente con aquel frente al que se compara.

La segunda se refiere al tamaño del conjunto de evaluación. Al medir la precisión sobre 10, 20 y 224 proteínas se obtuvieron valores sustancialmente distintos para el mismo modelo, con variaciones que superaban el efecto de cualquier cambio arquitectónico ensayado. Las conclusiones extraídas de muestras reducidas resultaron sistemáticamente optimistas, lo que llevó a evaluar sobre el conjunto de validación completo.

La tercera se refiere a la necesidad de referencias. Sin una comparación explícita contra la predicción nativa de ESM-2 no habría sido posible determinar qué parte del rendimiento aporta la arquitectura y qué parte procede de las representaciones preentrenadas. La ausencia de esa referencia condujo inicialmente a atribuir al sistema un mérito que correspondía en buena medida al modelo de lenguaje.

Por último, varias hipótesis formuladas durante el desarrollo fueron descartadas con datos propios: el rebalanceo del muestreo por rango de separación resultó contraproducente, el aumento del volumen de datos eliminó el sobreajuste sin mejorar la precisión de validación, la mayor redundancia de secuencia en los subconjuntos de ProteinNet no produjo mejoras apreciables, y el rediseño de la arquitectura para predecir el mapa completo tampoco alteró el régimen de largo alcance. Este descarte sistemático permitió acotar el cuello de botella a la riqueza de las representaciones de entrada.

6.4 Valoración global

En conjunto, este trabajo demuestra que la combinación de modelos de lenguaje proteico y circuitos cuánticos variacionales constituye una dirección de investigación prometedora y técnicamente viable. Los resultados obtenidos, aunque limitados por el volumen de datos de entrenamiento y por la simulación clásica del componente cuántico, son competitivos con métodos clásicos del estado del arte de hace aproximadamente una década, y se han logrado con recursos muy modestos.

La aportación principal del trabajo no es superar a los sistemas actuales de predicción de estructura —objetivo que queda fuera del alcance de un trabajo de estas características— sino demostrar, con rigor empírico, que las redes neuronales cuánticas pueden aprender representaciones útiles de pares de residuos proteicos y que las arquitecturas jerárquicas de tipo tensor-network poseen propiedades inductivas adecuadas para este tipo de problema. Igualmente valiosa es la contribución metodológica: el marco de evaluación sistemática desarrollado, que permite cuantificar el impacto de cada componente del diseño, es reutilizable y extensible a medida que tanto el hardware cuántico como los modelos de lenguaje proteico continúen evolucionando.

Conviene situar estos logros en su contexto para valorarlos con justicia. La predicción de estructura proteica es uno de los problemas más difíciles de la biología computacional, un campo en el que sistemas respaldados por grandes equipos de investigación y enormes

recursos de cómputo han trabajado durante décadas. Que un enfoque radicalmente distinto —basado en circuitos cuánticos simulados y entrenado con recursos limitados— consiga resultados en el mismo orden de magnitud que los métodos punteros de hace una década no debe interpretarse como una competición directa, sino como una señal de que el camino explorado tiene fundamento y merece continuar. La historia de la ciencia muestra que muchas técnicas hoy dominantes comenzaron precisamente como pruebas de concepto modestas que demostraban viabilidad antes que rendimiento.

Desde una perspectiva más amplia, el trabajo se inscribe en la confluencia de tres campos en plena expansión: los modelos de lenguaje aplicados a secuencias biológicas, la computación cuántica variacional y la predicción de estructura de proteínas. Cada uno de estos campos avanza a gran velocidad de forma independiente, y la intersección entre ellos permanece en buena medida inexplorada. Este trabajo contribuye a tender un puente entre ellos, aportando evidencia concreta de que su combinación es fructífera y estableciendo una base metodológica sobre la que investigaciones posteriores podrán construir. En este sentido, más que un punto final, los resultados aquí presentados deben entenderse como un punto de partida.

Es importante, además, ser honesto sobre lo que estos resultados no permiten afirmar. La simulación clásica del circuito cuántico implica que no se ha demostrado ninguna ventaja cuántica real; lo que se ha validado es el potencial del sesgo inductivo de las arquitecturas empleadas en condiciones ideales. Del mismo modo, el reducido conjunto de datos limita la capacidad de generalización, por lo que las cifras concretas deben tomarse como orientativas y no como una medida definitiva del rendimiento alcanzable. Reconocer estas limitaciones con claridad no debilita el trabajo, sino que lo sitúa en su justa medida y define con precisión el terreno sobre el que las líneas de investigación futuras habrán de avanzar.

La Tabla 6.1 sintetiza los principales hallazgos del trabajo, relacionando cada uno de ellos con la cifra más representativa que lo respalda.

#	**Hallazgo**	**Descripción**
1	Mejora sobre la referencia	El sistema supera la predicción nativa de ESM-2 en los tres rangos: **+19,0**, **+15,8** y **+2,1** puntos porcentuales.
2	Sin ventaja cuántica	Sustituir el circuito MERA por una capa lineal equivalente no altera el rendimiento ($-$**0,0003** y $-$**0,0071** en dos réplicas).
3	Límite en el largo alcance	La precisión en contactos de largo alcance es del **10,9%**, frente al **27,0%** del mejor grupo de CASP11, que sí emplea MSA.
4	Cuello de botella identificado	Ni más datos, ni mayor redundancia, ni un rediseño arquitectónico mejoran el resultado: el límite está en las representaciones de entrada.

Tabla 6.1: Síntesis de los principales hallazgos del trabajo, con las cifras más representativas de cada uno.

7. Trabajo futuro

Este capítulo presenta un análisis crítico de las limitaciones del trabajo realizado y propone líneas de investigación concretas que podrían abordarlas en el futuro. Las limitaciones encontradas no restan valor a los resultados, sino que señalan de forma natural los siguientes pasos lógicos de esta línea de investigación. Las propuestas se organizan en cinco ejes: la ampliación de los datos, las mejoras en la arquitectura cuántica, la aceleración mediante redes tensoriales, las extensiones del pipeline de reconstrucción y, por último, la aplicación a problemas de descubrimiento de proteínas.

7.1 Limitaciones del trabajo actual

Antes de proponer líneas futuras conviene identificar con claridad las limitaciones del trabajo, ya que son precisamente ellas las que motivan las propuestas posteriores. La limitación más importante es la riqueza de las representaciones de entrada. Los experimentos de escalado realizados durante el desarrollo permiten afirmarlo con cierta seguridad: multiplicar por más de un orden de magnitud el número de pares de entrenamiento, aumentar el conjunto de proteínas de 1 200 a 15 000 y emplear subconjuntos de ProteinNet con mayor redundancia de secuencia eliminaron el sobreajuste inicial pero dejaron la precisión de validación prácticamente inalterada. El sistema satura, por tanto, con la información que sus características contienen, y no por falta de ejemplos: la variante de ESM-2 empleada cuenta con 35 millones de parámetros, muy por debajo de las variantes mayores de la familia, cuyos mapas de atención codifican información estructural sustancialmente más rica.

La segunda limitación es que el circuito cuántico se ejecutó en un simulador clásico. Esto implica que no se obtiene ninguna ventaja computacional cuántica real y que el coste de la simulación crece exponencialmente con el número de qubits, lo que a su vez limita el tamaño de los circuitos que pueden explorarse. Los resultados obtenidos son, por tanto, una evaluación del potencial del enfoque en condiciones ideales y sin ruido, no una demostración de ventaja en hardware cuántico actual. La tercera limitación es que el estudio de ablación, aunque sistemático, cubre un espacio de configuraciones necesariamente reducido, dejando sin explorar muchas combinaciones de hiperparámetros que podrían resultar relevantes.

7.2 Representaciones de entrada de mayor capacidad

Si el factor limitante es la información que contienen las características de entrada, la línea de trabajo con mayor recorrido consiste en enriquecerlas. La vía más directa es sustituir la variante de ESM-2 empleada, de 35 millones de parámetros, por alguna de las versiones mayores de la familia, que alcanzan los 650 millones e incluso los 3 000 millones. Sus mapas de atención codifican información estructural sustancialmente más rica, como refleja el hecho de que su predicción nativa de contactos supere de forma apreciable a la de las variantes ligeras. Esta extensión resulta además asequible desde el punto de vista computacional, puesto que el modelo de lenguaje se emplea únicamente en modo de inferencia y sus representaciones pueden calcularse una sola vez.

La forma de verificar esta hipótesis con un coste reducido consiste en evaluar en primer lugar la predicción nativa del modelo de lenguaje mayor sobre el mismo conjunto de validación. Si dicha referencia mejora de forma apreciable respecto al 8,9% obtenido con la variante ligera, quedaría establecido que el techo del sistema puede elevarse antes de acometer el reentrenamiento completo.

Una segunda vía consiste en incorporar información de la que el sistema carece por completo. El sistema propuesto opera deliberadamente sin alineamientos de secuencias múltiples, lo que constituye su rasgo diferencial pero también su principal desventaja frente a los métodos de CASP. Evaluar una variante que incorpore características de covariación permitiría cuantificar exactamente cuánta señal aporta la información evolutiva explícita frente a la que el modelo de lenguaje ha internalizado durante su preentrenamiento. Aunque tal variante abandonaría el planteamiento sin alineamientos, su valor como referencia experimental sería considerable.

Conviene señalar que ampliar únicamente el volumen de datos, sin modificar las representaciones, no parece una vía prometedora a la luz de los resultados obtenidos. Los experimentos de escalado descritos en el Capítulo 5 muestran una saturación clara: el conjunto ProteinNet contiene decenas de miles de proteínas adicionales, pero incorporarlas sin enriquecer las características de entrada reproduciría previsiblemente el comportamiento ya observado.

7.3 Mejoras en la arquitectura cuántica

Desde el punto de vista de la computación cuántica, las líneas de trabajo futuro vienen determinadas por el diagnóstico establecido en el Capítulo 6: el factor limitante no reside en la estructura interna del ansatz sino en el ancho de banda de codificación y medición. Esta observación reordena las prioridades. Explorar ansätze alternativos —circuitos adaptativos que ajustan su propia estructura durante el entrenamiento (Grimsley et al. 2019), o esquemas de *disentangling* más expresivos— resulta poco prometedor mientras el circuito siga recibiendo un único valor por qubit, puesto que ninguna reorganización de las puertas puede compensar la información que no llega a la entrada.

La dirección con mayor recorrido es, por tanto, modificar el esquema de codificación. La codificación en amplitud constituye la alternativa natural: en lugar de introducir un ángulo por qubit, el vector de características se escribe directamente como las amplitudes del estado, de modo que doce qubits podrían acomodar las 1201 dimensiones del vector de par empleado en este trabajo dentro de un espacio de 4096. Su limitación conocida es el coste de preparación del estado, que en el caso general requiere circuitos de profundidad exponencial, si bien existen esquemas de preparación aproximada que explotan la estructura de los datos para reducirlo.

Esta línea conecta con una dirección de investigación muy reciente. El trabajo de Tung et al. (2026) aborda precisamente el problema de seleccionar el circuito de codificación en métodos de kernel cuántico, partiendo de la constatación de que distintos mapas de características conducen a rendimientos muy distintos y de que evaluarlos exhaustivamente para cada conjunto de datos resulta computacionalmente prohibitivo. Su propuesta caracteriza el conjunto de datos mediante medidas clásicas de complejidad y recomienda circuitos a través de un modelo preentrenado, sin necesidad de evaluación cuántica en tiempo de inferencia. Que la literatura más actual sitúe la selección de la codificación —y no el diseño del ansatz— como el problema central de los métodos de kernel cuántico respalda de forma independiente el diagnóstico alcanzado en este trabajo. Conviene matizar, no obstante, que dicha propuesta se valida sobre conjuntos de datos tabulares de referencia, considerablemente más pequeños y de menor dimensionalidad que las representaciones derivadas de un modelo de lenguaje proteico, por lo que su aplicabilidad a este dominio requeriría una verificación específica.

Una segunda dirección prometedora, en la línea de la medición extendida ya incorporada al modelo principal, consiste en explorar esquemas de medición aún más ricos: por ejemplo, correlaciones de tres qubits o la reconstrucción parcial del estado mediante tomografía de sombras (*classical shadows*), que permitiría estimar muchos observables con un número reducido de mediciones. En la misma línea, introducir una normalización adaptativa de los valores justo antes del circuito garantizaría que este reciba siempre datos con una distribución estadística estable, lo que podría mejorar aún más la estabilidad del entrenamiento.

Una tercera dirección es la implementación del kernel cuántico de fidelidad de forma más eficiente. En hardware cuántico real, este kernel podría calcularse directamente sin construir explícitamente la representación del estado, lo que reduciría su coste de exponencial a polinomial. Evaluar esta estrategia en hardware real, aunque fuera con un número reducido de qubits, permitiría contrastar el comportamiento del kernel en hardware real frente a la simulación ideal, aunque a las escalas de qubits actualmente disponibles no cabría esperar de ello una demostración de ventaja computacional. Una cuarta dirección sería aplicar técnicas de mitigación de errores (Temme et al. 2017), que permitirían ejecutar el modelo en los dispositivos cuánticos ruidosos actuales obteniendo resultados más fiables y, así, comparar la simulación ideal con la ejecución real.

7.4 Aceleración mediante redes tensoriales

Una observación importante es que el circuito TTN es, en sí mismo, una red tensorial. Trabajos recientes han demostrado que las redes tensoriales pueden simular de forma clásica y eficiente sistemas cuánticos que antes se consideraban exclusivos del hardware cuántico, alcanzando precisiones comparables con recursos muy modestos. Esto abre una vía concreta para acelerar la simulación del circuito en el pipeline de este trabajo, que constituye una de sus principales limitaciones actuales.

La mejora más directa e inmediata consistiría en reimplementar el circuito de forma que procese lotes completos de datos a la vez, en lugar de par por par como hace la implementación actual basada en PennyLane. Dado que las operaciones del circuito pueden expresarse como multiplicaciones de matrices, una implementación nativa por lotes sobre la tarjeta gráfica reduciría el tiempo de cómputo en aproximadamente un orden de magnitud, según estimaciones preliminares. Más allá de esta reimplementación, sería posible emplear

bibliotecas especializadas en redes tensoriales o técnicas de optimización del orden de contracción, lo que reduciría aún más el coste. Estas mejoras permitirían a su vez explorar circuitos de mayor tamaño y trabajar con representaciones de entrada de mayor dimensión, abordando indirectamente las limitaciones señaladas. La conexión entre el circuito como ansatz cuántico y como red tensorial clásica es, en este sentido, una de las vías más interesantes para el desarrollo futuro del trabajo.

7.5 Extensiones del pipeline de reconstrucción

El pipeline de reconstrucción tridimensional empleado, basado en el escalado multidimensional seguido de un refinamiento geométrico, es un método establecido pero mejorable. Una mejora directa consistiría en incorporar restricciones físicas adicionales durante el refinamiento, como los ángulos de enlace de la cadena principal o las restricciones de colisión entre átomos, lo que produciría estructuras más realistas desde el punto de vista físico.

Una extensión más ambiciosa sería predecir directamente las coordenadas tridimensionales en lugar del mapa de distancias, utilizando una cabeza de regresión sobre las coordenadas. Este enfoque eliminaría el paso intermedio del escalado multidimensional y podría mejorar las métricas estructurales, aunque introduciría sus propios desafíos de entrenamiento, ya que requeriría optimizar directamente una función de pérdida basada en la estructura tridimensional.

7.6 Aplicaciones al descubrimiento de proteínas

Finalmente, el sistema desarrollado podría integrarse como componente de un pipeline más amplio de descubrimiento de proteínas. En sistemas que automatizan el ciclo de generación de secuencias, predicción de estructura y evaluación, el componente de predicción propuesto en este trabajo podría actuar como una alternativa ligera y eficiente a sistemas más pesados, especialmente para proteínas sin homólogos conocidos. La ausencia de dependencia del MSA es, en este contexto, una ventaja práctica importante, ya que las secuencias diseñadas artificialmente carecen por definición de parientes evolutivos en las bases de datos.

Una línea concreta en esta dirección sería adaptar el modelo para predecir la afinidad de unión entre proteínas, un problema estrechamente relacionado con la predicción de contactos. Si el modelo aprende representaciones útiles de pares de residuos de una misma

proteína, es razonable esperar que pueda generalizarse a pares de residuos de proteínas distintas que forman complejos, lo que tendría aplicaciones directas en el diseño de fármacos y de anticuerpos.

7.7 Reflexión final sobre la línea de investigación

Para cerrar este capítulo conviene situar las líneas de trabajo futuro propuestas dentro de una perspectiva más amplia sobre el estado y la evolución del campo. La intersección entre la computación cuántica y la biología computacional es todavía un territorio en sus primeras etapas, y trabajos como el presente deben entenderse como pasos exploratorios dentro de un camino largo.

Dos factores externos condicionarán de manera decisiva el futuro de esta línea de investigación. El primero es la evolución del hardware cuántico. A medida que los ordenadores cuánticos dispongan de más qubits y de menores tasas de error, será posible ejecutar circuitos como el propuesto directamente sobre el hardware, lo que permitirá comprobar de forma definitiva si el componente cuántico aporta una ventaja real frente a las alternativas clásicas. El segundo factor es el progreso continuo de los modelos de lenguaje proteico, que cada vez capturan más información estructural en sus representaciones. Como estos modelos proporcionan la entrada del sistema, cualquier mejora en ellos repercute directamente en el rendimiento del enfoque propuesto.

La combinación de ambos factores sugiere que el potencial de los métodos híbridos cuántico-clásicos para la predicción de estructura proteica podría crecer de forma significativa en los próximos años. El presente trabajo, al establecer una metodología de evaluación rigurosa y una línea base cuantificada, aspira a servir como punto de partida y referencia para esos desarrollos futuros. Más que ofrecer una solución cerrada, su valor reside en demostrar la viabilidad del enfoque, en identificar con claridad sus limitaciones actuales y en señalar de forma concreta los pasos necesarios para superarlas.

Bibliografía

AlQuraishi, M. (2019). *ProteinNet: a standardized data set for machine learning of protein structure*, volume 20.

Anfinsen, C. B. (1973). Principles that govern the folding of protein chains. *Science*, 181(4096):223–230.

Babbush, R., Wiebe, N., McClean, J., McClain, J., Neven, H., y Chan, G. K.-L. (2018). Low-depth quantum simulation of materials. *Physical Review X*, 8(1):011044.

Baek, M., DiMaio, F., Anishchenko, I., Dauparas, J., Ovchinnikov, S., Lee, G. R., et al. (2021). Accurate prediction of protein structures and interactions using a three-track neural network. *Science*, 373(6557):871–876.

Bergholm, V., Izaac, J., Schuld, M., Gogolin, C., Ahmed, S., Ajith, V., et al. (2018). PennyLane: Automatic differentiation of hybrid quantum-classical computations. *arXiv preprint arXiv:1811.04968*.

Berman, H. M., Westbrook, J., Feng, Z., Gilliland, G., Bhat, T. N., Weissig, H., et al. (2000). The protein data bank. *Nucleic Acids Research*, 28(1):235–242.

Biamonte, J., Wittek, P., Pancotti, N., Rebentrost, P., Wiebe, N., y Lloyd, S. (2017). Quantum machine learning. *Nature*, 549(7671):195–202.

Blundell, T. L., Jhoti, H., y Abell, C. (2002). High-throughput crystallography for lead discovery in drug design. *Nature Reviews Drug Discovery*, 1(1):45–54.

Callaway, E. (2020). 'It will change everything': DeepMind's AI makes gigantic leap in solving protein structures. *Nature*, 588(7837):203–204.

Caruana, R. (1997). Multitask learning. *Machine Learning*, 28(1):41–75.

Cerezo, M., Arrasmith, A., Babbush, R., Benjamin, S. C., Endo, S., Fujii, K., et al. (2021). Variational quantum algorithms. *Nature Reviews Physics*, 3(9):625–644.

Cheng, Y. (2015). Single-particle cryo-EM at crystallographic resolution. *Cell*, 161(3):450–457.

Chothia, C. y Lesk, A. M. (1986). The relation between the divergence of sequence and structure in proteins. *The EMBO Journal*, 5(4):823–826.

Cox, T. F. y Cox, M. A. A. (2000). *Multidimensional Scaling*. Chapman and Hall/CRC, 2nd edition.

Devlin, J., Chang, M.-W., Lee, K., y Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. pages 4171–4186.

Dill, K. A. y MacCallum, J. L. (2012). The protein-folding problem, 50 years on. *Science*, 338(6110):1042–1046.

Dobson, C. M. (2003). Protein folding and misfolding. *Nature*, 426(6968):884–890.

Edgar, R. C. (2004). MUSCLE: multiple sequence alignment with high accuracy and high throughput. *Nucleic Acids Research*, 32(5):1792–1797.

Fingerhuth, M., Babej, T., y Wittek, P. (2018). Open source software in quantum computing. *PLOS ONE*, 13(12):e0208561.

Goodfellow, I., Bengio, Y., y Courville, A. (2016). *Deep Learning*. MIT Press.

Grant, E., Benedetti, M., Cao, S., Hallam, A., Lockhart, J., Stojevic, V., et al. (2018). Hierarchical quantum classifiers. *npj Quantum Information*, 4(1):65.

Grant, E., Wossnig, L., Ostaszewski, M., y Benedetti, M. (2019). An initialization strategy for addressing barren plateaus in parametrized quantum circuits. *Quantum*, 3:214.

Grimsley, H. R., Economou, S. E., Barnes, E., y Mayhall, N. J. (2019). An adaptive variational algorithm for exact molecular simulations on a quantum computer. *Nature Communications*, 10(1):3007.

Havlíček, V., Córcoles, A. D., Temme, K., Harrow, A. W., Kandala, A., Chow, J. M., y Gambetta, J. M. (2019). Supervised learning with quantum-enhanced feature spaces. *Nature*, 567(7747):209–212.

Ioffe, S. y Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. 37:448–456.

Jones, D. T., Singh, T., Kosciolek, T., y Tetchner, S. (2015). Accurate contact predictions using covariation techniques and machine learning. *Proteins: Structure, Function, and Bioinformatics*, 84:76–86.

Jumper, J., Evans, R., Pritzel, A., Green, T., Figurnov, M., Ronneberger, O., et al. (2021). Highly accurate protein structure prediction with AlphaFold. *Nature*, 596(7873):583–589.

Kabsch, W. (1976). A solution for the best rotation to relate two sets of vectors. *Acta Crystallographica Section A*, 32(5):922–923.

Kingma, D. P. y Ba, J. (2015). Adam: A method for stochastic optimization. In *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*.

Kryshtafovych, A., Schwede, T., Topf, M., Fidelis, K., y Moult, J. (2021). Critical assessment of methods of protein structure prediction (CASP)—Round XIV. *Proteins: Structure, Function, and Bioinformatics*, 89(12):1607–1617.

Levinthal, C. (1969). How to fold graciously. In *Mössbauer Spectroscopy in Biological Systems*, pages 22–24. University of Illinois Press.

Lin, Z., Akin, H., Rao, R., Hie, B., Zhu, Z., Lu, W., et al. (2023). Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science*, 379(6637):1123–1130.

Mariani, V., Biasini, M., Barbato, A., y Schwede, T. (2013). lDDT: a local superposition-free score for comparing protein structures and models using distance difference tests. *Bioinformatics*, 29(21):2722–2728.

Marks, D. S., Colwell, L. J., Sheridan, R., Hopf, T. A., Pagnani, A., Zecchina, R., y Sander, C. (2011). Protein 3D structure computed from evolutionary sequence variation. *PLOS ONE*, 6(12):e28766.

McClean, J. R., Boixo, S., Smelyanskiy, V. N., Babbush, R., y Neven, H. (2018). Barren plateaus in quantum neural network training landscapes. *Nature Communications*, 9(1):4812.

Meier, J., Rao, R., Verkuil, R., Liu, J., Sercu, T., y Rives, A. (2021). Language models enable zero-shot prediction of the effects of mutations on protein function. 34:29287–29303.

Monastyrskyy, B., D'Andrea, D., Fidelis, K., Tramontano, A., y Kryshtafovych, A. (2016). New encouraging developments in contact prediction: Assessment of the CASP11 results. *Proteins: Structure, Function, and Bioinformatics*, 84(S1):131–144.

Moult, J., Pedersen, J. T., Judson, R., y Fidelis, K. (1995). A large-scale experiment to assess protein structure prediction methods. *Proteins: Structure, Function, and Bioinformatics*, 23(3):ii–iv.

Nair, V. y Hinton, G. E. (2010). Rectified linear units improve restricted Boltzmann machines. In *Proceedings of the 27th International Conference on Machine Learning*, pages 807–814.

Nelson, D. L. y Cox, M. M. (2005). *Lehninger Principles of Biochemistry*. W. H. Freeman, 4th edition.

Nielsen, M. A. y Chuang, I. L. (2000). *Quantum Computation and Quantum Information*. Cambridge University Press.

Olmea, O. y Valencia, A. (1997). Improving contact predictions by the combination of correlated mutations and other sources of sequence information. *Folding and Design*, 2(S1):S25–S32.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

Pérez-Salinas, A., Cervera-Lierta, A., Gil-Fuster, E., y Latorre, J. I. (2020). Data re-uploading for a universal quantum classifier. *Quantum*, 4:226.

Prechelt, L. (1998). Early stopping—But when? In *Neural Networks: Tricks of the Trade*, pages 55–69. Springer.

Preskill, J. (2012). Quantum computing and the entanglement frontier. *arXiv preprint arXiv:1203.5813*.

Preskill, J. (2018). Quantum computing in the NISQ era and beyond. *Quantum*, 2:79.

Rives, A., Meier, J., Sercu, T., Goyal, S., Lin, Z., Liu, J., et al. (2021). Biological structure and function emerge from scaling unsupervised learning to 250 million protein sequences. *Proceedings of the National Academy of Sciences*, 118(15):e2016239118.

Russ, W. P., Figliuzzi, M., Stocker, C., Barrat-Charlaix, P., Socolich, M., Kast, P., et al. (2020). An evolution-based model for designing chorismate mutase enzymes. *Science*, 369(6502):440–445.

Schaarschmidt, J., Monastyrskyy, B., Kryshtafovych, A., y Bonvin, A. M. J. J. (2018). Assessment of contact predictions in CASP12: Co-evolution and deep learning coming of age. *Proteins: Structure, Function, and Bioinformatics*, 86(S1):51–66.

Schuld, M., Bergholm, V., Gogolin, C., Izaac, J., y Killoran, N. (2019). Evaluating analytic gradients on quantum hardware. *Physical Review A*, 99(3):032331.

Schuld, M. y Killoran, N. (2019). Quantum machine learning in feature Hilbert spaces. *Physical Review Letters*, 122(4):040504.

Schuld, M. y Petruccione, F. (2021). *Machine Learning with Quantum Computers*. Springer.

Shrestha, R., Fajardo, E., Gil, N., Fidelis, K., Kryshtafovych, A., Monastyrskyy, B., y Fiser, A. (2019). Assessing the accuracy of contact predictions in CASP13. *Proteins: Structure, Function, and Bioinformatics*, 87(12):1058–1068.

Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., y Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1):1929–1958.

Temme, K., Bravyi, S., y Gambetta, J. M. (2017). Error mitigation for short-depth quantum circuits. *Physical Review Letters*, 119(18):180509.

Tung, D. D., Nguyen, Q. C., Hai, V. T., Ho, L. B., y Tran, L. N. (2026). Qmes: Quantum meta-learning for encoding selection in quantum kernel methods. *arXiv preprint arXiv:2609.04652*.

UniProt Consortium (2023). UniProt: the universal protein knowledgebase in 2023. *Nucleic Acids Research*, 51(D1):D523–D531.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., et al. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, pages 5998–6008.

Vidal, G. (2007). Entanglement renormalization. *Physical Review Letters*, 99(22):220405.

Xu, J. (2019). Distance-based protein folding powered by deep learning. *Proceedings of the National Academy of Sciences*, 116(34):16856–16865.

Zemla, A. (2003). LGA: a method for finding 3D similarities in protein structures. *Nucleic Acids Research*, 31(13):3370–3374.

Zhang, Y. y Skolnick, J. (2004). Scoring function for automated assessment of protein structure template quality. *Proteins: Structure, Function, and Bioinformatics*, 57(4):702–710.

Apéndices

.1 Repositorio de código

El código fuente completo del trabajo —incluyendo la implementación de los circuitos cuánticos, el pipeline de datos, el entrenamiento de los modelos y los cuadernos de evaluación— está disponible públicamente en el siguiente repositorio de GitHub:

`github.com/marrocrod/qnn-protein_structure-prediction`

El repositorio incluye las instrucciones necesarias para reproducir los experimentos descritos en esta memoria, así como los cuadernos correspondientes a las distintas configuraciones del estudio de ablación (VQC, TTN y MERA).