Red neuronal cuántica híbrida para la predicción de estructura tridimensional de proteínas mediante embeddings de lenguaje proteico

Marco Antonio Roca Rodríguez

Director: Mariano Caruso · Máster Universitario en Computación Cuántica

unir LA UNIVERSIDAD EN INTERNET

ÍNDICE

01 – Contexto

Proteínas y plegamiento · estado del arte · ESM-2 · computación cuántica · objetivos

02 – Metodología y desarrollo

Estructura · arquitectura · circuito MERA · decisiones de diseño

03 – Resultados

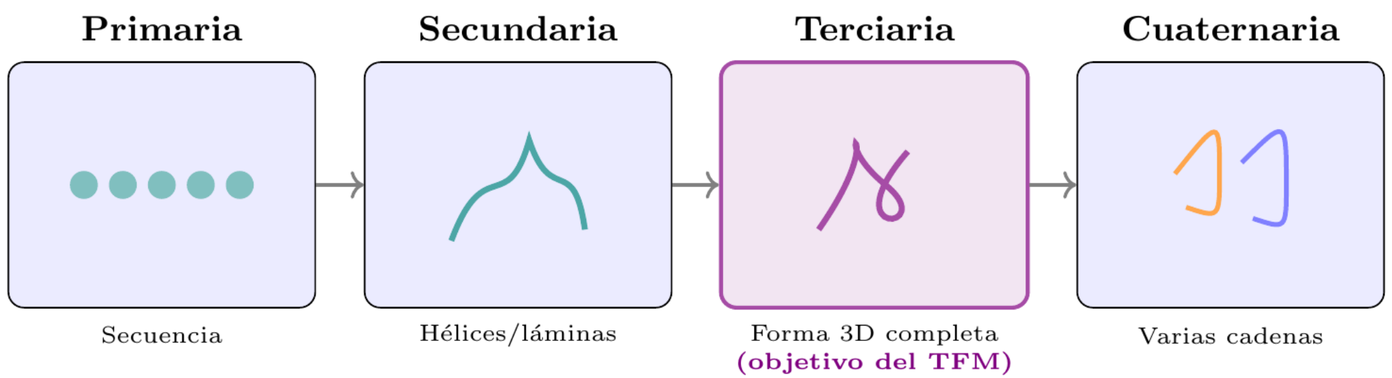
Evaluación · contactos · ablación · CASP11 · reconstrucción 3D

04 – Conclusiones

Conclusiones · trabajo futuro · agradecimientos

01 · Contexto
Las proteínas y el problema del plegamiento

Una proteína es una cadena de aminoácidos que se pliega, y su forma decide lo que hace.



- **Enzimas** aceleran las reacciones
- **Transporte** la hemoglobina lleva oxígeno
- **Defensa** los anticuerpos frenan virus
- **Señales** la insulina regula el azúcar
- **Estructura** el colágeno sostiene tejidos

La secuencia ya lo dice todo

Toda la información para plegarse está ahí (Anfinsen).

Hay infinitas formas posibles

Y aun así se pliega en milisegundos. Es la paradoja de Levinthal.

≈ 150 M frente a ≈ 250 000

Conocemos muchísimas secuencias y muy pocas estructuras: medirlas es lento y caro.

01 · Contexto
Estado del arte

Homología

Copiar la forma de una proteína parecida que ya conocemos

Si no hay parientes conocidos, no funciona

Covariación (MSA)

Si dos posiciones cambian a la vez entre especies, seguramente se tocan

En CASP11 llegó al 27 % en largo alcance

Aprendizaje profundo

AlphaFold2 (2021) acierta casi como un experimento

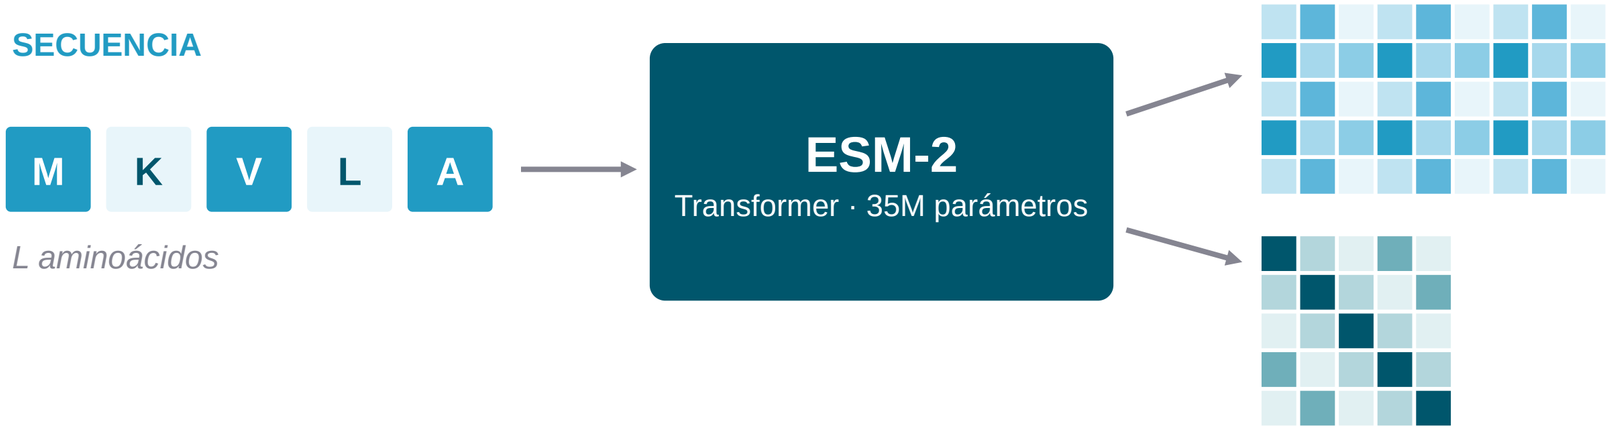
Ganó el Nobel de Química en 2024

Lo que se usa hoy

AlphaFold2	RoseTTAFold	AlphaFold3	ESMFold	Este trabajo
Necesita la secuencia y el MSA	Necesita la secuencia y el MSA	Usa el MSA y predice complejos con ADN	Le basta la secuencia, gracias a ESM-2	Combina ESM-2 con un circuito cuántico

El problema: casi todas necesitan el MSA y fallan si la proteína no tiene parientes. **La alternativa:** modelos de lenguaje que trabajan con una sola secuencia.

01 · Contexto
Embeddings de lenguaje proteico: ESM-2



1 Cómo aprende

Igual que un modelo de texto: se ocultan aminoácidos y aprende a predecirlos en millones de secuencias.

2 Qué es un embedding

480 números por aminoácido que resumen su contexto. Si dos residuos hacen papeles parecidos, sus vectores se parecen.

3 Por qué es útil aquí

Para acertar, el modelo aprende información evolutiva: su atención ya señala qué pares están en contacto, sin MSA.

01 · Contexto
¿Qué puede aportar la computación cuántica?

Las proteínas siguen las reglas de la física cuántica, y un ordenador cuántico funciona con esas mismas reglas.

Simular moléculas de forma natural

Los átomos se comportan de forma cuántica: un ordenador cuántico lo representa de forma natural, mientras que uno clásico necesita recursos que crecen exponencialmente.

Superposición: muchísimo espacio

n qubits pueden representar 2^n estados a la vez: con 12 qubits son 4096, usando muy pocos parámetros.

Entrelazamiento: todo conectado

Permite relacionar variables entre sí, como dos residuos alejados en la secuencia que acaban en contacto en el espacio.

Buscar la forma más estable

Plegarse es buscar la forma de menor energía, y algoritmos como VQE, QAOA o el annealing cuántico ya se prueban para eso en modelos sencillos.

La propuesta: una red neuronal cuántica (QNN) que aprende a predecir contactos.

Limitación: el hardware aún es pequeño y ruidoso, y nadie ha demostrado ventaja todavía.

01 · Contexto
Objetivos

La pregunta

Si se introduce un circuito cuántico en una red que predice contactos a partir de ESM-2, ¿mejora el resultado de forma medible?

1 Construir

Se construye un sistema completo, de ESM-2 para predecir la estructura 3D, con un circuito MERA de 12 qubits.

2 Aislar

El circuito se puede cambiar por una capa clásica para comparar en igualdad de condiciones.

3 Evaluar

Se mide con el protocolo de CASP11, para que las cifras sean comparables.

Alcance: no se usa MSA, el ESM-2 es el pequeño (35M, cabe en una GPU de 16 GB) y los 12 qubits son simulados. El objetivo no es superar a AlphaFold2, sino saber si lo cuántico aporta.

02 · Metodología y desarrollo
Estructura del proyecto

Por fases

01 · Investigar
Se estudian el plegamiento, CASP, los modelos de lenguaje proteico y el QML.

→

02 · Plantear
Se fijan la pregunta, el alcance y cómo se va a medir el resultado.

→

03 · Prototipo
Se construye una primera versión que va de la secuencia a la estructura 3D.

→

04 · Iterar
Se introducen los cambios de uno en uno, midiendo siempre con el mismo protocolo.

→

05 · Validar
Se compara el circuito con una capa clásica, se evalúa con CASP11.

Todo en un notebook: 5 etapas, 19 bloques

Datos
Bloques 1–6
Se cargan las proteínas de ProteinNet, se codifican con ESM-2 y se construyen los pares con sus distancias y ángulos reales.

Modelo híbrido
Bloques 7–8
Se define el circuito MERA de 12 qubits y se coloca entre la proyección MLP y las capas clásicas.

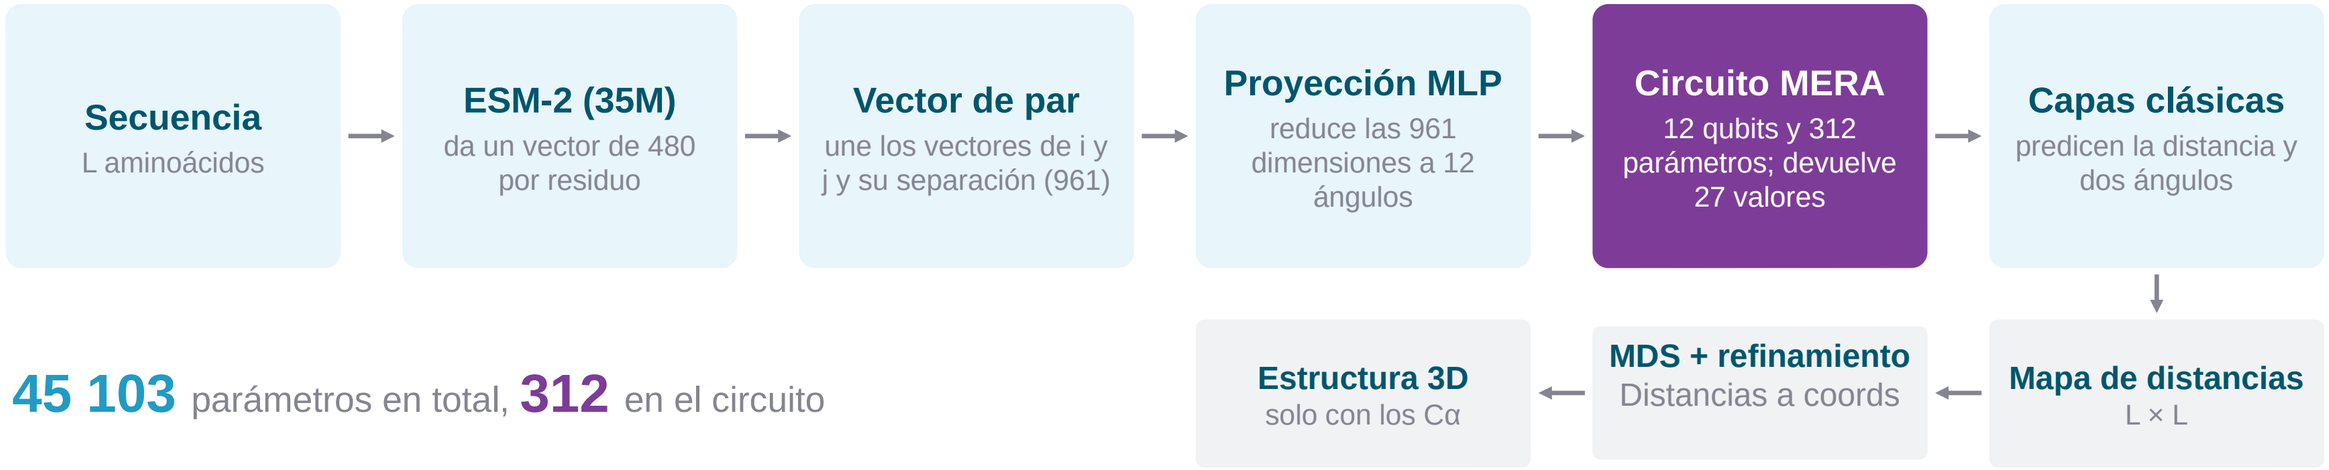
Entrenamiento
Bloques 9–10
La red aprende a la vez distancias y ángulos, con parada temprana, y se revisan las curvas.

Evaluación
Bloques 11–15
Se miden los contactos con el protocolo de CASP11 y se reconstruye la estructura 3D.

Ablación
Bloques 16–19
Se sustituye el circuito por una capa lineal, se comparan ambos y se exportan las estructuras a PDB.

Herramientas: PyTorch · PennyLane · ESM · **Repositorio:** github.com/marrocrod/qnn-protein_structure-prediction

02 · Metodología y desarrollo
Arquitectura y metodología de desarrollo



45 103 parámetros en total, **312** en el circuito

Metodología de desarrollo

Iterativa e incremental

Primero se construye una versión completa funcional y después se añaden mejoras de una en una.

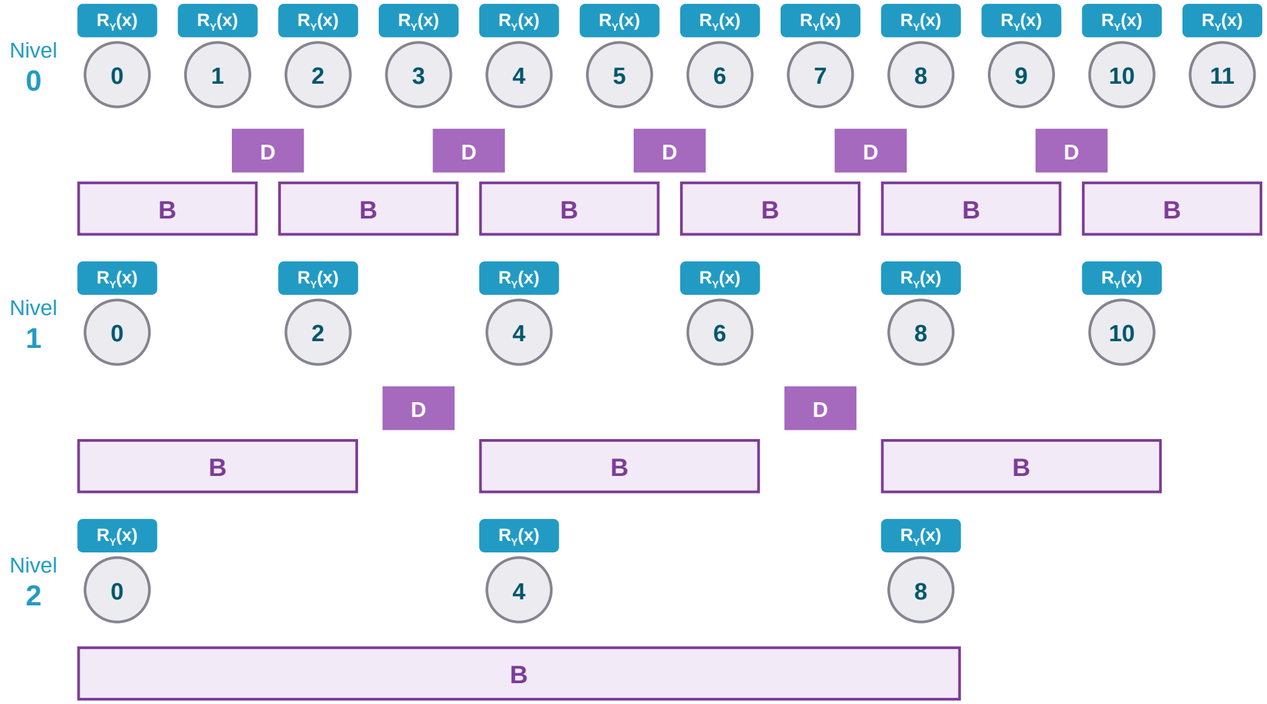
Aislamiento cuántico vs clásico

El MERA se puede cambiar por una capa lineal 12 → 27 (312 / 351 parámetros) sin tocar nada más, y la comparación se repite dos veces.

Evaluación

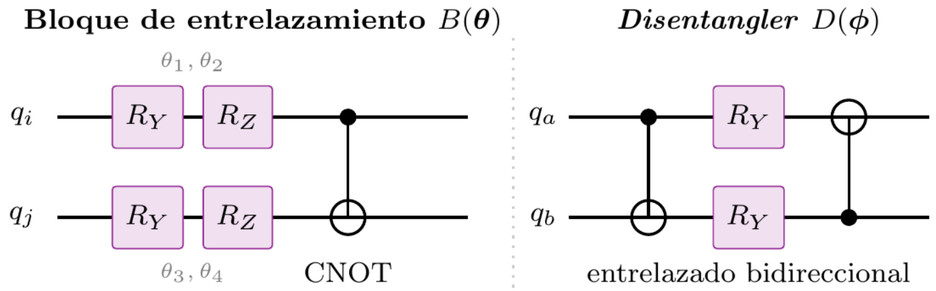
Todo se mide en 224 proteínas de validación que el modelo no ha visto, siguiendo el protocolo de CASP.

02 · Metodología y desarrollo
Circuito MERA de 12 qubits



RY(x): recarga de datos en cada nivel · B: bloque de entrelazamiento · D: disentangler

Medición: 12 ⟨Z⟩ + 9 ⟨ZZ⟩ + 3 ⟨X⟩ + 3 ⟨Y⟩ = 27 valores



12	312	4096
qubits	parámetros	dimensiones

Circuitos desarrollados: VQC → TTN → MERA

VQC
Circuito genérico, con CNOT entre todos los qubits

→

TTN
Árbol de 28 parámetros que solo medía 2 valores

→

MERA
Añade disentanglers al árbol y mide 27 valores

02 · Metodología y desarrollo
Decisiones de diseño y cambios en el circuito

Qubits · 12

Es un tamaño que la GPU simula bien; con más qubits el modelo memorizaba en lugar de generalizar.

Codificación · Angular

Cada uno de los 12 valores del par se convierte en el ángulo de giro de un qubit.

Recarga · En cada nivel

Los datos se vuelven a cargar en cada nivel, lo que da más expresividad sin alargar el circuito (Pérez-Salinas et al., 2020).

cambio

Ansatz · VQC → TTN → MERA

Al árbol se le añaden disentanglers para captar relaciones entre qubits lejanos.

Profundidad · Jerárquica

Cada nivel deja activos la mitad de los qubits, así que la profundidad crece muy despacio.

cambio

Medición · De 2 a 27 valores

Antes solo se medían $\langle Z_0 \rangle$ y $\langle Z_4 \rangle$; ahora se miden Z, ZZ, X e Y, que dan más información con los mismos parámetros.

Inicialización · [−0,01, 0,01]

Los parámetros empiezan casi a cero para evitar las mesetas estériles (Grant et al., 2019).

Aprendizaje · $5 \cdot 10^{-4}$ frente a $3 \cdot 10^{-3}$

El circuito usa una tasa más baja porque sus gradientes son más ruidosos que los clásicos.

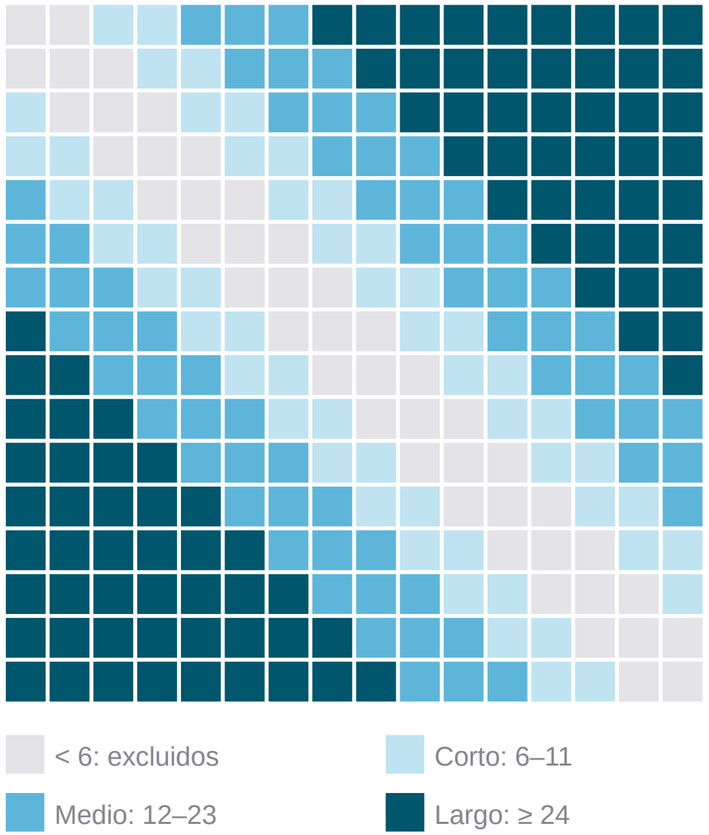
cambio

Simulación · Por lotes en GPU

En PennyLane, par a par, cada época tardaba media hora. Por lotes se pudieron usar 200 000 pares de 15 000 proteínas.

03 · Resultados
Cómo se evalúa: el protocolo de CASP11

Pares (i, j) según su separación



CASP
Una competición a ciegas que se celebra cada dos años desde 1994. Las proteínas de validación proceden de CASP11 (2014).

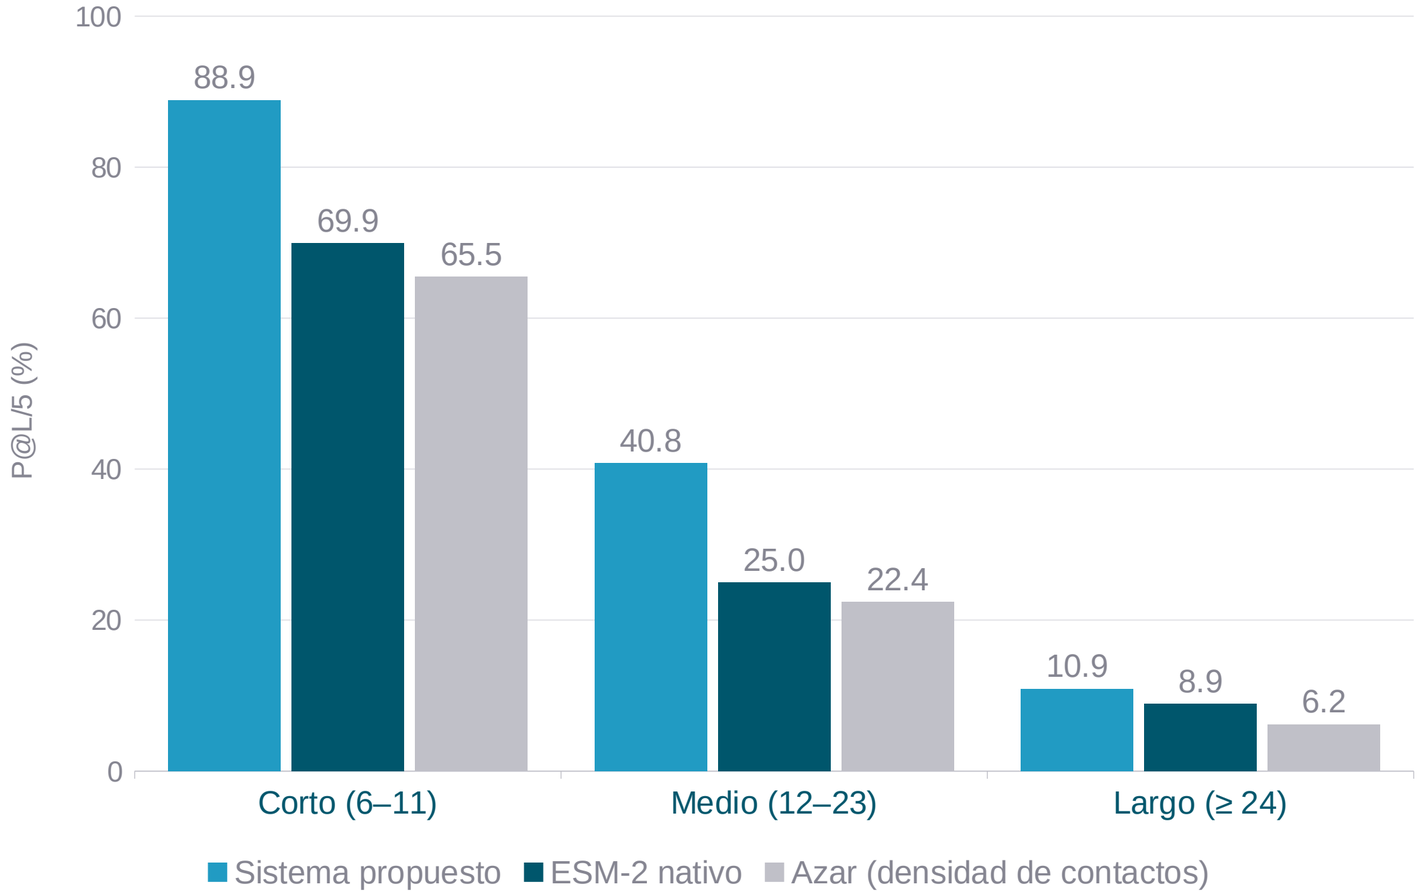
P@L/5
De los pares que el modelo ve más claros, ¿cuántos se tocan de verdad (a menos de 8 Å)?

Rangos por separado
Corto, medio y largo se miden aparte. El que cuenta en CASP es el largo.

Referencias
Los resultados se comparan siempre con el azar y con ESM-2.

Forma 3D
La estructura se mide con TM-score, GDT_TS, RMSD y lDDT en 30 proteínas.

03 · Resultados
Predicción de contactos



Mejora sobre ESM-2

+19,0 puntos · corto

+15,8 puntos · medio

+2,1 puntos · largo

Medido en 224 proteínas que el modelo nunca vio. MCC y Xd dicen lo mismo.

03 · Resultados
Resultados: ¿aporta algo el circuito?

Diferencia en P@L/5 de largo alcance (MERA − lineal)

−0,0003

Réplica 1 (training_30)
MERA 0,1047 frente a 0,1050 de la lineal

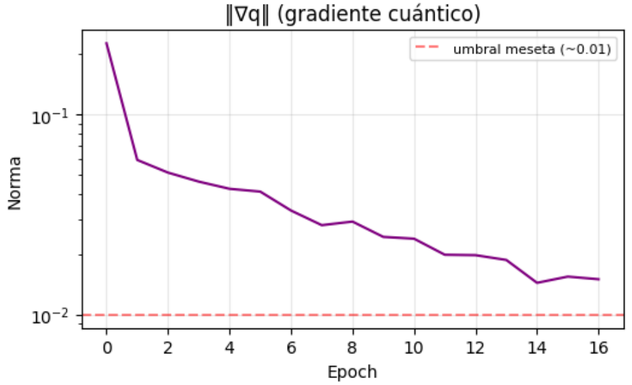
−0,0071

Réplica 2 (training_100)
MERA 0,0980 frente a 0,1051 de la lineal

312 / 351

Parámetros de la ruta
el circuito usa menos parámetros que la lineal

¿Por qué no hay ventaja?



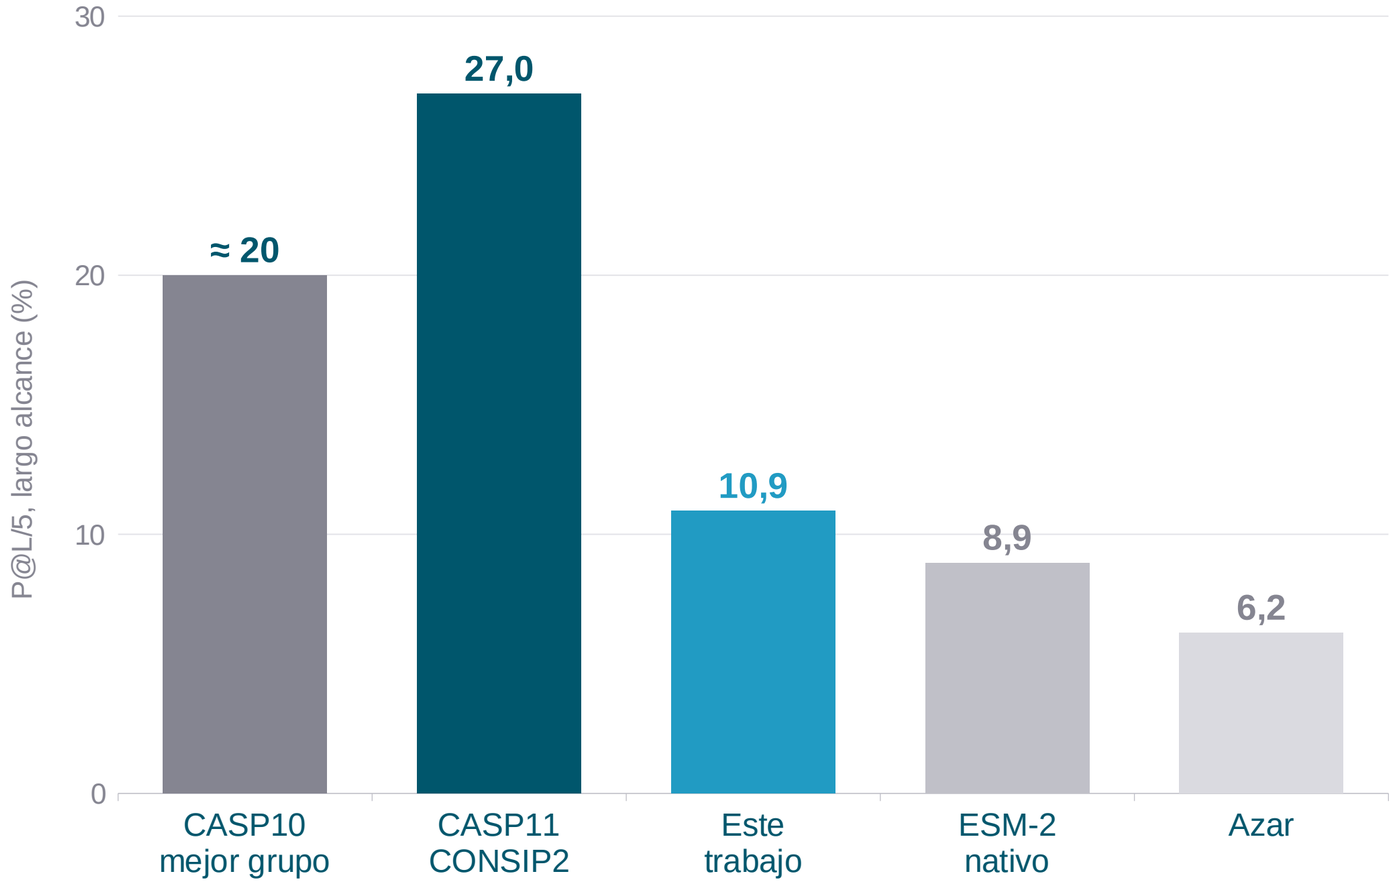
1 · El gradiente cae
Baja de 0,22 a 0,015: el circuito casi deja de aprender y acaba actuando como una capa lineal.

2 · Codificación
Al circuito solo entran 12 números y se leen 27, así que apenas se aprovechan sus 4096 dimensiones.

3 · La entrada
Ni más datos ni un modelo 2D mejoraron el largo alcance, porque a la entrada le falta información.

Conclusión: el circuito no mejora a una capa clásica equivalente.

03 · Resultados
Comparación con CASP11



Con MSA

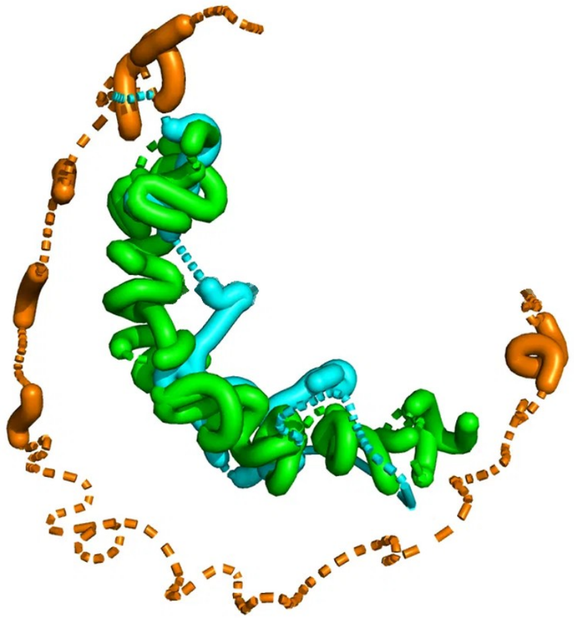
Usan cientos de proteínas parecidas para ver qué posiciones cambian juntas.

Sin MSA (este trabajo)

Se usa una sola secuencia y un ESM-2 pequeño, de 35 millones de parámetros.

CASP11 mide solo los casos más difíciles y aquí se miden todos, así que es una comparación orientativa.

03 · Resultados
Reconstrucción 3D



En PyMOL: la estructura real (cian), la reconstrucción directa (naranja) y la refinada (verde).

Media en 30 proteínas: TM 0,222 · GDT_TS 0,114 · RMSD 14,2 Å · lDDT 0,363

MEJOR CASO

2KJI · 50 aa

GDT_TS 0,485 · TM 0,393 · RMSD 3,55 Å

CADENA LARGA

3PBT · 501 aa

GDT_TS 0,049 · TM 0,294 · RMSD 18,5 Å

¿Por qué baja las métricas?

Arrastra los errores

Si el mapa de distancias tiene fallos, la estructura 3D también.

Cuantos más residuos, peor

Hay que cuadrar todas las distancias a la vez, y en cadenas largas son muchísimas.

Algunos casos fallan

En 2 de 30 proteínas la reconstrucción no converge y el refinamiento no siempre ayuda: eso hunde la media.

Conclusiones

+19,0

Mejora sobre ESM-2 en los tres rangos

Se ganan 19,0 puntos en corto, 15,8 en medio y 2,1 en largo alcance (P@L/5).

≈ 0

Sin ventaja cuántica medible

El MERA y una capa lineal equivalente dan lo mismo (−0,0003 y −0,0071).

10,9 %

Límite en el largo alcance

Lejos del 27,0 % de CASP11, que sí usa el MSA.

Entrada

El límite está en la entrada

Ni más datos ni otra arquitectura cambian el resultado, porque falta información de partida.

El valor del trabajo: se ha medido de forma controlada y se explica por qué ocurre.

04 · Conclusiones
Trabajo futuro

Parte cuántica

- Codificación en amplitud: meter el par entero en las 4096 amplitudes de 12 qubits
- Elegir la codificación con criterio, no a ojo (Qmes, 2026)
- Evaluar el kernel cuántico, que ya está programado
- Extraer más información del estado con classical shadows
- Llevarlo a hardware real, con mitigación de errores

Parte clásica

- Probar un ESM-2 más grande (650M o 3B)
- Añadir el MSA para medir cuánto aporta
- Mejorar la reconstrucción 3D en cadenas largas

Hoy por hoy: el circuito está simulado y sin ruido, solo se ha comparado un ansatz y el ESM-2 es pequeño.

muchas gracias

Anexo A
Predicción de contactos: detalle

Rango	Modelo	P@L	P@L/2	P@L/5	MCC	Xd	Densidad
Corto (6–11)	**Sistema propuesto**	**87,5 %**	**88,5 %**	**88,9 %**	**0,101**	**4,36**	**65,5 %**
	ESM-2 nativo	69,7 %	70,0 %	69,9 %	0,018	0,79	
Medio (12–23)	**Sistema propuesto**	**38,9 %**	**39,8 %**	**40,8 %**	**0,071**	**3,59**	**22,4 %**
	ESM-2 nativo	25,0 %	25,0 %	25,0 %	0,009	0,69	
Largo (≥ 24)	**Sistema propuesto**	**10,2 %**	**10,7 %**	**10,9 %**	**0,018**	**1,81**	**6,2 %**
	ESM-2 nativo	8,6 %	8,7 %	8,9 %	0,007	0,99	

224 proteínas de validación oficial de ProteinNet CASP11. Rangos exclusivos, umbral de 8 Å.

Anexo B
Ablación: detalle por réplica

Réplica	Variante	Parámetros	P@L/5 largo	MCC	Xd	TM-score	GDT_TS
1 · training_30	**Circuito MERA**	45 103	0,1047	0,016	1,64	0,227	0,120
	Capa lineal	45 142	0,1050	0,016	1,78	0,232	0,129
2 · training_100	**Circuito MERA**	45 103	0,0980	0,015	1,44	0,229	0,120
	Capa lineal	45 142	0,1051	0,016	1,79	0,223	0,114

Ambos brazos comparten datos, semilla e hiperparámetros; el circuito se reinicializa en cada brazo. Contactos sobre 224 proteínas; métricas 3D sobre 30.